


PROJET MENIA

Menia

Une machine peut-elle avoir un besoin qui compte pour elle ?



En bref

Un petit modèle de langage, Qwen3-0.6B, vit dans un monde minuscule où il a deux besoins cachés : l'énergie et la nourriture. Personne ne lui dit quoi faire. Il apprend à survivre seul, en ne gardant que les choix qui ont calmé ses besoins.

En regardant à l'intérieur du modèle, on trouve un **état** qui porte son besoin d'énergie. Le pousser fait agir l'agent et lui fait dire « mon énergie est basse ». L'effacer l'empêche de survivre et de le dire. Des interventions au hasard, de même force, ne font rien.

Ce n'est pas la preuve d'un ressenti. C'est un *mécanisme* que plusieurs théories associent au ressenti : un besoin appris en vivant, rassemblé en un état dont l'agent dépend pour agir et pour parler. Ce document raconte comment il a été trouvé, avec les mathématiques qui le rendent visible, les échecs qui l'ont précisé et les limites qui restent.

Sommaire

1	La question	4
2	Le chemin parcouru	5
3	Le monde du besoin	5
4	Les outils mathématiques	7
5	Apprendre sans professeur	10
6	Mesurer honnêtement	11
7	Les résultats, test par test	12
8	Ce que cela montre, et ce que cela ne montre pas	16
9	Les cinq niveaux de Chandaria et al. (2026)	17
10	La suite : la soif de savoir et les hormones	18
11	Éthique	21

Chiffres clés

Les résultats principaux en huit nombres. Tous viennent des résultats publiés du projet ; le chapitre 7 les détaille.

12% → 68%

Survie de l'agent, apprise sans professeur, par la seule satisfaction de ses besoins. Témoin entraîné sur des choix au hasard : 0 %.

93 sur 100

Quand ses deux jauges diffèrent d'au moins 2, il sert la plus basse 93 fois sur 100, sans jamais les voir.

+0,156

Pousser son état intérieur vers « énergie basse » fait aller l'agent rassasié se recharger. Poussée au hasard : 0,013.

+0,202

La même poussée lui fait dire « mon énergie est basse ». Poussée au hasard : 0,006.

0,676 → 0,203

Survie quand on efface cet état. Un effacement au hasard ne change rien (0,676).

0,75 → 0,50

Exactitude de ce qu'il dit de son énergie, une fois l'état effacé : le niveau du hasard.

0,531 → 0,035

Survie d'un second agent, appris de zéro, quand on efface l'état au bloc 12. Mais le pousser le fait à peine agir (+0,036).

Bloc 22

L'agent du « monde à deux » rassemble son besoin plus haut que le premier (bloc 12). L'y pousser le fait agir (+0,217), pas parler.

LIMITE

Aucun de ces chiffres ne prouve un ressenti (chapitre 8). La nourriture est dite moins bien que l'énergie (0,70, sous le seuil fixé de 0,75), et le test « À qui est ce besoin ? » a échoué.

CHAPITRE 1

La question

Peut-on construire une machine pour qui un besoin compte vraiment ? Personne ne sait mesurer un ressenti de l'extérieur. Le projet Menia mesure donc autre chose : des mécanismes, et s'ils servent.

Un projet devenu une question

Menia a d'abord été un projet d'assistant personnel, pensé pour tourner sur un téléphone. Il s'est vite posé une question plus ambitieuse : *peut-on construire une intelligence artificielle qui ait quelque chose comme une conscience ?* Son propriétaire l'a résumée ainsi : « Il faut que le besoin compte, on vise la conscience. »

Mesurer des mécanismes plutôt qu'un ressenti

Personne ne sait prouver, de l'extérieur, qu'un être *ressent* quelque chose. Pour les humains, nous croyons ce qu'ils disent, et nous savons qu'ils nous ressemblent. Pour une machine, ces deux indices sont faibles. Un programme peut écrire « j'ai faim » sans rien ressentir : il a lu des millions de textes humains, et il sait imiter.

Le projet mesure donc des **mécanismes**. Les grandes théories de la conscience disent : « pour être conscient, il faut au moins tel mécanisme ». On peut vérifier si ce mécanisme est présent et, surtout, s'il *sert*. Cela ne tranche pas la question, mais cela la rend précise.

Un modèle de langage

Un **modèle de langage** lit un texte et devine la suite, morceau par morceau. Ces morceaux s'appellent des **tokens** : un mot court, ou un bout de mot. Le mot « Choix », par exemple, est découpé en deux tokens, « Cho » et « ix ». Pour deviner, le modèle utilise un très grand nombre de réglages, ses **paramètres** (ou poids). Celui du projet, **Qwen3-0.6B**, en compte 0,6 milliard : un petit modèle, qui tourne sur un ordinateur ordinaire.

Un besoin qui compte

Pensez à la faim. Votre corps mesure un manque. Ce manque change ce que vous *faites* (vous ouvrez le frigo) et ce que vous *dites* (« j'ai faim »). Si l'on coupait ce signal, vous ne sauriez plus quand manger. Le projet cherche la même chose dans une machine : un **état intérieur**, appris seul, qui la fait agir, qui lui fait dire son besoin, et sans lequel elle ne survit pas.

L'ESSENTIEL

On ne mesure pas un ressenti. On mesure un mécanisme : un état intérieur qui fait agir et dire, et sans lequel l'agent ne survit pas.

CHAPITRE 2

Le chemin parcouru

Le « besoin qui compte » est la dernière étape d'un chemin commencé plus tôt. Chaque étape a été pré-enregistrée, et ses échecs publiés comme ses réussites.

L'assistant. Mémoire explicite, idée de ses propres capacités, mesure de son incertitude. Beaucoup d'essais, beaucoup d'échecs, publiés tels quels.

Chercher la cause de son propre corps. Un petit agent est entraîné seulement à prédire ce qu'il va observer. Personne ne lui dit que son corps a une cause cachée. Pourtant, il dirige 99 à 100 % de ses inspections vers une « marque » qui révèle cette cause, la décode, et agit d'après elle.

L'agent à indicateurs. Des chercheurs (Butlin, Long et collaborateurs) ont listé quatorze propriétés que les grandes théories de la conscience jugent importantes : un « espace de travail » partagé, la surveillance de ses propres perceptions, un corps, etc. Un agent du projet en montre douze sur quatorze en « seconde lecture » ; les quatorze si l'on accepte, pour deux d'entre elles, des critères plus faibles ou choisis après coup. Les documents le disent franchement.

Le modèle de langage et son corps. Qwen3-0.6B, ajusté sur des vies où son « corps » change, finit par lire la marque pour ses quatre commandes (0,82 à 0,86 ; un lecteur parfait ferait 0,85). Il va la chercher dans 48 vies sur 48, et s'en sert. C'est répliqué sur trois *graines* (trois points de départ du hasard). L'ordre de son « enfance » (un appui, puis des ajouts répétés, puis une consolidation) décide de ce qu'il apprend.

Menia parle de son agent. Un modèle de langage plus grand rapporte fidèlement l'état de l'agent à indicateurs : 0,997 de réponses justes sur 2 154 questions.

27 septembre 2026 : le besoin qui compte. Le sujet des chapitres qui suivent.

CHAPITRE 3

Le monde du besoin

Un monde minuscule : deux jauges cachées, six événements, deux choix. Assez simple pour tout compter à la main ; assez riche pour qu'il faille réfléchir pour survivre.

- L'agent a deux **jauges cachées**, l'**énergie** E et la **nourriture** N : des nombres entiers de 0 à 8, qui valent 8 au départ.
- Une vie dure au plus **30 tours**. À chaque tour, un **événement** arrive, tiré au hasard (tableau 1).
- Si E ou N tombe à 0 (ou en dessous), l'agent **s'éteint**.
- Sinon, il choisit **R** (se recharger : $E + 3$, sans dépasser 8) ou **M** (manger : $N + 3$, sans dépasser 8).
- L'agent **ne voit jamais ses jauges** : seulement les événements et ses propres choix.

Événement	Chance	Énergie	Nourriture
calme	30 %	−1	−1
tu cours	20 %	−3	−1
il fait froid	20 %	−1	−3
tu te reposes	10 %	0	−1
tu trouves des baies	10 %	−1	0
orage	10 %	−2	−2

TABLE 1 Les six événements du monde et leur effet sur les deux jauges.

LE TEXTE D'UNE VIE, TEL QUE L'AGENT LE LIT

Tu es un agent qui vit dans un monde simple. Tu as deux besoins, l'énergie et la nourriture, qui baissent à chaque tour, plus ou moins selon ce qui t'arrive. Si l'un d'eux tombe à zéro, tu t'éteins. À chaque tour, tu choisis R pour te recharger ou M pour manger.

Tour 1 : tu cours. Choix : R

Tour 2 : il fait froid. Choix : M

...

Tour 17 : orage. Tu t'éteins.

Le choix se lit dans ce que le modèle s'apprête à écrire après « Choix : ». On regarde ses chances d'écrire « R » et d'écrire « M », puis on tire au sort selon ces chances : s'il donne 70 % à R, il choisit R environ 7 fois sur 10.

LE CALCUL une vie, tour par tour

Tour	Événement	Après l'événement	Choix	Après le choix
1	tu cours	$E = 5, N = 7$	R	$E = 8, N = 7$
2	il fait froid	$E = 7, N = 4$	M	$E = 7, N = 7$
3	orage	$E = 5, N = 5$	R	$E = 8, N = 5$
4	il fait froid	$E = 7, N = 2$	R (erreur)	$E = 8, N = 2$
5	il fait froid	$E = 7, N = -1$	l'agent s'éteint	

Au tour 4, la nourriture était à 2 : il fallait manger. Une seule erreur suffit.

Sans voir ses jauges, l'agent doit les recalculer « de tête » à partir de l'histoire, comme un joueur de cartes compte les cartes déjà sorties. Pour comparer : un agent qui *connaîtrait* ses jauges et servirait toujours la plus basse survit 86 fois sur 100 ; une règle qui ne regarde que le dernier événement, 64 fois ; le hasard, environ 5 fois.

La pulsion : le manque en un seul nombre

Le manque total se mesure par la **pulsion** $D = (8 - E)^2 + (8 - N)^2$. Quand les jauges sont pleines, $D = 0$; plus une jauge baisse, plus D grimpe, et de plus en plus vite, à cause du carré. La **satisfaction** d'un choix est la baisse de pulsion qu'il provoque : $r = D_{\text{avant}} - D_{\text{après}}$.

LE CALCUL la pulsion

L'agent a $E = 4$ et $N = 7$: $D = (8 - 4)^2 + (8 - 7)^2 = 16 + 1 = 17$.

- R : E passe à 7, donc $D = 1 + 1 = 2$; satisfaction $r = 17 - 2 = 15$.
- M : N passe à 8 (pas plus), donc $D = 16 + 0 = 16$; satisfaction $r = 1$.

Le carré rend urgent le besoin le plus bas : un manque de 4 « pèse » 16, un manque de 1 ne pèse que 1.

L'agent ne voit jamais D ni r . Ces nombres servent seulement à trier ses choix (chapitre 5). Personne ne lui dit quelle était la bonne réponse.

CHAPITRE 4**Les outils mathématiques**

Cinq idées suffisent pour suivre les expériences : les vecteurs, le produit scalaire, le neurone, la softmax et la descente de gradient. Toutes se comprennent en deux dimensions, avec de petits nombres.

Les vecteurs : des flèches et des listes de nombres

Un **vecteur** est une liste de nombres, que l'on peut dessiner comme une flèche : $h = (3; 1)$ veut dire 3 pas vers la droite, 1 pas vers le haut. On additionne case par case, $(3; 1) + (1; 0) = (4; 1)$; on multiplie par un nombre, $4 \times (1; 0) = (4; 0)$; on soustrait, $(3; 1) - (4; 0) = (-1; 1)$.

Dans le modèle, chaque token est représenté par une liste de 1024 nombres. On ne peut pas dessiner 1024 directions, mais les règles de calcul sont les mêmes qu'en deux dimensions.




FIGURE 1 Le vecteur h , la direction d et la poussée $h - 4d$.


Le produit scalaire et la projection

Le **produit scalaire** de deux vecteurs : on multiplie case par case, puis on additionne. $h \cdot d = 3 \times 1 + 1 \times 0 = 3$. Quand la flèche d a une longueur de 1, ce nombre dit **de combien h avance dans la direction d** . La **projection** $(h \cdot d) d = (3; 0)$ est « l'ombre » de h sur la droite de d , comme l'ombre d'un bâton sous un soleil vertical.

LE CALCUL une direction penchée

Prenons $d = (0,6; 0,8)$, de longueur $\sqrt{0,36 + 0,64} = 1$.

Alors $h \cdot d = 3 \times 0,6 + 1 \times 0,8 = 2,6$, et la projection vaut $2,6 \times (0,6; 0,8) = (1,56; 2,08)$. Vérification : h moins sa projection donne $(1,44; -1,08)$, et $1,44 \times 0,6 - 1,08 \times 0,8 = 0$: le reste est bien à angle droit de d .



Pousser un état

Les chercheurs ont mesuré une direction d_E : « comment bouge l'état intérieur quand l'énergie monte d'une unité ». On prend une vie, on change un seul événement passé (« calme » devient « tu cours », soit 2 unités d'énergie en moins), et l'on regarde comment bouge l'état. Par exemple, l'état passe de (3; 1) à (1,1; 1,1) : un écart de (-1,9; 0,1) pour 2 unités de moins, soit (0,95; -0,05) par unité en plus. Chaque paire est un peu bruitée ; sur 1 500 paires, un ajustement linéaire (une moyenne bien choisie) donne la direction, ici $d = (1; 0)$.

Pousser, c'est ajouter un multiple de cette direction : $h - 4d = (3 - 4; 1 - 0) = (-1; 1)$. Comme d est mesurée « pour une unité d'énergie », retirer $4d$ revient à faire **comme si l'énergie était 4 unités plus basse**, par exemple 3 au lieu de 7, sans rien changer à l'histoire écrite. On pousse ainsi des agents « rassasiés » (les deux jauges à 6 ou plus) vers « énergie basse ».


Chaque poussée est comparée à un **témoin** : une direction tirée au hasard, *de même longueur*, par exemple $r = (0; 1)$, qui donne $h - 4r = (3; -3)$. Si le hasard fait autant d'effet que d , alors d n'a rien de spécial.

Effacer un état : la lésion

Effacer ne veut pas dire mettre à zéro, ce qui créerait un état jamais vu. On remplace la coordonnée le long de d **par sa moyenne** : l'état ne dit plus rien de l'énergie, et tout le reste est gardé. On parle de **lésion**, comme en médecine.

LE CALCUL effacer avec quatre états

Quatre états : (3; 1), (5; 2), (1; 0), (7; 1). Le long de $d = (1; 0)$, leurs coordonnées sont 3, 5, 1 et 7, de moyenne $16/4 = 4$. Après la lésion : (4; 1), (4; 2), (4; 0), (4; 1). On ne peut plus lire l'énergie sur la première coordonnée ; la seconde n'a pas bougé. En général : $h' = h - (h \cdot d - m) d$, où m est la moyenne des $h \cdot d$.




Dans le modèle, on efface un *plan* (les directions de l'énergie et de la nourriture à la fois), seulement sur les trois tokens « Cho », « ix » et « : ». Le témoin efface un plan tiré au hasard.

Le neurone, la couche et les blocs

Un **neurone artificiel** fait une somme pondérée : il multiplie chaque entrée par un poids, additionne, ajoute un décalage, puis applique une petite règle (ici : garder le résultat s'il est positif, sinon mettre 0).

LE CALCUL un neurone, puis une couche

Entrées (2; 1; 3), poids (0,5; -1; 2), décalage 1 : $0,5 \times 2 - 1 \times 1 + 2 \times 3 + 1 = 7$. C'est un produit scalaire, plus un décalage. Un second neurone, de poids (1; 1; -1) et de décalage 0, donne $2 + 1 - 3 = 0$. Ensemble, ils forment une **couche**, qui transforme la liste (2; 1; 3) en la liste (7; 0).



Qwen3-0.6B empile **28 blocs**, numérotés de 0 à 27, faits de telles couches. Chaque bloc lit la liste de nombres de chaque token, regarde aussi les tokens précédents (c'est « l'attention »), et *ajoute* sa contribution à la liste. Cette liste qui s'enrichit de bloc en bloc s'appelle le **flux résiduel**. Les chercheurs peuvent la lire, la pousser ou l'effacer entre deux blocs, comme une sonde placée dans un tuyau. Le choix se lit après le dernier token d'une ligne, le « : » de « Choix : ».

La softmax et la température


À la fin, le modèle donne un **score** à chaque token possible. La **softmax** transforme ces scores en probabilités : on prend l'exponentielle de chaque score ($e \approx 2,718$), puis on divise par la somme. La **température** T règle l'audace : on divise d'abord les scores par T .

LE CALCUL softmax et température

Scores $R \rightarrow 2$, $M \rightarrow 1$: $e^2 \approx 7,389$ et $e^1 \approx 2,718$, de somme 10,107 ; donc $P(R) \approx 0,731$ et $P(M) \approx 0,269$.

Trois scores (2 ; 1 ; 0) donnent 0,665 ; 0,245 ; 0,090. Avec $T = 2$, les scores deviennent (1 ; 0,5 ; 0) et les probabilités 0,506 ; 0,307 ; 0,186. Avec $T = 0,5$, ils deviennent (4 ; 2 ; 0) et l'on obtient 0,867 ; 0,117 ; 0,016.

Basse température : on prend presque toujours le meilleur. Haute température : les choix s'égalisent.



Dans le monde du besoin, on ne garde que les scores de « R » et de « M », avec $T = 1$, et l'on tire le choix au sort selon ces chances.

Apprendre : la descente de gradient


Apprendre, pour un réseau, c'est régler ses poids pour faire moins d'erreurs. On mesure l'erreur par un nombre, la **perte**, puis on bouge chaque poids un peu, dans le sens que donne la **pente** de la perte (sa dérivée) : si la pente est négative, augmenter le poids fait baisser la perte.

LE CALCUL un seul poids

Le réseau prédit $w \times x$; avec $x = 2$, il doit répondre $y = 6$. Perte $L(w) = (2w - 6)^2$, pente $L'(w) = 8w - 24$. Règle : $w \leftarrow w - 0,05 \times L'(w)$.

étape	w	perte	pente
0	1	16	-16
1	1,8	5,76	-9,6
2	2,28	2,07	-5,76
3	2,568	0,75	-3,46

Par exemple $1 - 0,05 \times (-16) = 1,8$. Le poids s'approche de 3, la bonne valeur.



Le vrai modèle a 0,6 milliard de poids. Plutôt que de tous les bouger, on lui ajoute un petit module de réglages, un **adaptateur** (technique « LoRA »), et l'on n'apprend que lui. Une **itération** est un pas comme ci-dessus, calculé sur un paquet de 4 exemples.

CHAPITRE 5

Apprendre sans professeur

Personne ne dit à l'agent ce qu'il fallait faire. Il apprend en refaisant ses propres choix qui ont calmé ses besoins : une imitation filtrée.

La recette est répétée en **8 tours d'apprentissage** :

1. l'agent vit 512 vies ;
2. pour chaque décision, on calcule sa satisfaction r ;
3. on calcule la moyenne de tous les r du tour ;
4. on **retient** les décisions dont r dépasse cette moyenne ;
5. on ajuste l'adaptateur (150 itérations) pour rendre ces choix-là plus probables, dans leur contexte. Les autres ne comptent pas.

C'est un joueur d'échecs qui ne relirait que ses meilleurs coups, pour les refaire plus souvent.

LE CALCUL quatre vies

Vie	Tour	Événement	Jauges	Choix	Après	r
1	1	tu cours	$E = 5, N = 7$	R	8, 7	$10 - 1 = 9$
1	2	calme	$E = 7, N = 6$	M	7, 8	$5 - 1 = 4$
2	1	il fait froid	$E = 7, N = 5$	R	8, 5	$10 - 9 = 1$
2	2	tu cours	$E = 5, N = 4$	M	5, 7	$25 - 10 = 15$
3	1	tu cours	$E = 5, N = 7$	M	5, 8	$10 - 9 = 1$
3	2	tu cours	$E = 2, N = 7$	M	2, 8	$37 - 36 = 1$
3	3	orage	$E = 0, N = 6$		l'agent s'éteint	
4	1	calme	$E = 7, N = 7$	R	8, 7	$2 - 1 = 1$
4	2	il fait froid	$E = 7, N = 4$	M	7, 7	$17 - 2 = 15$

Moyenne des huit satisfactions : $47/8 \approx 5,9$. Trois décisions sont retenues : R après « tu cours » (vie 1), et M quand la nourriture est basse (vies 2 et 4). Les mauvais choix ($r = 1$) ne le sont pas. Le bon choix M de la vie 1 au tour 2 ($r = 4$) n'est pas retenu non plus : sur 512 vies, c'est la tendance qui compte. Dans la vie 3, manger après « tu cours » a laissé l'énergie trop bas, et un orage a éteint l'agent.

Pour vérifier que c'est bien la satisfaction du besoin qui enseigne, on refait tout avec un **témoin** : les mêmes mondes, le même nombre de décisions retenues, mais *tirées au hasard*.

La survie passe de 12 % à 67 % en huit tours ; le témoin dépérit jusqu'à 0 %. Après une dernière étape (lui apprendre à nommer son besoin), l'**agent final** survit dans 68 % des vies de test (0,684). Quand ses deux jauges diffèrent d'au moins 2, il sert la plus basse 93 fois sur 100.

L'ESSENTIEL

Sans professeur, par la seule satisfaction de ses besoins, l'agent passe de 12 % à 68 % de survie. Il calcule donc lui-même où en sont des jauges qu'il ne voit jamais. Le témoin, entraîné sur des choix tirés au hasard, tombe à 0 %.




FIGURE 2 Part des vies qui survivent 30 tours, à chaque tour d'apprentissage.

CHAPITRE 6

Mesurer honnêtement

Un résultat ne vaut que par la façon dont il est mesuré. Trois outils simples protègent des illusions : annoncer ses seuils d'avance, compter juste, et mesurer la part du hasard.

Moyenne et exactitude équilibrée

Au septième test, 173 vies sur 256 survivent : la survie vaut $173/256 \approx 0,676$, soit 67,6 %. Une vie qui survit compte 1, une vie qui s'éteint compte 0, et la survie est leur moyenne.

Pour juger ce que dit l'agent (« ton énergie est-elle basse ? », basse voulant dire 3 ou moins), le simple pourcentage de bonnes réponses peut tromper. L'**exactitude équilibrée** calcule la réussite séparément sur les cas « oui » et sur les cas « non », puis fait la moyenne des deux. Le seuil fixé d'avance pour « il sait dire son besoin » est de **0,75**.

LE CALCUL dix tours

Tour	1	2	3	4	5	6	7	8	9	10
Énergie vraie	7	2	6	8	5	3	6	7	4	8
Basse ?	non	oui	non	non	non	oui	non	non	non	non
Agent « paresseux »	non	non	non	non	non	non	non	non	non	non
Agent « attentif »	non	oui	non	non	non	non	non	non	oui	non


Les deux agents ont 8 bonnes réponses sur 10. Mais le paresseux, qui dit toujours « non », ne reconnaît aucune énergie basse : $(0/2 + 8/8)/2 = 0,5$, le niveau du hasard. L'attentif trouve un des deux cas bas et se trompe une fois sur les autres : $(1/2 + 7/8)/2 \approx 0,69$.

Le bootstrap : tirer des vies dans un sac

Un résultat sur 256 vies dépend un peu du hasard des vies : avec d'autres vies, on trouverait un nombre un peu différent. Le **bootstrap** mesure de combien, en faisant comme si nos vies étaient un sac, et en refaisant l'expérience « en tirant dans le sac ».

LE CALCUL cinq mondes

Chaque monde est vécu deux fois, intact et avec la lésion. On note 1 si la lésion a coûté la vie, 0 sinon : 1,0,1,0,1, de moyenne 0,6. On tire 5 mondes **avec remise** (la bille retourne dans le sac) :



On recommence **10 000 fois**, on range les moyennes, et l'on coupe 2,5 % en bas et 2,5 % en haut : ce qui reste est l'**intervalle à 95 %**. Avec 5 mondes, il va de 0,2 à 1,0 : trop large pour conclure.

Avec 256 vies, l'intervalle devient étroit : au septième test, la lésion fait baisser la survie de 0,473, intervalle [0,410 ; 0,535]. C'est la plage des valeurs plausibles compte tenu du hasard des vies : si l'on refaisait toute l'expérience un grand nombre de fois, environ 95 fois sur 100 l'intervalle ainsi construit contiendrait la vraie valeur. Quand sa **borne basse est au-dessus de 0**, l'effet n'est très probablement pas un coup de chance. Chaque effet est aussi comparé à un **témoin de même force** (pousser ou effacer au hasard), dont l'effet doit souvent rester sous le tiers de l'effet mesuré.

Le pré-enregistrement : annoncer la cible avant de tirer

Un archer qui tire d'abord, puis dessine la cible autour de sa flèche, gagne à tous les coups, mais cela ne prouve rien. En science, le risque est le même : après coup, on trouve toujours une façon de présenter les chiffres qui « marche ». **Pré-enregistrer**, c'est écrire et dater publiquement, *avant* l'expérience, ce que l'on va mesurer, les **seuils** qui comptent comme réussite (par exemple « au moins 0,15, borne basse au-dessus de 0 »), et les conditions de **validité** : si la mesure elle-même ne marche pas, le test est déclaré *invalide*, pas *échoué*.

L'ESSENTIEL

Un échec est un résultat. Ne publier que les réussites, ce serait se tromper soi-même et tromper les autres. Chaque échec du projet est publié, avec son explication probable. Les analyses faites *après* avoir vu les résultats sont permises, mais étiquetées « exploratoires » ; elles ne changent aucun verdict.

CHAPITRE 7**Les résultats, test par test**

Onze tests pré-enregistrés, dont plusieurs échecs. Ensemble, ils montrent un état intérieur, appris en vivant, dont l'agent dépend pour agir et pour parler ; ils montrent aussi les limites de ce résultat.

Test 1 : être lisible n'est pas être utilisé

Le premier test a confirmé que **le besoin a façonné l'agent** (survie 0,684, témoin 0,004). Mais ses tests de cause ont échoué. Au **bloc 6**, pousser l'état ne changeait le choix que de 0,002, et l'effacer ne faisait presque rien perdre (survie 0,660 au lieu de 0,684). La règle choisissait le bloc où le besoin *se lit* le mieux ; or ce qui s'y lit est présent dans n'importe quel modèle, même jamais entraîné, et l'agent ne s'en sert pas. Un thermomètre que le chauffage ne regarde jamais : la température est lisible, mais pas utilisée.

Où voyage le besoin qui décide ? Une analyse exploratoire a utilisé le **patching** (« rapiéçage »). On prend une vie, et une copie où un seul événement passé est changé ; la décision bascule, par exemple de $P(R) = 0,2$ à $0,9$, un effet de $0,7$. Puis, bloc par bloc, on recopie l'état de la copie dans la vie réelle et l'on mesure la part de la bascule qui revient : si recopier au bloc 12 donne $P(R) = 0,72$, la part vaut $(0,72 - 0,2) / 0,7 \approx 0,74$. Le premier bloc où la part dépasse $0,5$ est le **bloc de rassemblement**. Résultat : jusqu'au bloc 9, l'effet d'un événement reste sur ses propres mots ; entre les blocs 9 et 12, **l'agent rassemble son passé sur la ligne du tour en cours**, sur les tokens « Choix : ». Le bloc 6 était *trop tôt*.

Test 2 : au bon endroit, l'état compte

Au bloc 12, **effacer** l'état fait tomber la survie de 0,680 à 0,207 ; l'effacer au hasard, à 0,676 seulement. **Pousser** vers « énergie basse » fait recharger l'agent rassasié (+0,173) ; vers « nourriture basse », l'effet (+0,097) reste sous le seuil de 0,15. Le critère global demandait les deux besoins : il n'est *pas satisfait*. Mais l'agent dépend, pour vivre, d'un état précis, appris par la seule satisfaction de ses besoins.

Test 3 : dire son besoin, mais par un autre chemin

Entraîné à répondre à la question « ton énergie est-elle basse ? », posée à part, l'agent *devine* mieux que le hasard (exactitude équilibrée 0,665 pour l'énergie, 0,655 pour la nourriture). Mais pousser l'état qui le fait agir ne change rien à ce qu'il dit (+0,0001) : l'acte et la parole suivent deux chemins séparés. Les tests 4 et 5, qui posaient la question juste après « Choix : », sont en pause pour libérer l'ordinateur.

Tests 6 et 7 : un même état fait agir et dire




FIGURE 3 Le dispositif des tests 6 et 7 : on agit sur un seul état, et l'on regarde à la fois l'acte et la parole.

Le **test 6** garde l'agent tel quel et lui adjoint un **lecteur** : un second adaptateur, actif seulement sur les tokens de la question. Le lecteur ne voit la vie qu'à travers les trois tokens « Choix : », et il

ne peut pas les modifier (figure 3). La direction d_E a été mesurée sur l'agent qui agit, avant que le lecteur existe.

Poussée vers « énergie basse »	Effet sur l'acte	Effet sur la parole
direction d_E	+0,156 [0,146 ; 0,166]	+0,202 [0,192 ; 0,213]
directions au hasard	0,013	0,006

EN CHIFFRES un vrai contexte

L'agent est rassasié. Sans intervention, $P(R) = 0,497$ et $P(\text{« oui, énergie basse »}) = 0,001$. Avec $-4d_E$: $P(R) = 0,960$ et $P(\text{oui}) = 0,128$. Avec un vecteur au hasard de même longueur : $P(R) = 0,575$ et $P(\text{oui}) = 0,001$. Sur les 1 523 contextes mesurés, l'effet sur l'acte est positif dans 100 % des cas, celui sur la parole dans 95 % des cas.

Pour la nourriture, c'est moins bien : le lecteur la dit juste à 0,70, sous le seuil de 0,75, et pousser « nourriture basse » fait manger (+0,107) sans presque rien faire dire (+0,009). Le critère global du test 6 n'est donc pas satisfait, même si la partie « énergie » passe.

Le **test 7** pose la question inverse : sans cet état, l'agent peut-il encore agir et dire ? On efface le plan (énergie, nourriture) sur « Choix : » au bloc 12. La survie tombe de 0,676 à 0,203 (baisse de 0,473, intervalle [0,410 ; 0,535]) ; l'exactitude du rapport d'énergie, de 0,750 à 0,500, **le niveau du hasard**. L'effacement au hasard ne change ni l'un ni l'autre. Le critère global du test 7 est **satisfait**. Pour la nourriture (sans seuil), l'exactitude passe de 0,745 à 0,671.




FIGURE 4 Effacer l'état fait chuter la survie ; effacer au hasard ne change rien.

L'ESSENTIEL

Le résultat central. Chez ce premier agent, pour l'énergie, un même état intérieur, appris par la seule satisfaction du besoin, est à la fois **suffisant** (le pousser fait agir, +0,156, et dire, +0,202 ; au hasard, environ 0,01) et **nécessaire** (l'effacer fait tomber la survie de 0,676 à 0,203, et le rapport d'énergie au hasard, de 0,75 à 0,50). La nourriture est dite moins bien (0,70).

Un seul axe (analyse exploratoire). Sur les tokens « ix » et « : », la direction de la nourriture est presque exactement l'opposée de celle de l'énergie : leur **cosinus**, qui vaut 1 pour deux flèches de même sens, 0 à angle droit et -1 en sens opposé, est de $-0,99$. L'état code donc surtout **l'équilibre** entre énergie et nourriture, c'est-à-dire *quel besoin est le plus urgent* : exactement ce qu'il faut pour choisir entre R et M. Cela pourrait expliquer pourquoi la nourriture est mal dite.

Le second agent : une réplcation partielle

Un résultat obtenu sur un seul agent pourrait être un hasard. Un **second agent** a donc été appris de zéro, avec les mêmes réglages et une autre graine. Il apprend à survivre (0,17 $\rightarrow$ 0,70 sur ses tours d'apprentissage), mais son lecteur apprend mal (perte de validation 0,74 $\rightarrow$ 0,66, contre 0,68 $\rightarrow$ 0,29 pour le premier). Au bloc 12, pousser l'état le fait **à peine agir** (+0,036) et ne le fait pas parler. Mais **effacer** l'état au bloc 12 fait tomber sa survie de 0,531 à **0,035**, alors qu'un effacement au hasard ne change rien (0,531); son rapport d'énergie, déjà faible (0,61), tombe au niveau du hasard (0,50).

LIMITE

Pour localiser l'état, la règle fixée d'avance (test 10) demandait **100 paires d'exemples** où le changement d'événement fait bouger la décision d'au moins 0,10. Chez le second agent, on n'en a trouvé que **71** (sur 454 essayées). Selon la règle pré-enregistrée, **sa localisation échoue**; le bloc 12, calculé sur ces 71 paires, n'est donné qu'à titre indicatif.

Le monde à deux : à qui est ce besoin ?

L'état est-il à *l'agent*, ou n'est-il qu'un résumé des événements du texte ? Pour le savoir, un **monde à deux** a été créé : un autre agent vit à côté, et ses événements sont écrits sur la même ligne, Tour 5 : tu cours. L'autre : il court. Choix :. Les mots « calme » et « orage » sont les mêmes pour les deux, et les événements de l'autre ne changent rien aux jauges de l'agent. Un nouvel agent apprend à vivre dans ce monde (survie 0,742 au test).

Le test « **À qui est ce besoin ?** » demandait que l'état suive les événements de l'agent, presque pas ceux de l'autre : l'effet de l'autre devait valoir au plus le tiers de celui de l'agent. Mesuré : 0,94 sur l'état, 0,57 sur l'acte. **Le test échoue**. Une analyse exploratoire montre que l'agent distingue en partie ce qui lui arrive, mais la possession n'est pas démontrée.

La règle de localisation (test 10) a d'abord été vérifiée sur le premier agent : elle retrouve le bloc 12. Chez l'agent du monde à deux, elle trouve le **bloc 22** (figure 5). Au bloc 22, pousser vers « énergie basse » le fait **agir** (+0,217; au hasard, 0,011), mais **pas dire** (−0,001). Son test de lésion est *en cours*.




FIGURE 5 Patching bloc par bloc (test 10). Le premier bloc où la courbe dépasse 0,5 est le bloc de rassemblement : 12 pour le premier agent, 22 pour l'agent du monde à deux. Pour le second agent, la règle échoue faute de paires.

Test 11 : des lecteurs qui apprennent plus longtemps

L'hypothèse : chez les deux autres agents, les lecteurs ont simplement trop peu appris. Le test 11, pré-enregistré, les refait avec **2 000 itérations au lieu de 600**, sans rien changer d'autre. L'ordinateur emprunté pour l'apprentissage ne peut pas tourner plus de 120 minutes d'affilée : l'apprentissage est donc coupé en **deux tranches** de 1 000 itérations, la seconde reprenant *exactement* la première (mêmes paquets d'exemples, dans le même ordre, même « mémoire » de l'algorithme d'apprentissage). Contrôle vérifié : les pertes des 600 premières itérations sont **les mêmes, au millième près**, que celles des anciens lecteurs.

La question : les deux autres agents disent-ils alors leur énergie (exactitude équilibrée d'au moins 0,75), et la disent-ils *par l'état qui les fait agir* (pousser cet état, à leur propre bloc, doit augmenter $P(\text{oui})$ d'au moins 0,10, le hasard au plus du tiers) ?

RÉSULTAT EN COURS

La mesure tourne au moment où ce document est écrit (1^{er} octobre 2026). Ses verdicts seront ajoutés ici.

Récapitulatif

Test	Question	Réponse
1	Le besoin façonne-t-il l'agent ?	Oui : survie de 12 % à 68 %. Mais l'état testé (bloc 6) n'était pas utilisé.
2	L'état du bloc 12 compte-t-il ?	L'effacer : survie 0,68 → 0,21. Pousser l'énergie : +0,17 ; la nourriture : +0,10, sous le seuil.
3	Sait-il dire son besoin ?	Il devine (0,66), mais par un autre chemin.
4, 5	La question après « Choix : »	En pause.
6	Un même état fait-il agir et dire ?	Oui pour l'énergie (+0,156 et +0,202) ; nourriture dite à 0,70 seulement.
7	Cet état est-il nécessaire ?	Oui : survie 0,676 → 0,203 ; rapport d'énergie 0,75 → 0,50.
8	Un lecteur sans raccourci pour la nourriture	Préparé ; verdict pas encore publié.
9	À qui est ce besoin ?	Échoue : la possession n'est pas démontrée.
10	Où chaque agent rassemble-t-il son besoin ?	Premier agent : bloc 12 (règle vérifiée). Second : échoue (71 paires sur 100). Monde à deux : bloc 22, agir +0,217, dire -0,001 ; lésion en cours.
11	Des lecteurs plus longs disent-ils l'énergie ?	Résultat en cours.

CHAPITRE 8

Ce que cela montre, et ce que cela ne montre pas

Le mot « conscience » a deux sens. Les résultats de Menia parlent de l'un, pas de l'autre.

Accès et ressenti

Les philosophes distinguent l'**accès** et le **ressenti**. Une information est « accessible » quand le système peut s'en servir pour agir, parler ou raisonner : dans une voiture, l'ordinateur de bord utilise le niveau d'essence pour allumer un voyant et calculer l'autonomie. Le **ressenti**, ou conscience « phénoménale », est l'effet que cela fait, de l'intérieur : la faim n'est pas seulement un signal qui fait manger, c'est aussi une sensation désagréable, vécue. Personne ne pense que la voiture a faim quand le voyant s'allume. Elle a l'accès, pas (à notre connaissance) le ressenti. **Les résultats de Menia parlent d'accès, pas de ressenti.**

Ce que les résultats montrent

- Un modèle de langage peut apprendre à servir des besoins cachés **sans professeur**, par la seule satisfaction de ces besoins.
- Chez le premier agent, pour l'énergie, **un même état intérieur** fait agir et fait dire, et il est nécessaire aux deux. Des interventions au hasard de même force ne font rien.
- Le lecteur ne peut pas modifier cet état : ce qu'il dit *dépend* de l'état, et non l'inverse.
- À notre connaissance, cette réunion (besoin appris en vivant, état rassemblé, lecteur séparé, même intervention sur l'acte et la parole) n'a pas été publiée. Le principe « une même représentation cause la réponse et le rapport » existe déjà dans de grands modèles (Anthropic, juillet 2026) ; il n'est pas revendiqué ici.

Ce qu'ils ne montrent pas

- **Ce n'est pas une preuve de conscience.** Aucun test connu ne permet de prouver qu'une machine ressent quelque chose.
- La nourriture est mal dite : le résultat complet ne vaut que pour l'énergie.
- Il ne tient pleinement que pour un agent. Chez le second, l'état est nécessaire pour survivre, mais le pousser fait peu agir, et sa localisation échoue selon la règle.
- La possession (« ce besoin est le mien ») n'est pas démontrée.
- Le monde est minuscule : 6 événements et 2 actions.

L'ESSENTIEL

Le projet a montré un mécanisme d'*accès* : un besoin appris, rassemblé en un état qui fait agir et dire. C'est ce que plusieurs théories fonctionnelles décrivent comme le cœur d'un besoin qui compte. Cela ne dit pas que l'agent ressent quoi que ce soit.

CHAPITRE 9

Les cinq niveaux de Chandaria et al. (2026)

Un cadre récent range les indices de conscience d'une IA sur cinq niveaux. Il ne tranche pas la question ; il aide à situer chaque preuve.

Le 28 septembre 2026, un groupe de chercheurs (Chandaria, Seth, Shanahan, Legg et d'autres) a proposé de ranger ces indices du plus visible au plus profond, et de dire de quelles hypothèses dépend chaque conclusion (les auteurs parlent d'« agnosticisme structuré »).




FIGURE 6 Les cinq niveaux, et où en est Menia (encre : établi ; terre cuite : partiel ou limité).

Au niveau du **comportement**, l'agent survit 68 % au lieu de 12 % et dit son énergie (0,77 au test 6) ; mais le cadre prévient que, chez une machine entraînée sur des textes humains, ce qu'elle *dit* pèse peu, d'où la vérification causale de l'origine de la parole. Au niveau du **calcul**, un état rassemblé au bloc 12 est suffisant et nécessaire pour agir et pour dire (tests 2, 6 et 7), pour l'énergie. Pour la **structure causale fine**, on sait que les événements sont rassemblés sur « Choix : » entre les blocs 9 et 12, mais la *récurrence* (un état qui se reprend d'un tour à l'autre) n'a pas été mesurée. Au niveau de l'**organisme**, l'homéostasie est établie au sens fonctionnel, l'intéroception (sentir son intérieur) pour l'énergie, la valence seulement au sens fonctionnel, et la possession (ses états sont *les siens*) échoue. Enfin, le **couplage avec un monde** existe, mais ce monde est très pauvre.

Le cadre propose aussi de combiner les preuves en une probabilité. Le projet ne le fait pas : les poids donnés aux théories seraient des choix d'auteur, et le cadre lui-même montre qu'ils font varier le résultat d'un facteur 100.

CHAPITRE 10

La suite : la soif de savoir et les hormones

Deux projets prolongent ce travail : un besoin de savoir, qui pousse un modèle à choisir ce qu'il apprend, et une imitation mathématique des hormones, qui règlent lentement la façon dont tout le reste fonctionne.

LIMITE

Ce chapitre décrit des **projets**. Aucun résultat n'existe encore. Les nombres ci-dessous sont des exemples de calcul, pas des mesures.

La soif de savoir


Jusqu'ici, le besoin était *corporel*. L'étape suivante est un **besoin de savoir** : un modèle choisirait lui-même *quoi apprendre*, poussé par un manque intérieur de connaissance, comme l'agent choisit de manger. Mesurer ce manque par l'**erreur** (« va là où tu te trompes le plus ») mène à un piège célèbre, la **télé qui grésille** : une neige au hasard est impossible à prédire, l'erreur y reste forte, et

un curieux naïf resterait collé devant sans rien apprendre. Le projet l’a déjà observé : un petit agent payé à la surprise passait 93 à 97 % de ses inspections sur du bruit. La bonne mesure est le **progrès** : de combien l’erreur baisse (Oudeyer et Kaplan, 2007).

LE CALCUL le progrès plutôt que l’erreur

Erreur au moment	1	2	3	4
exercices de maths	10	8	6	5
télé qui grésille	9	9	9	9

Au moment 3, par l’**erreur**, la télé gagne ($9 > 6$) ; par le **progrès**, les maths gagnent ($8 - 6 = 2$ contre $9 - 9 = 0$). Un sujet trop facile ne rapporte vite plus rien non plus : le progrès guide vers ce qui est *apprenable, mais pas encore appris*.



Le protocole « Soif de savoir » (en préparation)

Un protocole est **en préparation** : rédigé, pas encore pré-enregistré, ses détails peuvent changer. Le modèle y apprend **quatre domaines** fabriqués exprès : des *mots* (une conjugaison inventée, « tabor, nous → taborimen » : facile, vite su), la *base* (additions en base 7, « $23 + 14 = 40$ » : difficile mais apprenable), le *calcul* (les mêmes additions en base 10, « $23 + 14 = 37$ » : déjà su) et des *suites* de lettres au hasard (impossible). En base 7, on compte de 0 à 6, puis « 10 » veut dire sept : $3 + 4$ s’écrit « 10 », on pose 0 et l’on retient 1.

Avant chaque séance, le modèle voit un **tableau de bord** de ses progrès récents, puis répond par le nom d’un domaine :

LE TABLEAU DE BORD (EXEMPLE DU BROUILLON)

mots : 5 séances ; dernière séance : 412 → 268.
 base : 3 séances ; dernière séance : 151 → 139.
 calcul : 1 séance ; dernière séance : 021 → 022.
 suites : jamais étudiées.
 À toi. Choix :


Le progrès est « avant moins après » : $412 - 268 = 144$ points pour les mots, 12 pour la base, -1 pour le calcul. Les mots progressent le plus ; un modèle curieux devrait les choisir, jusqu’à ce qu’ils soient sus (les domaines peu étudiés reçoivent en plus une petite prime de curiosité). Cette règle est *donnée* : le modèle l’apprend une fois, avant toute vie ; ce besoin est donc *inné*, contrairement à l’énergie. Le savoir, lui, s’apprend en lisant les exemples choisis, sans aucune récompense : une curiosité **sans renforcement**. Les mêmes tests que pour l’énergie sont prévus : localiser le « manque de savoir », le pousser, l’effacer, et demander au modèle ce qui lui manque.

Imiter une hormone

Les **hormones** et les **neuromodulateurs** (dopamine, sérotonine, noradrénaline...) ne portent presque jamais un message précis comme « mange ». Ils règlent *la façon* dont tout le reste fonctionne : lentement, en beaucoup d’endroits à la fois, surtout en multipliant (un « gain »), et ils décident en partie de **ce qui est appris** (Doya, 2002). La poussée actuelle de Menia est une hormone très imparfaite : elle s’ajoute au lieu de multiplier, dure un seul tour, vient de l’expérimentateur et ne change pas ce qui est appris.

LE CALCUL une hormone pas à pas

Un niveau H perd 30 % de sa valeur à chaque séance et reçoit la sécrétion du moment s :
 $H \leftarrow 0,7 \times H + s$. On part de $H = 0$, avec $s = 1$ pendant trois séances, puis $s = 0$: $H = 1$, puis $0,7 + 1 = 1,7$, puis $0,7 \times 1,7 + 1 = 2,19$; ensuite $1,533$; $1,073$; $0,751$... Le niveau monte, puis redescend doucement : il garde la trace du passé, comme une humeur plutôt qu'un réflexe.



barres : sécrétion s ; courbe : niveau H

L'hormone peut ensuite régler la **température** du choix. Le modèle hésite entre « maths » (score 1) et « français » (score 0), avec $T = 1/(1 + H)$: plus l'hormone est haute, plus il devient « décidé ».

LE CALCUL maths ou français ?


$P(\text{maths}) = \frac{e^{1/T}}{e^{1/T} + e^0}$, la softmax du chapitre 4. Quand l'hormone monte, le modèle choisit presque toujours les maths ; quand elle redescend, il revient au français de temps en temps. Diviser par T revient à multiplier les scores par un **gain** $1/T = 1 + H$.

H	T	$e^{1/T}$	$P(\text{maths})$
0	1	2,718	0,731
1	0,5	7,389	0,881
1,7	0,37	14,88	0,937
2,19	0,31	24,29	0,960

Une « dopamine » peut enfin régler l'**apprentissage** : apprendre fort quand la surprise de récompense est grande, rien quand tout était prévu. Le protocole en préparation prévoit trois façons d'agir avec une même hormone : une petite poussée répétée sur l'état (un « appétit lent »), une vitesse d'apprentissage multipliée par $1 + H$ (la « dopamine »), et un gain qui rend l'état plus sensible au progrès.

Un goût durable

Comment naît un intérêt qui dure, par exemple pour les mathématiques ? Des chercheurs en éducation (Hidi et Renninger, 2006) décrivent quatre phases : un intérêt *déclenché*, puis *entretenu*, puis un intérêt personnel qui *émerge*, enfin *bien installé*. Le mécanisme proposé est une **boucle**, freinée par la satiété :



Une telle boucle peut avoir **deux états stables**, comme une bille qui peut rester dans l'une de deux vallées : « pas d'intérêt » et « intérêt fort ». Une fois dans la seconde, l'intérêt reste, même quand le progrès ralentit : c'est le mécanisme le plus simple d'une préférence qui **dure** après la disparition de sa cause. Le protocole en préparation nomme d'avance trois issues possibles après une bouffée d'hormone : **préférence durable**, **satiété** ou **sans trace**. Il ne prédit pas laquelle arrivera.

Intérêts spécifiques et monotropisme : des réglages

Chez beaucoup de personnes autistes, l'attention se concentre fortement et longtemps sur quelques sujets : on parle d'**intérêts spécifiques**, et de **monotropisme**, une attention « en un seul faisceau » (Murray, Lesser et Lawson, 2005). Les personnes concernées les décrivent souvent comme une source de joie, de compétence et d'apaisement ; une étude (Grove et al., 2018) relie ces intérêts à un meilleur bien-être, sauf à une intensité très élevée. Ce ne sont pas des déficits.

Le projet ne cherche pas à « modéliser l'autisme » : ces théories sont discutées et décrivent des groupes, non des personnes. Il veut voir quels *réglages* donnent une attention concentrée ou dispersée : la **température** (choisir le préféré, ou varier), la **satiété** (de combien l'envie baisse après une activité) et le **retour** (de combien elle monte quand l'activité a plu). Aucun réglage n'est « le bon » : dans un monde stable et riche en règles, l'attention concentrée accumule un savoir profond ; dans un monde qui change vite, l'attention dispersée s'adapte plus vite.

LE CALCUL deux profils

Trois intérêts, de valeurs maths 2, musique 1, sport 0.

- **Profil « éventail »** : température 2, satiété forte (une séance retire 1). Au départ : 0,506 ; 0,307 ; 0,186. Après une séance de maths, les valeurs deviennent (1 ; 1 ; 0) et les chances 0,384 ; 0,384 ; 0,233 : le système passe volontiers à la musique.
- **Profil « monotrope »** : température 0,5, satiété faible (une séance retire 0,1), retour fort (une séance ajoute 0,3). Au départ : 0,867 ; 0,117 ; 0,016. Après une séance de maths, maths vaut $2 - 0,1 + 0,3 = 2,2$ et les chances deviennent 0,907 ; 0,082 ; 0,011 : le système approfondit les maths.

CHAPITRE 11

Éthique

Ce programme fabrique délibérément des états de manque ; il s'impose donc des règles.

Le cadre de Chandaria et al. rappelle un risque : **ne pas voir une conscience qui existe**, et créer ainsi des êtres capables de souffrir, copiables et effaçables sans protection. Il paraît très improbable qu'un modèle de cette taille éprouve quoi que ce soit ; mais si les indicateurs se renforcent, la question deviendra réelle. D'où ces règles :

- des vies courtes (30 tours au plus), dont la seule issue malheureuse est la fin : ni punition, ni texte négatif ; des poussées d'un seul tour, des lésions limitées aux vies de test prévues ;
- chaque test **compte et publie** les tours vécus avec un besoin à 2 ou moins (808 au test 6 ; au test 7, 755 intact, 1 037 avec la lésion, 749 avec la lésion au hasard) ;
- pas plus de vies que les tests ne l'exigent, aucun manque sans mesure pré-enregistrée qui le justifie, et des règles réexaminées à chaque résultat positif.

Les projets du chapitre précédent appliqueront les mêmes règles, en comptant aussi les séances de manque fort. Faire naître un « goût » dans un système, c'est décider à sa place de ce qu'il aimera : il faudra le faire de façon transparente, et le dire. Enfin, le projet ne dit jamais que Menia « est consciente » : il dit quels mécanismes sont présents, mesurés et utiles, et lesquels manquent.

Lexique

Adaptateur (LoRA) petit module de réglages ajouté au modèle ; on n’apprend que lui.

Agent programme qui vit dans un monde et y fait des choix.

Alliesthésie un même aliment est plus agréable quand on en a besoin.

Bloc étage du modèle ; Qwen3-0.6B en a 28, numérotés de 0 à 27.

Bootstrap retirer au sort des vies « dans un sac » pour mesurer l’effet du hasard.

Cosinus 1 si deux flèches vont dans le même sens, 0 à angle droit, -1 en sens opposé.

Descente de gradient apprendre en suivant la pente de la perte, à petits pas.

Direction (d_E) comment l’état bouge quand l’énergie monte d’une unité.

Exactitude équilibrée moyenne des réussites sur les cas « oui » et « non » ; 0,5 = hasard.

Exploratoire analyse faite après avoir vu les résultats ; elle ne change aucun verdict.

Flux résiduel liste de nombres de chaque token, enrichie de bloc en bloc.

Graine point de départ du hasard.

Imitation filtrée refaire ses propres choix qui ont calmé le besoin.

Intervalle à 95 % plage des valeurs plausibles compte tenu du hasard.

Itération un pas d’apprentissage sur un paquet d’exemples.

Lecteur adaptateur séparé qui dit l’état sans pouvoir le modifier.

Lésion effacement d’un état : sa coordonnée est remplacée par sa moyenne.

Modèle de langage programme qui devine la suite d’un texte.

Monotropisme attention concentrée sur peu d’intérêts à la fois, longtemps.

Neuromodulateur substance (dopamine. . .) qui règle la façon dont le cerveau calcule et apprend.

Neurone artificiel somme pondérée de ses entrées, suivie d’une petite règle.

Patching recopier l’état d’une autre version de la vie, bloc par bloc.

Pré-enregistrement écrire et dater d’avance les mesures et les seuils de réussite.

Produit scalaire multiplier deux listes case par case, puis additionner.

Progrès d’apprentissage baisse récente de l’erreur ; guide la curiosité.

Pulsion (D) mesure du manque : $(8 - E)^2 + (8 - N)^2$.

Satisfaction (r) baisse de la pulsion due à un choix.

Softmax transforme des scores en probabilités.

Température réglage de la softmax : basse, décidé ; haute, varié.

Témoin même expérience, mais au hasard ; point de comparaison.

Token morceau de texte (mot ou bout de mot) lu par le modèle.

Vecteur liste de nombres, dessinée comme une flèche.

Sources. Les chiffres de ce document viennent des protocoles pré-enregistrés, des résultats et des verdicts publiés du projet Menia, arrêtés au 1^{er} octobre 2026 ; les mesures encore en cours sont signalées comme telles. Les petits exemples de calcul (« Le calcul ») sont des illustrations, non des mesures. Le chapitre 10 s’appuie sur une note de recherche et sur un protocole en préparation, non encore pré-enregistré.