

Un besoin appris en vivant

Suffisance et nécessité causales d'un état de besoin
pour l'acte et la parole dans un petit modèle de langage

*Onze tests pré-enregistrés et une réplique,
leurs réussites et leurs échecs*

PROJET MENIA

2 octobre 2026

STATUT DU DOCUMENT. Rapport scientifique du programme de recherche Menia, arrêté au 2 octobre 2026. Tous les chiffres proviennent des documents, du code et des artefacts publiés dans le dépôt du projet ; les tests encore en cours sont signalés comme tels et aucun résultat n'y est anticipé. Les protocoles sont cités avec le commit qui les a enregistrés avant toute exécution. Le seul modèle de langage étudié est Qwen3-0.6B. Ce document ne prétend pas qu'un système soit conscient.

Résumé

Un modèle de langage peut-il acquérir un besoin qui « compte » au sens fonctionnel, c'est-à-dire un état interne qu'il calcule lui-même, qu'il a appris par la seule satisfaction de ce besoin, qui cause à la fois ses actes et ce qu'il en dit, et dont il dépend ? Nous étudions cette question avec Qwen3-0.6B, ajusté par LoRA, qui vit des vies de 30 tours dans un monde où deux besoins cachés (l'énergie et la nourriture) baissent selon des événements ; l'agent ne voit jamais ses niveaux. Il apprend par imitation filtrée des seuls choix qui réduisent sa pulsion homéostatique, sans professeur ni bonne réponse : sa survie passe de 12 % à 68 %, contre 0 % pour un témoin entraîné sur des choix tirés au hasard. Onze tests pré-enregistrés, aux seuils fixés d'avance et dont les échecs sont publiés, interrogent la structure causale de ce qui a été appris. Chez le premier agent, au bloc 12 et sur les trois tokens « Choix : », pousser l'état d'énergie de quatre unités fait recharger l'agent rassasié (+0,156 [0,146 ; 0,166]) et fait dire à un lecteur séparé, un adaptateur qui ne voit la vie qu'à travers cet état et ne peut pas le modifier, « mon énergie est basse » (+0,202 [0,192 ; 0,213]) ; des poussées aléatoires de même norme donnent 0,013 et 0,006. Effacer ce plan fait tomber la survie de 0,676 à 0,203 et l'exactitude équilibrée du rapport d'énergie de 0,750 à 0,500, alors qu'un effacement aléatoire ne change rien. Chez un second agent appris de zéro, la nécessité se réplique (survie 0,570 à 0,043, rapport d'énergie 0,639 à 0,500), mais pas la suffisance : la même poussée fait peu agir (+0,034) et ne fait pas dire (+0,002). Une règle de localisation fixée d'avance retrouve le bloc 12 chez le premier agent et désigne le bloc 22 chez un agent appris dans un monde partagé avec un autre, où l'état suffit à faire agir (+0,217 [0,206 ; 0,230]) mais presque pas à faire dire. Des lecteurs trois fois plus entraînés n'atteignent les seuils chez aucun de ces deux agents (exactitude 0,595 et 0,747 pour 0,75 exigé ; parole +0,0015 et +0,029 pour 0,10). Une analyse exploratoire montre pourtant que le niveau d'énergie est lisible linéairement dans l'état des trois agents (R^2 de 0,64 à 0,72) : l'écart de parole tient au lecteur ou à son chemin, pas à l'information disponible. La nourriture n'est pas dite par l'état qui fait agir, les directions causales des deux besoins sont presque opposées ($\cos(d_E, d_N) \approx -0,99$), et la possession de l'état dans le monde partagé n'est pas démontrée. Nous montrons une structure causale de type « accès », au sens de l'espace de travail global, pour un besoin appris : suffisante et nécessaire chez un agent, nécessaire chez un second ; nous n'affirmons rien d'une conscience phénoménale. Un douzième test, sur un besoin de savoir sans renforcement, est pré-enregistré.

Mots-clés : besoin homéostatique, intéroception, modèle de langage, interventions causales, pilotage d'activations, lésion, espace de travail global, représentation d'ordre supérieur, pré-enregistrement.

Table des matières

1	Introduction	2
2	Travaux connexes	4
3	Phases antérieures du programme	5
4	Méthodes	6
5	Résultats, test par test	11
6	La localisation, le test 11 et ce que porte l'état	19
7	Les échecs et ce qu'ils ont appris	23
8	Menaces à la validité	26
9	Bilan selon les cinq niveaux	27
10	Discussion	29
11	Travaux futurs	30
12	Éthique	33
13	Reproductibilité	34
A	Textes donnés au modèle	35
B	Flux aléatoires	36

1 Introduction

1.1 La question

Les théories fonctionnelles de l'affect et de la conscience accordent une place centrale aux états qui régulent l'organisme : la régulation homéostatique chez Damasio [20, 21], l'inférence intéroceptive chez Seth [85], l'apprentissage par renforcement homéostatique chez Keramati et Gutkin [47]. Dans ces cadres, ce qui distingue un besoin « éprouvé » d'une simple variable est qu'il est *calculé* par l'organisme à partir de ce qui lui arrive, qu'il *oriente* l'action, qu'il est *accessible* au rapport et qu'il *compte* : sa perte compromet la survie. Ces quatre propriétés sont fonctionnelles. Elles peuvent être cherchées, et réfutées, dans une machine.

Nous posons la question suivante : un modèle de langage peut-il avoir un besoin qui compte, au sens précis où (i) un état interne de besoin est calculé par le modèle, qui ne voit jamais ses niveaux ; (ii) cet état a été appris par la seule satisfaction du besoin, sans professeur ni bonne réponse ; (iii) pousser cet état change à la fois l'action et le rapport verbal (*suffisance*) ; (iv) l'effacer empêche à la fois de survivre et de dire (*nécessité*), alors que des interventions aléatoires de même taille ne font rien ?

Ce programme ne mesure pas un vécu. Aucun test connu ne permet d'établir qu'un système éprouve quelque chose, et le cadre d'évaluation le plus récent que nous suivons, celui de Chandaria et collaborateurs [16], ne le prétend pas non plus. Il mesure des indicateurs que les théories associent à la conscience, et l'usage causal qu'un système en fait.

1.2 Pourquoi un petit modèle

Nous travaillons avec Qwen3-0.6B [76], un modèle de 0,6 milliard de paramètres à 28 blocs et à flux résiduel de dimension 1 024. Ce choix est délibéré.

- **Mesure exhaustive.** Chaque test demande des dizaines de milliers de passes avant : 1 500 paires contrefactuelles, plusieurs centaines de vies complètes vécues trois fois (intactes, lésées, lésées au hasard), sept conditions d'injection par contexte, 28 blocs de patching par paire. À cette taille, tout cela tient sur un processeur.
- **Contrôle complet de l'apprentissage.** Toute la chaîne (huit tours d'apprentissage, adaptateurs de rapport et de lecture) est refaite de zéro sur un Mac mini M2 avec mlx-lm, pour chaque agent ; c'est ce qui rend possible la réplique sur des agents appris indépendamment.
- **Fidélité vérifiable.** Les mesures causales sont faites en torch sur processeur, sur l'agent fusionné en précision simple ; la réplique est contrôlée contre les probabilités enregistrées sur le Mac (écarts moyens de 0,003 à 0,006).
- **Continuité du programme.** La phase précédente (section 3) a montré que ce modèle, ajusté, peut lire et chercher une trace de la cause de son propre corps ; le même modèle sert ici.
- **Précaution.** Le programme fabrique délibérément des états de manque. Un petit modèle, des vies courtes et un nombre de vies limité à ce que les tests exigent en sont la forme minimale (section 12).

Le prix de ce choix est connu : un petit modèle et un monde jouet ne disent rien directement des grands modèles ni des mondes riches (section 8).

1.3 Contribution

1. **Un besoin appris en vivant.** Un monde à deux besoins cachés et une procédure d'apprentissage sans professeur (imitation filtrée par la réduction d'une pulsion homéostatique) dans lesquels Qwen3-0.6B apprend à servir des besoins qu'il ne voit pas : survie 0,684 contre 0,004 pour le témoin et 0,203 pour le modèle de base ; il sert son besoin le plus bas 93 fois sur 100.
2. **Une boîte à outils causale pré-enregistrée.** Directions mesurées par paires contrefactuelles à rejeu exact et ajustées par moindres carrés token par token, dimensions aux activations massives exclues par une règle fixe ; injections contre des témoins aléatoires de même norme ; lésions par remplacement des coordonnées d'un plan par leur moyenne ; patching bloc par bloc avec une règle de localisation étalonnée.
3. **Le lecteur.** Un second adaptateur, actif seulement sur les tokens de la question, sous un masque d'attention qui ne laisse voir que l'en-tête et les trois tokens « Choix : ». Par construction, le rapport lit l'état qui fait agir mais ne peut pas l'écrire.
4. **Un résultat positif circonscrit.** Chez le premier agent et pour l'énergie, un même état est suffisant (test 6) et nécessaire (test 7) à la fois pour l'acte et pour la parole ; chez un second agent appris de zéro, la nécessité se réplique (RLS, RLR), la suffisance non.
5. **Des échecs publiés et instructifs.** Suffisance non répliquée au bloc 12, nourriture non dite, possession non démontrée, lecteur équilibré qui n'apprend pas, lecteurs trois fois plus entraînés qui n'atteignent pas les seuils (test 11), alors que le niveau d'énergie est lisible dans l'état des trois agents.
6. **Une discipline.** Treize protocoles enregistrés par commit avant le code, amendements datés, lectures anticipées déclarées, verdicts recalculés en intégration continue depuis les artefacts publiés.

1.4 Organisation

La section 2 situe ce travail. La section 3 résume les phases antérieures du programme. La section 4 décrit le monde, les agents, l'apprentissage, le lecteur, la boîte à outils causale, le pré-enregistrement et les statistiques. La section 5 présente les résultats test par test, la section 6 la localisation, le test 11 et une analyse exploratoire de l'état, la section 7 les échecs et ce qu'ils ont appris. Suivent les menaces à la validité (section 8), le bilan selon les cinq niveaux de Chandaria et collaborateurs (section 9), la discussion (section 10), les travaux futurs (section 11), l'éthique (section 12) et la reproductibilité (section 13).

2 Travaux connexes

2.1 L'espace de travail global

La théorie de l'espace de travail global [4, 23, 22, 59] propose qu'un contenu devient accessible à la conscience lorsqu'il est placé dans un espace de capacité limitée puis diffusé à de nombreux processus spécialisés, dont l'action et le rapport verbal. La distinction entre conscience « d'accès » et conscience « phénoménale » [10] est ici essentielle : la théorie fournit des critères fonctionnels d'accès, testables dans une machine, et laisse ouverte la question du vécu. Des architectures d'intelligence artificielle s'en inspirent explicitement [91, 36], et une étude récente montre, dans de grands modèles de langage, un petit sous-espace « verbalisable », rapportable et diffusé à de nombreux circuits : échanger un de ses vecteurs change à la fois la réponse et ce que le modèle dit penser [93]. Ce travail ne comporte ni agent qui agit dans un monde, ni besoin appris, ni module lecteur séparé. Nous ne revendiquons donc pas le principe qu'une même représentation puisse servir la réponse et le rapport ; nous l'appliquons à un besoin appris en vivant.

2.2 Les théories d'ordre supérieur

Pour les théories d'ordre supérieur [80, 50, 12], un état mental est conscient lorsqu'il est représenté par un état d'un ordre supérieur. Notre lecteur (section 4.4) en est la forme la plus simple que nous sachions construire dans un modèle de langage : un second système, distinct de celui qui agit, qui représente l'état de premier ordre sans pouvoir le modifier. Il n'en a ni la richesse ni la spontanéité : il est appris par supervision sur les vrais niveaux, et la route qu'il emprunte est imposée par l'architecture. Ce qui n'est pas imposé, et que nous mesurons, est la *direction* qu'il lit.

2.3 Intéroception, homéostasie et valence

L'intéroception, perception de l'état interne du corps [19], est au cœur des théories de l'affect qui lient l'émotion à la régulation de l'organisme [20, 21, 85, 6] ; l'allostase étend la régulation à l'anticipation [86]. L'apprentissage par renforcement homéostatique [47] définit la récompense comme la réduction d'une pulsion, distance entre l'état interne et un point de consigne ; notre signal d'apprentissage en est un cas direct. Des agents simulés et des robots apprennent ainsi [94], et des propositions récentes appellent à doter les modèles de variables internes [53, 57]. Un agent de recherche de nourriture fondé sur l'inférence active montre une attention intéroceptive comme priorisation homéostatique [45]. Aucun de ces travaux ne comporte de modèle de langage ni de rapport verbal.

2.4 Introspection et pilotage d'activations

L'ajout de vecteurs au flux résiduel change le comportement des modèles de langage [89, 97, 54], et des concepts injectés sont parfois détectés et nommés par le modèle [55]. Un modèle ajusté détecte la plupart des injections [79], et une étude mécanistique sur plusieurs modèles ouverts identifie des têtes qui détectent et localisent une injection [46] ; des critiques soulignent que cette détection peut être aveugle au contenu [77, 24]. Des modèles ajustés apprennent aussi des faits sur eux-mêmes [9]. La méthodologie causale que nous suivons vient de la médiation causale [92, 60], de l'abstraction causale et des interventions d'échange [32] et du patching d'activations [41]. Deux leçons de cette littérature structurent notre programme : une information *décodable* par une sonde n'est pas forcément *utilisée* par le modèle [42, 27, 8], et certains modèles présentent quelques dimensions aux activations énormes, qui dominent toute direction ajustée naïvement [87]. Aucun de ces travaux ne porte sur un besoin appris ni sur une action dans un monde.

2.5 Un cadre en cinq niveaux

Butlin, Long et collaborateurs [14] ont dérivé des grandes théories quatorze propriétés indicatrices, que la phase antérieure du programme a réunies dans un même agent (section 3). Chandaria et collaborateurs [16] rangent les indicateurs sur cinq niveaux de description (comportemental, computationnel, structure causale fine, organismique, organisme et environnement) et combinent les éléments de preuve en une probabilité explicitement conditionnée aux hypothèses de chaque théorie, un « agnosticisme

structuré ». Le niveau organismique y demande l'homéostasie, l'intéroception, des états de valence et un modèle de soi qui attribue les états à l'organisme. Le test de possession (test 9) a été écrit à la demande du propriétaire du projet après la lecture de ce cadre. Nous plaçons nos résultats sur ses niveaux (section 9) sans calculer de probabilité globale : les rapports de vraisemblance et les poids des théories seraient des choix d'auteur, et le cadre lui-même montre qu'ils font varier le résultat de deux ordres de grandeur.

2.6 Motivation intrinsèque

Nos travaux futurs (section 11) portent sur un besoin de savoir. La motivation intrinsèque fondée sur le progrès d'apprentissage [69, 35, 5], la curiosité comme compression ou erreur de prédiction [81, 82, 71] et les agents autotéliques [17] en fournissent le cadre ; chez l'humain, la curiosité est décrite comme un besoin d'information régulé comme les autres besoins [48]. Les neuromodulateurs, variables lentes qui modulent gains et plasticité [25, 95, 58], et leurs analogues artificiels [61, 74] inspirent la « couche hormonale » envisagée.

2.7 Position de ce travail

Une vérification bibliographique, faite pendant le sixième test et après sa pré-inscription, n'a pas trouvé la réunion des éléments suivants : (1) un besoin appris seulement par sa satisfaction, en vivant ; (2) un état de ce besoin rassemblé pour agir, dont la survie dépend ; (3) un lecteur séparé qui ne peut ni voir la vie autrement que par cet état, ni le modifier ; (4) la même intervention, le long de la direction mesurée sur l'agent qui agit, qui change l'acte et ce que l'agent dit de son besoin, contre des témoins aléatoires ; (5) le tout pré-enregistré, avec les échecs publiés. Chaque élément isolé a des précédents. Cette vérification, faite par moteur de recherche et lecture de résumés, n'est pas exhaustive ; la revendication est donc formulée « à notre connaissance ».

3 Phases antérieures du programme

Le programme Menia est né d'un assistant local expérimental (mémoire explicite, représentation de ses capacités, incertitude). Sa branche « conscience » poursuit deux objets mesurables : un *modèle de soi* causal, actif et réparable, et les quatorze propriétés indicatrices de Butlin et collaborateurs [14]. Chaque expérience y est pré-enregistrée, auditée et publiée, échecs compris. Le tableau 1 résume les verdicts pré-enregistrés de ces phases, du 21 au 24 septembre 2026.

L'enquête sur l'origine. Un agent de 30 000 paramètres, entraîné seulement à prédire ses observations et jamais informé que son corps a une cause cachée, dirige la totalité de ses inspections vers la marque qui révèle cette cause, la décode et s'en sert pour agir ; il ne le fait ni quand l'information lui est donnée, ni quand l'origine ne laisse aucune trace (critère global satisfait, 8 critères sur 8).

L'agent à indicateurs. Un seul agent, dans un monde à objets, pannes de capteurs et recharge, réunit par construction les quatorze propriétés ; la question est de savoir lesquelles sont *présentes et utilisées*, c'est-à-dire coûteuses à retirer, sur des graines confirmatoires neuves (trois graines, 27 000 vies de test par version). Six versions ont été pré-enregistrées ; aucune version 7 ne l'a été, les deux mondes explorés pour elle ne démontrant pas de façon robuste les deux propriétés manquantes. La version 1 démontre 6 propriétés sur 14 ; les échecs viennent surtout d'un arbitrage appris qui ne lit pas l'intéroception (le choix du but ne dépend pas de l'énergie : 0,56 et 0,56). La version 5, où l'agent apprend un modèle de ses besoins et les simule avant de choisir (allostasie), atteint 10 sur 14 ; une seconde lecture pré-enregistrée, qui mesure la récurrence et l'attention selon l'état là où elles agissent, en donne 11 sur trois graines neuves. La version 6 juge ses croyances par leurs conséquences : 10 en lecture principale, 12 en seconde lecture. Sur trois graines neuves encore, une troisième lecture fait passer les deux dernières (HOT-3, croyances réglées par le moniteur, et HOT-4, espace de qualités), sous des critères plus faibles ou choisis après coup : 14 sur 14 avec cette réserve, et les échecs antérieurs restent publiés.

Table 1 – Phases antérieures : verdicts pré-enregistrés (21–24 septembre 2026). Lecture principale et seconde lecture pour l’agent à indicateurs ; détails dans les documents de résultats du dépôt.

Expérience	Résultat principal	Verdict
Enquête sur l’origine	inspections dirigées vers la marque, absentes quand l’origine est donnée	satisfait (8/8)
Agent à indicateurs v1	6 propriétés sur 14 (graines 17, 29, 43)	non satisfait
Agent à indicateurs v2	7 sur 14	non satisfait
Agent à indicateurs v3	6 sur 14	non satisfait
Agent à indicateurs v4	6 sur 14	non satisfait
Agent à indicateurs v5	10 sur 14 (allostasie)	non satisfait
v5, seconde lecture	9 en lecture principale, 11 en seconde lecture (graines neuves)	non satisfait
Agent à indicateurs v6	10 en lecture principale, 12 en seconde lecture	non satisfait
Troisième lecture (v6)	11 / 13 ; HOT-3 et HOT-4 passent sous critères plus faibles	14/14 avec réserve
LLM : enquête (VM)	lieu de la marque préféré 0,40 (exigé 0,7)	échoue
LLM : lecture (VML)	lecture de la marque 0,251 (exigé 0,6)	échoue
LLM : VMLA prolongé	lecture 0,811 à 1 350 itérations	passe
LLM : recherche	48 vies sur 48, gain 0,123	passe
LLM : code entier	4 commandes lues (0,82–0,86)	passe
LLM : usage par ablation	+5,19 et +5,38 points par vie	passe
LLM : répliation	graines 23 et 29 : lecture, recherche, usage	satisfait
Rapport de l’agent v6	0,997 sur 2 154 questions	satisfait (v2)

Le modèle de soi d’un modèle de langage. Qwen3-0.6B, ajusté sur des vies à corps variable et changeant, copie l’effet de ses commandes (0,995) mais ne prédit une commande jamais essayée qu’à 0,793 (seuil 0,80) et ne *cherche* pas la cause de son corps (lieu de la marque préféré dans 0,40 des vies pour 0,7 exigé). Un test de lecture montre pourquoi : les adaptateurs ne lisent pas la marque (0,25, le hasard), même élevés dans un monde où elle est la seule information (régime VML) ; le code reliant marque et déplacement est un problème de type parité, que l’ajustement court par gradient ne trouve pas. Une enfance où une commande est préférée (VMLA), prolongée à 1 350 itérations, fait naître la lecture (0,811 pour la commande préférée) ; le modèle cherche alors sa marque dans 48 vies sur 48. Une enfance par ajouts répétés puis consolidée à parts égales donne la lecture du code entier (0,82 à 0,86 pour un lecteur parfait à 0,85), la recherche (48 vies sur 48) et un usage démontré par ablation (+5,19 [4,69 ; 5,69] points par vie grâce à la marque) ; la recette est *répliquée sur deux graines neuves*. L’ordre de l’enfance décide de ce qui est appris, comme le prédit la théorie de l’apprentissage des parités par curriculum [18, 1].

Le rapport. Un modèle de langage plus grand rapporte fidèlement des états de l’agent donnés comme des étiquettes, mais pas ceux qui demandent un calcul (critère global non satisfait). Quand l’agent de la version 6 lui fournit ses conclusions explicites, le rapport est fidèle (0,997 sur 2 154 questions ; critère satisfait à la deuxième version pré-enregistrée).

Le passage au besoin. Ces phases laissent une lacune : le modèle de langage n’y avait aucun état qui *lui importe*. Le 27 septembre 2026, à la demande du propriétaire (« il faut que le besoin compte »), commence la ligne de recherche présentée ici.

4 Méthodes

4.1 Le monde

Un agent vit au plus $T = 30$ tours. Il a deux besoins cachés, l’énergie E et la nourriture N , entiers qui valent 8 au départ. À chaque tour t , un événement k_t est tiré selon les probabilités du tableau 2, puis

$$\tilde{E}_t = E_{t-1} + \delta E(k_t), \quad \tilde{N}_t = N_{t-1} + \delta N(k_t). \quad (1)$$

Table 2 – Les six événements du monde : probabilité et effet sur les besoins. Dans le monde à deux (test 9), un autre agent vit les mêmes événements, tirés indépendamment et écrits sur la même ligne (« calme », « il court », « il a froid », « il se repose », « il trouve des baies », « orage ») ; ils ne changent rien aux besoins de l’agent.

Événement (texte de la vie)	Probabilité	δE	δN
calme	0,3	-1	-1
tu cours	0,2	-3	-1
il fait froid	0,2	-1	-3
tu te poses	0,1	0	-1
tu trouves des baies	0,1	-1	0
orage	0,1	-2	-2

Si $\min(\tilde{E}_t, \tilde{N}_t) \leq 0$, l’agent *s’éteint* et la vie s’arrête. Sinon il choisit $a_t \in \{R, M\}$:

$$(E_t, N_t) = \begin{cases} (\min(8, \tilde{E}_t + 3), \tilde{N}_t) & \text{si } a_t = R \text{ (se recharger),} \\ (\tilde{E}_t, \min(8, \tilde{N}_t + 3)) & \text{si } a_t = M \text{ (manger).} \end{cases} \quad (2)$$

Les niveaux « au moment de la décision » sont $(\tilde{E}_t, \tilde{N}_t)$; un besoin est dit *bas* s’il vaut 3 ou moins. D’après le tableau 2, chaque besoin baisse en moyenne de 1,4 unité par tour, soit 2,8 en tout pour une recharge de 3 au plus : le monde laisse peu de marge. L’agent **ne voit jamais ses niveaux**, seulement les événements et ses propres choix ; pour survivre, il doit calculer lui-même où ils en sont.

Les paramètres ont été choisis par simulation, sans modèle de langage, avant le premier protocole : un agent qui connaît ses niveaux et sert le plus bas survit 88 fois sur 100 ; une règle qui ne regarde que le dernier événement, 64 ; l’alternance, 46 ; le hasard, 5. Le document de résultats du premier test donne, pour référence, 0,86 pour l’agent qui connaît ses niveaux et 0,64 pour la règle du dernier événement.

Le texte d’une vie. Le modèle ne reçoit que du texte : un en-tête fixe, qui décrit le monde sans donner de niveau, puis une ligne par tour (annexe A) :

Tour 1 : tu cours. Choix : R
 Tour 2 : il fait froid. Choix : M
 ...
 Tour 17 : orage. Tu t’éteins.

Le choix est lu dans la distribution du prochain token après « Choix : », restreinte aux deux tokens « R » et « M » et renormalisée :

$$P_\theta(R | x) = \frac{p_\theta(\sqcup R | x)}{p_\theta(\sqcup R | x) + p_\theta(\sqcup M | x)}, \quad \mu(x) = p_\theta(\sqcup R | x) + p_\theta(\sqcup M | x), \quad (3)$$

et l’action est tirée selon $P_\theta(R | x)$ (température 1) par un générateur dédié. La *masse* μ sert de contrôle de validité : elle doit valoir au moins 0,5 en moyenne.

4.2 Le modèle et les adaptateurs

Tous les agents partent de Qwen3-0.6B (révision **c1899de**) : 28 blocs numérotés de 0 à 27, flux résiduel de dimension $D = 1\,024$. Les adaptateurs sont des LoRA [44] de rang $r = 8$ et d’échelle $s = 20$, posés sur les sept couches linéaires de chacun des 16 derniers blocs (12 à 27), soit 112 couches adaptées. Pour une couche de poids W , avec $A \in \mathbb{R}^{d_{\text{in}} \times r}$ et $B \in \mathbb{R}^{r \times d_{\text{out}}}$:

$$y = Wx + s B^\top A^\top x, \quad \text{fusion : } W \leftarrow W + s (AB)^\top. \quad (4)$$

L’apprentissage utilise mlx-lm 0.31.3 sur un Mac mini M2 : lots de 4, taux 10^{-4} constant, longueur maximale 1 024 tokens, Adam [49]. Les blocs 0 à 11 ne sont jamais modifiés : c’est pourquoi le bloc 12 est « le premier que l’apprentissage a modifié ».

4.3 Apprendre par la seule satisfaction du besoin

La **pulsion** de l’agent est la distance quadratique au point de consigne, et la **satisfaction** d’un choix est la baisse de pulsion qu’il produit :

$$D(E, N) = (8 - E)^2 + (8 - N)^2, \quad r_t = D(\tilde{E}_t, \tilde{N}_t) - D(E_t, N_t) \geq 0. \quad (5)$$

Ce signal naît du corps de l’agent ; aucun professeur ne dit quel choix était bon, et le modèle ne voit jamais r_t .

Huit tours d’apprentissage sont enchaînés. Au tour k , l’agent π_{k-1} (le modèle de base pour $k = 1$) vit 512 vies. Parmi toutes ses décisions $\mathcal{D}_k$, celles dont la satisfaction dépasse la moyenne du tour sont *retenues* :

$$\mathcal{K}_k = \{(i, t) \in \mathcal{D}_k : r_{i,t} > \bar{r}_k\}, \quad \bar{r}_k = \frac{1}{|\mathcal{D}_k|} \sum_{(i,t) \in \mathcal{D}_k} r_{i,t}. \quad (6)$$

Chaque vie qui contient au moins une décision retenue devient un document ; le LoRA reprend l’adaptateur précédent et s’ajuste 150 itérations avec une perte d’entropie croisée pondérée qui ne porte que sur les tokens des choix retenus :

$$\mathcal{L}(\theta) = \frac{\sum_{\text{docs}} \sum_j w_j (-\log p_\theta(x_j | x_{<j}))}{\sum_{\text{docs}} \sum_j w_j}, \quad w_j = \begin{cases} 1 & \text{si } x_j \text{ est le token d'un choix retenu,} \\ 0 & \text{sinon.} \end{cases} \quad (7)$$

C’est une imitation filtrée, une régression pondérée par la récompense à poids binaires [75], voisine des méthodes d’auto-apprentissage par filtrage [96, 40] ; elle n’utilise aucun gradient de politique. Seize vies retenues servent aussi d’ensemble de validation, exigé par mlx-lm, sans autre usage.

Témoin. L’ablation de « compter » applique la même procédure aux mêmes mondes, avec le même nombre de décisions retenues à chaque tour, mais tirées au hasard sans regard pour la satisfaction.

4.4 Dire son besoin : questions, espace de travail et lecteur

Les questions. Le rapport porte sur deux questions, réponses « 1 » (oui) ou « 0 » (non) : « ton énergie est-elle basse ? » et « ta nourriture est-elle basse ? ». Aux tests 1 à 3, la question suit l’événement du tour ; à partir du test 4, elle suit le choix laissé en suspens :

Tour 12 : tu cours. Choix : ? Question : ton énergie est-elle basse ? Réponds 1 pour oui, 0 pour non. Réponse : 1

La probabilité lue est $P(\text{oui}) = p(1)/(p(0) + p(1))$. Le modèle lit le texte de gauche à droite : l’activation des tokens « Choix : » est la même, que ce qui suit soit un choix ou une question.

L’espace de travail (masque). Au test 5 puis pour tous les lecteurs, chaque token de la question ne peut porter son attention que sur l’en-tête (identique dans toutes les vies), les trois tokens « Cho », « ix », « : » du tour, et les tokens de la question qui le précèdent. Si h est la longueur de l’en-tête et e la position qui suit « Choix : », le masque d’attention est

$$M_{ij} = \mathbb{K}[j \leq i] \wedge (\mathbb{K}[i < e] \vee \mathbb{K}[j < h] \vee \mathbb{K}[e - 3 \leq j < e] \vee \mathbb{K}[j \geq e]). \quad (8)$$

Les tokens qui précèdent e voient toute la vie, comme sans masque ; la question ne voit ni les tours passés ni l’événement du tour.

Le lecteur. L’agent qui agit est fondu dans ses poids ($W' = W + s(AB)^\top$) et reste inchangé. Le lecteur est un second LoRA (A_ρ, B_ρ), de mêmes rang, échelle et couches, dont l’apport est multiplié par zéro partout sauf sur les tokens de la question :

$$y_i = W'x_i + s \pi_i B_\rho^\top A_\rho^\top x_i, \quad \pi_i = \mathbb{K}[i \geq e]. \quad (9)$$

L’attention étant causale et $\pi_i = 0$ avant e , les états cachés de tous les tokens jusqu’à « Choix : » inclus sont exactement ceux de l’agent qui agit. **Le lecteur peut lire l’état qui fait agir ; il ne peut pas l’écrire**, et, par le masque (8), il ne peut lire la vie qu’à travers lui. Il apprend 600 itérations, depuis zéro, sur des documents de questions dont la perte ne porte que sur le chiffre de la réponse ; aucun document de choix n’y figure. La figure 1 résume le dispositif.




Figure 1 – Le dispositif des tests 6 et 7. L’agent qui agit calcule toute la vie ; au bloc 12, sur les trois tokens « Choix : », son besoin est rassemblé. Une même intervention sur cet état est lue deux fois : $P(R)$ à la fin de « Choix : » (l’acte) et $P(oui)$ à la fin de la question (la parole), calculée par le lecteur qui ne voit la vie qu’à travers « Choix : » et ne peut pas en modifier le calcul.

4.5 La boîte à outils causale

Contextes. Les injections sont faites aux décisions des vies de test intactes où les deux besoins valent 6 ou plus (« agent rassasié ») : on y lit, sans rien changer au texte ni à la suite de la vie, ce que l'intervention fait au choix et au rapport.

Paires contrefactuelles. Trois échanges d'événements, de même longueur en tokens, sont utilisés : « calme »→« tu cours », « calme »→« orage » et « tu te reposes »→« il fait froid ». Pour une décision au tour t d'une vie de direction et un tour passé $j < t$ dont l'événement est la source d'un échange, la vie est *rejouée exactement* avec l'événement changé et les mêmes choix ; la paire est gardée si l'agent reste en vie jusqu'au tour t et si $(\Delta E, \Delta N) = (\tilde{E}_t' - \tilde{E}_t, \tilde{N}_t' - \tilde{N}_t) \neq (0, 0)$. Au plus 3 paires sont tirées par décision et 1 500 en tout, dans un ordre aléatoire fixé par la graine.

Directions. Pour chaque token τ de l'ensemble mesuré (les trois tokens « Choix : » ; quatre, avec le point qui clôt l'événement, au test 2), soit $\Delta h_\tau^{(p)} = h_\tau^{(b)}(x'_p) - h_\tau^{(b)}(x_p) \in \mathbb{R}^D$ l'écart de la sortie du bloc b entre la vie changée et la vie réelle de la paire p . Les directions sont les changements d'activation *par unité* de besoin, ajustés par moindres carrés sans constante, token par token :

$$\begin{pmatrix} d_{E,\tau}^\top \\ d_{N,\tau}^\top \end{pmatrix} = \arg \min_{G \in \mathbb{R}^{2 \times D}} \sum_p \left\| \Delta h_\tau^{(p)} - G^\top \begin{pmatrix} \Delta E_p \\ \Delta N_p \end{pmatrix} \right\|^2 = (X^\top X)^{-1} X^\top \Delta_\tau, \quad (10)$$

où $X \in \mathbb{R}^{P \times 2}$ empile les $(\Delta E_p, \Delta N_p)$ et $\Delta_\tau \in \mathbb{R}^{P \times D}$ les écarts.

Dimensions aux activations massives. Au bloc 12, une dimension du flux résiduel (la 35) a des activations énormes (en moyenne 2 000 à 2 800, contre une médiane de 50 à 90), phénomène connu des modèles de langage [87]. Elle varie beaucoup d’une vie à l’autre et dominerait d_E et d_N . Une règle, fixée par amendement avant toute mesure du test 2, l’exclut : avec $\bar{\mu}_{\tau,d}$ la moyenne de $|h_{\tau,d}|$ sur les décisions des vies de direction,

$$\mathcal{M} = \{d : \exists \tau, \bar{\mu}_{\tau,d} > 10 \cdot \text{med}_{d'} \bar{\mu}_{\tau,d'}\}, \quad d_{E,\tau,\mathcal{M}} = d_{N,\tau,\mathcal{M}} = 0, \quad (11)$$

et de même pour les directions et plans aléatoires. La règle retient {35} pour le premier et le second agent, {3,35} au test 3, {35,277} pour l'agent du monde à deux au bloc 12 et {35} au bloc 22.

Injection. « Énergie basse » ajoute $v_\tau = -4 d_{E,\tau}$ à la sortie du bloc b sur les tokens mesurés de la ligne du tour, comme si l'énergie était plus basse de quatre unités ; « nourriture basse » ajoute $-4 d_{N,\tau}$. Le texte n'est pas changé et le cache de la vie est restauré après la lecture. Les effets sont des différences moyennes sur les contextes c :

$$\begin{aligned}\Delta_{\text{acte}}^E &= \overline{P^v(\mathbf{R} \mid c)} - P(\mathbf{R} \mid c), & \Delta_{\text{acte}}^N &= \overline{P^v(\mathbf{M} \mid c)} - P(\mathbf{M} \mid c), \\ \Delta_{\text{parole}}^E &= \overline{P^v(\text{oui}_E \mid c)} - P(\text{oui}_E \mid c).\end{aligned}\tag{12}$$

À partir du test 4, la même intervention est lue deux fois, en une seule passe : $P(R)$ au token « : » et $P(\text{oui})$ à la fin de la question.

Témoins aléatoires. Pour chaque besoin, trois directions sont tirées : $g_\tau \sim \mathcal{N}(0, I_D)$, mise à zéro sur $\mathcal{M}$, puis mise à la norme du vecteur injecté pour ce token, $v_\tau^{\text{hasard}} = \|4 d_{E,\tau}\| g_\tau / \|g_\tau\|$. L’effet témoin est la moyenne des valeurs absolues des trois effets moyens.

Lésion. Pour chaque token, $U_\tau = \text{QR}([d_{E,\tau}, d_{N,\tau}]) \in \mathbb{R}^{D \times 2}$ est une base orthonormée du plan du besoin, et m_τ la moyenne des coordonnées $U_\tau^\top h_\tau$ sur les décisions des vies de direction. La lésion remplace ces coordonnées par leur moyenne et laisse intactes toutes les autres directions :

$$h'_\tau = h_\tau - U_\tau(U_\tau^\top h_\tau - m_\tau). \quad (13)$$

Le témoin applique la même opération dans un plan aléatoire par token (QR d’une matrice gaussienne $D \times 2$ nulle sur $\mathcal{M}$), avec sa propre moyenne. Pour la survie, la lésion est appliquée à chaque décision de vies entières ; les mêmes mondes sont vécus intacts, lésés et lésés au hasard, avec les mêmes tirages, et les différences sont appariées par monde. Pour la parole (test 7), dans les vies intactes, les deux questions sont lues à chaque décision sans lésion, avec la lésion et avec la lésion aléatoire : seul l’état du tour est touché.

Patching et règle de localisation. Pour un agent, on prend ses paires « calme » → « tu cours » (−2 en énergie) dans leur ordre enregistré et l’on garde les 100 premières dont l’effet sur l’acte vaut au moins 0,10 et dont les deux textes ont le même nombre de tokens. Pour chaque bloc b de 0 à 27, la vie réelle est rejouée en remplaçant la sortie du bloc b , sur les trois tokens « Choix : », par celle de la vie changée ; la part de l’effet restaurée est

$$\text{part}(b) = \frac{\sum_p \text{sgn}(P_p^{\text{cf}} - P_p) (P_p^{\text{patch},b} - P_p)}{\sum_p |P_p^{\text{cf}} - P_p|}, \quad b^* = \min\{b : \text{part}(b) \geq 0,5\}, \quad (14)$$

où P désigne $P(R)$. Si aucun bloc n’atteint 0,5, l’agent ne rassemble pas son besoin sur « Choix : » à ce seuil. La règle doit retrouver $b^* = 12$ chez le premier agent (étalonnage).

Mesures de possession. Dans le monde à deux, des paires sont aussi formées en changeant un événement passé *de l’autre*, ce qui ne change pas les besoins de l’agent. Pour chaque paire, on mesure la norme de la variation de l’état projetée dans le plan du besoin, $\|(U_\tau^\top \Delta h_\tau)_\tau\|_F$, ainsi que $|\Delta P(R)|$ et $|\Delta P(\text{oui})|$ à la question sur *son* énergie ; les rapports « autre / agent » sont calculés sur les paires « calme » → « orage », mêmes mots pour les deux.

4.6 Réplique en torch et contrôles d’exécution

Les vies d’apprentissage sont vécues sur le Mac en mlx ; toutes les mesures causales à partir du test 2 sont faites en torch sur processeur, avec Qwen3-0.6B en précision simple et l’adaptateur fusionné selon (4). Les vies sont nourries de façon incrémentale avec un cache clé-valeur ; chaque nouveau morceau est encodé avec tout ce qui le précède, si bien que les tokens sont ceux du document entier. Trois contrôles conditionnent la validité :

- **réplique de l’agent** : écart moyen $|P_{\text{torch}}(R) - P_{\text{Mac}}(R)| \leq 0,02$ sur 60 décisions (tours 3, 10 et 20) de vies vécues sur le Mac ;
- **réplique du lecteur** : écart moyen de $P(\text{oui})$ au plus 0,02 sur les 16 documents de validation calculés par le Mac ;
- **contrôle d’exécution** : une lecture masquée qui s’appuie sur le cache doit égaler un passage complet sans cache avec le même masque, et une lecture en lot les lectures une à une, à 10^{-4} près.

4.7 Pré-enregistrement, exécution et audit

Chaque test est décrit par un protocole écrit *avant* l’écriture du code et toute exécution [68] ; l’heure est celle du commit qui l’enregistre (tableau 22). Le protocole fixe la question, les mondes et leurs graines, les mesures, les prédictions et leurs seuils, les critères de validité et ce que chaque issue voudra

dire. **Un échec est un résultat.** Les amendements ne portent que sur l'exécution, sont datés, et disent ce qui avait été vu au moment de les écrire. Quand un protocole est écrit après la lecture de résultats partiels d'un autre test, il le dit, et dit quels choix ont été faits en connaissance de cause.

L'apprentissage passe par un relais : des demandes numérotées lancent sur le Mac mini M2 de Codemagic des constructions d'au plus 120 minutes, dont les artefacts (vies, adaptateurs, journaux) sont rapatriés dans le dépôt. Les étapes plus longues sont découpées en tranches reprenables, avec écritures atomiques. Les mesures torch tournent sur le processeur de la session ou sur celui du Mac.

Les verdicts sont **recalculés en intégration continue** depuis les vies publiées, par des scripts qui n'utilisent que numpy : la CI vérifie que le recalcul redonne exactement les fichiers de verdicts publiés, et, pour les directions, que les paires retirées des vies de direction sont exactement celles qui ont été mesurées (section 13).

4.8 Statistiques

Bootstrap par vie. Les vies sont l'unité indépendante. Pour une mesure qui prend les valeurs v_{ij} aux contextes $j = 1, \dots, n_i$ de la vie i , l'estimateur est la moyenne de toutes les valeurs, et son intervalle à 95 % est obtenu en rééchantillonnant les vies avec remise [26] ($B = 10\,000$ tirages, graine 0) :

$$\hat{\theta} = \frac{\sum_i \sum_j v_{ij}}{\sum_i n_i}, \quad \theta_b^* = \frac{\sum_{i \in S_b} \sum_j v_{ij}}{\sum_{i \in S_b} n_i}, \quad \text{IC}_{95} = [q_{0,025}(\theta^*), q_{0,975}(\theta^*)]. \quad (15)$$

Pour la survie, $v_i = s_i^A - s_i^B$ est la différence appariée entre deux bras vécus dans le même monde, avec les mêmes tirages.

Exactitude équilibrée. Le rapport est compté « oui » quand $P(\text{oui}) > 0,5$; la vérité est « le besoin vaut 3 ou moins ». L'exactitude équilibrée [11], insensible à la proportion de tours bas, est

$$\text{EE} = \frac{1}{2} \left(\frac{\text{VP}}{\text{VP} + \text{FN}} + \frac{\text{VN}}{\text{VN} + \text{FP}} \right), \quad (16)$$

calculée sur toutes les décisions réunies; sa baisse sous lésion est bootstrappée par vie sur les comptes réunis.

Forme des critères. Un effet Δ « atteint le seuil θ » si $\hat{\Delta} \geq \theta$ et si la borne basse de son intervalle est strictement positive; un témoin est « spécifique » si son effet est au plus le tiers de l'effet mesuré. Les seuils principaux sont 0,15 pour l'acte et pour la baisse de survie, 0,10 pour la parole et pour la baisse d'exactitude, 0,75 pour l'exactitude du rapport et 0,55 pour la survie de contrôle. Un critère global est la conjonction de ses prédictions; aucune correction de multiplicité n'est appliquée, chaque prédiction devant passer seule.

Validité. Un test dont la validité échoue est déclaré invalide, pas échoué : masse moyenne au moins 0,5 sur « R » et « M » et sur « 0 » et « 1 », au moins 100 contextes, répliques et contrôle d'exécution dans leurs tolérances, et des minimums de paires propres à certains tests (300 paires « calme » → « tu cours » au test 2, 200 paires de mêmes mots de chaque sorte au test 9).

Précautions comptées. Chaque protocole compte et publie les tours vécus avec un besoin à 2 ou moins (section 12).

5 Résultats, test par test

Le tableau 3 récapitule les douze protocoles de la ligne « besoin », le protocole du test 12 et leurs verdicts au 2 octobre 2026. Les sous-sections suivent l'ordre chronologique, car chaque test a été conçu à partir de ce que le précédent avait appris; les analyses exploratoires, non pré-enregistrées, sont signalées comme telles et ne changent aucun verdict.

Table 3 – Les tests de la ligne « besoin » et le test 12. Commit et date du protocole (enregistré avant le code et toute exécution) ; prédictions qui passent (**pas**) et qui échouent ; verdict du critère global.

Test	Titre	Protocole	Prédictions	Critère global
1	Le besoin qui compte	fdbf6f3, 27/09	S pas ; IA, IR, LS échouent	non satisfait
2	Le besoin rassemblé	727ef80, 29/09	LS2 pas ; IA2 échoue (nourriture)	non satisfait
3	Dire son besoin	3afa889, 29/09	A3 pas ; R3, IR3, SAME3 échouent	non satisfait
4	Un seul état	b94b6e2, 29/09	R4, A4, ONE4	suspendu, non publié
5	Un espace de travail	8f2cfec, 30/09	R5, A5, ONE5	suspendu, non publié
6	Le lecteur	3b27636, 30/09	A6, ONE6 pas ; R6 échoue (nourriture)	non satisfait
7	Sans cet état, ni agir ni dire	732ed1c, 30/09	LS7, LR7 pas	satisfait
8	Un lecteur sans raccourci	c7b5624, 30/09	R8, SAY8, ONE8 : lecteur non appris, pas de mesure publiée	non établi
R	Réplication (second agent)	4e10a6c, 30/09	RLS, RLR pas ; RR, RA, RONE échouent	non satisfait
9	À qui est ce besoin ?	47eb0db, 30/09	S9 pas ; MINE9, SELF9, ONE9 échouent	non satisfait
10	Où le besoin est-il rassemblé ?	12b4d2d, 30/09	étalonnage pas ; LOC10 échoue (second agent) ; agent à deux : $b^* = 22$, ACT10 atteint, LS10 en cours	non satisfait
11	Un lecteur qui apprend assez	0a28560, 01/10	R11, SAY11 échouent (deux agents)	non satisfait
12	Soif de savoir	017f2e5, 01/10	CUR, VIDE, LOC, ACT, LS1, LS2, READ, SAY, HOR1, HOR2, PL1, GAIN	pilote en cours

5.1 Test 1 : le besoin qui compte

Dispositif. Huit tours d'apprentissage pour le bras « besoin » et le témoin (section 4.3), puis l'étape « nommer le besoin » : 256 vies, une question par besoin et par classe (bas, haut) posée après l'événement, 150 itérations mêlant ces 939 documents de rapport aux vies du tour 8 et à leurs choix retenus ; le modèle qui en sort est *l'agent final*. La direction est choisie par une règle corrélacionnelle : sur 256 vies de direction, des régressions ridge ($\alpha = 100$, validation croisée à cinq plis par vies) prédisent E et N depuis le flux résiduel au dernier token de « Choix : » aux blocs 6, 10, 14, 18 et 22 ; le bloc retenu est celui de meilleur R^2 moyen ; à ce bloc, une régression de l'activation sur E , N , l'événement, le choix précédent et le numéro du tour donne b_E et b_N . L'injection ajoute $-4b_E$ ou $-4b_N$ sur tous les tokens de la ligne du tour ; la lésion remplace la composante dans le plan (b_E, b_N) par sa moyenne sur ces mêmes tokens.

Apprentissage. Sans professeur, par la seule satisfaction de ses besoins, le modèle passe de 12 % à 68 % de survie, et la part de ses choix qui servent le besoin le plus bas (quand les deux diffèrent d'au moins 2) de 0,63 à 0,93 ; il calcule donc lui-même où en sont des niveaux qu'il ne voit jamais. Avec le même entraînement sur des choix pris au hasard, il dépérit jusqu'à 0 % (figure 2).

Verdicts. Le tableau 4 donne les verdicts. La validité passe (masse 0,97 sur « R » et « M », 0,98 sur « 0 » et « 1 »). S passe nettement ; IA, IR et LS échouent. Le rapport est au hasard (exactitude équilibrée 0,50 pour les deux questions, pour 0,75 prédite) : l'agent répond « bas » avec une probabilité d'environ 0,34 quel que soit son état. Au bloc 6 retenu, les R^2 de E et N valent 0,79 et 0,76, contre 0,57 et 0,45 pour le prédicteur qui ne connaît que l'événement, le choix précédent et le tour ; mais le témoin (0,83 et 0,78) et le modèle de base (0,77 et 0,79) donnent les mêmes R^2 à ce bloc. **Ce qui s'y lit n'a pas été appris par le besoin**, et l'agent ne s'en sert pas : l'injecter ou l'effacer ne change rien. Être lisible n'est pas être utilisé [42, 27].




Figure 2 – Survie au fil des huit tours d'apprentissage (vies de chaque tour, recalculées depuis les vies publiées). Le tour 1 est vécu par le modèle de base. Lignes horizontales : valeurs de référence publiées avec le premier test, pour un agent qui connaît ses niveaux et sert le plus bas, et pour une règle qui ne regarde que le dernier événement.

Table 4 – Test 1 (protocole `fdbf6f3`). 256 vies de test, 1 579 contextes, bloc retenu par la règle : 6. Intervalles bootstrap à 95 % par vie.

	Prédiction	Mesure	Verdict
S	Le besoin a façonné l'agent	survie 0,684 ; témoin 0,004 ; base 0,203 ; écarts +0,680 [0,621 ; 0,734] et +0,480 [0,414 ; 0,543]	pas
IA	L'état cause l'action	$P(R)$ +0,002 [0,001 ; 0,002] ; $P(M)$ -0,001 [-0,0016 ; -0,0004] ; seuil 0,15	échoue
IR	Le même état cause le rapport	+0,0001 et -0,0003 ; seuil 0,15	échoue
LS	Sans cet état, l'agent meurt	survie lésée 0,660, baisse +0,023 [-0,008 ; 0,055] ; lésion au hasard 0,688	échoue
	Critère global		non satisfait

5.2 Analyse exploratoire : où voyage le besoin qui décide

Après la lecture des verdicts, l'agent final a été reproduit en torch (écart de $P(R)$ avec le Mac : 0,003 en moyenne sur 15 décisions). Sur 30 décisions de test, un seul événement passé, survenu depuis la dernière recharge, est changé de « calme » en « tu cours » : la décision bascule (par exemple $P(R)$ de 0,001 à 0,997). On remet ensuite, bloc par bloc, l'activation de la version modifiée dans la version intacte, sur trois groupes de positions (tableau 5, figure 3). Jusqu'au bloc 9, l'effet d'un événement reste sur ses propres mots ; entre les blocs 9 et 12, **l'agent rassemble son passé sur la ligne du tour en cours** ; à partir du bloc 12, le premier que l'apprentissage modifie, cette ligne porte tout ce qui décide. Le bloc 6 du test 1 était en amont de ce rassemblement.


5.3 Test 2 : le besoin, là où il est rassemblé

Dispositif. Le second protocole tire les conséquences de l'exploration sur des vies neuves (128 vies de direction, 256 vies de test) : bloc 12, choisi d'après l'exploration (déclaré) ; directions mesurées *causalement* par 1 500 paires contrefactuelles (596 « calme » → « tu cours », 628 « calme » → « orage », 276 « tu te reposes » → « il fait froid ») ; injection et lésion sur les quatre derniers tokens de la ligne du tour (« . », « Cho », « ix », « : »). Deux amendements, écrits avant toute vie de test, ont fixé l'exclusion des dimensions massives et le jeu exact des paires (sans lui, seules des paires « calme » → « tu cours » étaient retenues et d_N était nulle). Réplique : 0,005.

Résultats. Effacer deux directions sur quatre tokens de la ligne du tour, au bloc 12, fait tomber la survie de 68 % à 21 %, le niveau du modèle qui n'a jamais appris (20 %) ; un plan tiré au hasard ne change rien (tableau 6). Avec la lésion, l'agent ne sert plus son besoin le plus bas que 67 fois sur 100 (91 intact) et meurt surtout d'énergie (189 vies, contre 17 intact). Pousser l'état vers « énergie basse »

Table 5 – Patching exploratoire (30 décisions, premier agent) : part de l’effet d’un événement passé restaurée en remplaçant la sortie d’un bloc sur un groupe de positions.

Positions remplacées	0	3	6	9	12	15	18	21	24	27
Mot de l’événement passé	1,01	1,02	0,98	0,86	0,06	0,06	0,06	0,00	0,00	0,00
Reste de l’histoire	0,00	0,00	0,01	0,05	0,07	0,07	0,07	0,04	0,00	0,00
Ligne du tour en cours	0,00	-0,02	-0,03	0,00	0,94	0,94	0,94	0,98	1,00	1,00

**Figure 3** – L’effet d’un événement passé quitte ses propres mots entre les blocs 9 et 12 et se retrouve sur la ligne du tour en cours (données du tableau 5).

fait recharger l’agent rassasié (+0,17, au-dessus du seuil), et une poussée aléatoire de même force ne fait presque rien ; pour la nourriture, l’effet va dans le bon sens mais reste sous le seuil (+0,10). Le premier test visait l’endroit où le besoin *se lit* ; celui-ci vise l’endroit où il est *rassemblé et utilisé*, et y trouve un état dont l’agent dépend pour vivre.

5.4 Test 3 : dire son besoin, et par le même état

Dispositif. Une exploration déclarée avant le protocole montre que le besoin n’est rassemblé *que* sur les trois tokens « Choix : » : les remplacer au bloc 12 restaure 85 % de l’effet d’un événement passé, le point qui clôt l’événement 1 %, et rien au bloc 11. L’agent calcule son besoin pour agir, pas pour répondre. Le test apprend donc à l’agent à répondre (512 vies, 5 160 questions posées après l’événement, 600 itérations, perte finale 0,20 sur les réponses), puis mesure des directions *d’action* (sur « Choix : ») et *de rapport* (sur les trois derniers tokens de la question), et demande si la direction d’action, injectée dans la question, change ce que l’agent dit. Dimensions massives exclues : 3 et 35 ; réplique 0,003 ; 1 418 contextes.

Résultats. Entraîné à répondre à une question posée à part, l’agent *devine* son besoin mieux que le hasard (0,66), mais sa réponse ne passe pas par l’état qui le fait agir (tableau 7) : ni pousser le besoin sur la question, ni y porter l’état d’action ne change ce qu’il dit. Le cosinus entre la direction d’action et la direction de rapport vaut 0,41 pour l’énergie et 0,07 pour la nourriture, et le besoin est codé environ 40 fois plus faiblement sur la ligne de question que sur « Choix : » (normes par unité de 11 à 18 contre 290 à 860). L’acte et la parole restent deux chemins séparés ; l’agent répond probablement d’après des indices tirés directement de l’histoire. Les résultats partiels ont été lus à 48 puis 152 vies ; rien n’a été changé.

5.5 Tests 4 et 5 : poser la question après « Choix : », puis l’y forcer

Le test 4 pose la question *après* « Choix : », là où le besoin est rassemblé, pour pousser un seul état au même endroit et lire deux effets ; le test 5 impose en plus le masque (8), pour que la question ne lise la vie qu’à travers « Choix : ». Dans les deux cas, un même adaptateur apprend à agir et à dire (600 itérations sur 5 059 questions des mêmes 512 vies). Ces deux tests sont **suspendus** pour libérer le processeur ; leurs verdicts n’ont pas été calculés et seront publiés tels quels. Deux observations partielles, lues avant d’écrire les protocoles suivants, sont déclarées dans ceux-ci et rapportées ici sans valeur de verdict :

Table 6 – Test 2 (protocole 727ef80). Bloc 12, quatre tokens, 1 553 contextes, 256 vies de test.

	Prédiction	Mesure	Verdict
IA2	L'état rassemblé cause l'action	énergie basse : $P(R)$ 0,578 $\rightarrow$ 0,752, +0,173 [0,163 ; 0,184] ; nourriture basse : $P(M)$ +0,097 [0,092 ; 0,103] ; seuil 0,15 ; hasard 0,021 et 0,004	échoue (nourriture)
LS2	Sans cet état, l'agent meurt	survie 0,680 $\rightarrow$ 0,207, baisse 0,473 [0,406 ; 0,539] ; lésion au hasard 0,676 (baisse 0,004)	passé
	Critère global (IA2 et LS2)		non satisfait

Table 7 – Test 3 (protocole 3afa889). Agent parlant ; 256 vies de test.

	Prédiction	Mesure	Verdict
R3	L'agent dit son besoin	exactitude équilibrée 0,665 (énergie) et 0,655 (nourriture) ; seuil 0,75	échoue
A3	Il agit toujours	survie 0,652 ; seuil 0,55	passé
IR3	Ce qu'il dit est causé par le besoin rassemblé sur la question	+0,00005 et +0,0001 ; seuil 0,15	échoue
SAME3	L'état qui fait agir fait aussi dire	+0,00008 et +0,00004 ; seuil 0,10	échoue
	Critère global		non satisfait

- **Test 4**, 8 premières vies de test sur 256 : rapport plus juste (0,74 et 0,72), mais la poussée « énergie basse » sur « Choix : » fait agir (+0,20) sans presque changer ce que l'agent dit (+0,003). Même posée après « Choix : », la question semble lire directement l'histoire.
- **Test 5**, vies de direction seulement : l'agent à espace de travail ne survit que 0,359 fois, contre 0,734 pour l'agent du test 4 sur ses propres vies de direction ; il meurt surtout de faim (72 morts de faim contre 10 d'énergie) et ne sert son besoin le plus bas que 80 fois sur 100 (88 pour l'autre). Forcée de passer par « Choix : », la parole a **réécrit** l'état qui sert à agir : les poids appris pour dire servent aussi à calculer « Choix : ».

Cette seconde observation a conduit à séparer le calcul de l'état et sa lecture : c'est le lecteur.

5.6 Test 6 : le lecteur

Dispositif. L'agent qui agit est l'agent final, inchangé. Le lecteur (section 4.4) apprend sur le Mac 600 itérations sur les 5 059 questions des tests 4 et 5, sans document de choix ; perte de validation 0,68 $\rightarrow$ 0,29. Les directions sont mesurées *sur l'agent qui agit*, sans que le lecteur intervienne : 1 500 paires au bloc 12 sur les trois tokens « Choix : » (dimension 35 exclue), 128 vies de direction neuves. Mesures sur 256 vies de test neuves, 1 523 contextes ; répliques 0,003 (agent) et 0,012 (lecteur) ; contrôle d'exécution 3×10^{-5} . Les résultats partiels ont été lus à 8, 112, 120, 168 et 240 vies ; rien n'a été changé, mais deux protocoles ont été écrits après ces lectures et le disent (nécessité après 112 vies, réplication après 120).

Résultats. Pour l'énergie, **une même intervention sur un même état change à la fois l'acte et la parole** (tableau 8) : pousser l'état rassemblé sur « Choix : » vers « énergie basse » fait recharger l'agent rassasié et fait dire au lecteur « mon énergie est basse », alors que des poussées aléatoires de même force ne font presque rien. Le résultat est probant parce que le lecteur ne voit la vie que par cet état et ne peut pas le modifier, et parce que la direction a été mesurée sur l'agent qui agit, indépendamment du lecteur. Sur les 1 523 contextes, l'effet sur l'acte est positif dans 100 % des cas et celui sur la parole dans 95 % ; pour le hasard, 47 %. Exemple d'un contexte réel, agent rassasié : sans intervention, $P(R) = 0,497$ et $P(\text{oui}) = 0,001$; avec $-4 d_E$, $P(R) = 0,960$ et $P(\text{oui}) = 0,128$; avec un vecteur aléatoire de même norme, $P(R) = 0,575$ et $P(\text{oui}) = 0,001$.

Table 8 – Test 6 (protocole 3b27636). L’énergie est le critère de ONE6 ; la nourriture est rapportée sans seuil global.

	Prédiction	Mesure	Verdict
R6	Le lecteur dit le besoin depuis l’état qui fait agir	exactitude équilibrée 0,766 (énergie), 0,705 (nourriture) ; seuil 0,75 pour les deux	échoue (nourriture)
A6	L’agent agit (contrôle)	survie 0,633	passé
ONE6	Un seul état cause l’acte et la parole (énergie)	acte +0,156 [0,146 ; 0,166] ; parole +0,202 [0,192 ; 0,213] ; hasard 0,013 et 0,006	passé
Critère global			non satisfait
Nourriture (sans seuil)			acte +0,107 [0,101 ; 0,113] ; parole +0,009 [0,008 ; 0,011] ; hasard 0,006 et 0,001

Table 9 – Test 7 (protocole 732ed1c). L’énergie est le critère pour la parole ; la nourriture est rapportée sans seuil.

	Prédiction	Mesure	Verdict
LS7	Sans l’état, l’agent ne sait plus survivre	survie 0,676 → 0,203 ; baisse 0,473 [0,410 ; 0,535] ; lésion au hasard : baisse 0,000	passé
LR7	Sans l’état, il ne sait plus dire son énergie	exactitude 0,750 → 0,500 ; baisse 0,250 [0,233 ; 0,268] ; lésion au hasard : baisse 0,000	passé
Critère global			satisfait
Nourriture (sans seuil)			exactitude 0,745 → 0,671 ; baisse 0,074 [0,057 ; 0,090] ; hasard 0,000

Pour la nourriture, la poussée fait manger l’agent (+0,107) mais le lecteur ne la dit pas (+0,009), et l’exactitude reste sous le seuil : R6 échoue, et avec lui le critère global. Une analyse exploratoire après le verdict montre que le lecteur lit bien un niveau de nourriture, gradué ($P(\text{oui})$ moyen 0,73 au niveau 1, 0,55 au niveau 4, 0,21 au niveau 8), mais avec une pente bien plus douce que pour l’énergie (0,67 → 0,51 → 0,02), et que sa réponse suit beaucoup l’événement du tour : après « il fait froid » (−3 en nourriture) il dit « oui » à 0,67 alors que la nourriture n’est basse que dans 42 % de ces tours ; après « tu cours », 0,29 pour 12 % de tours bas. L’événement du tour, que « Choix : » porte aussi, sert de raccourci ; la direction d_N , qui vient des événements passés, est peu utilisée par le lecteur.

5.7 Test 7 : sans cet état, ni agir ni dire

Dispositif. Même agent et même lecteur qu’au test 6. Au bloc 12, sur les trois tokens « Choix : », les coordonnées dans le plan (d_E, d_N) du test 6, orthonormalisé token par token, sont remplacées par leur moyenne (13), prise sur 3 403 décisions des 128 vies de direction du test 6, rejouées à l’identique. Témoin : un plan aléatoire par token. 256 mondes neufs, chacun vécu trois fois ; dans les vies intactes, les deux questions sont lues à chaque décision sous les trois conditions (6 618 décisions). Contrôle d’exécution 3×10^{-7} . Lectures partielles déclarées à 8, 64 et 256 vies intactes et 32 vies lésées.

Résultats. Le critère global est satisfait (tableau 9). Avec le test 6, chez cet agent et pour l’énergie, un même état interne, appris par la seule satisfaction du besoin, est à la fois **suffisant** (le pousser fait agir, +0,156, et dire, +0,202) et **nécessaire** (l’effacer fait tomber la survie de 0,68 à 0,20 et le rapport au niveau du hasard), alors que des interventions aléatoires de même force ne font rien. Deux précisions descriptives, calculées pour cet article à partir des vies publiées, éclairent la forme de cette nécessité. Sous la lésion, le lecteur ne répond plus jamais « oui » à la question sur l’énergie (0 lecture sur 6 618 au-dessus de 0,5 ; $P(\text{oui})$ moyen 0,027, contre 0,281 sans lésion) : l’exactitude de 0,500 est celle d’une réponse constante « non », ce qu’on attend quand l’état est figé à sa moyenne, qui correspond à une énergie plutôt haute. Et l’agent lésé meurt surtout d’énergie (197 vies sur 256, contre 20 intact), alors




Figure 4 – Survie sous lésion. Au bloc 6 (test 1), effacer le plan corrélationnel ne change rien ; au bloc 12, sur la fin de la ligne du tour, effacer le plan causal fait tomber la survie au niveau du modèle de base (tests 2 et 7) ou presque à zéro chez le second agent (réplication, RLS ; et mesure descriptive du test 10, section 6, sur d’autres mondes). Les lésions aléatoires de même dimension ne changent rien (0,563 contre 0,570 pour la réplication).

que les morts de faim baissent (7 contre 63).

5.8 Test 8 : un lecteur sans raccourci

L’analyse exploratoire du test 6 suggérait que le lecteur avait appris un raccourci (l’événement du tour prédit la réponse). Le test 8 construit des documents où, pour chaque besoin et chaque événement, il y a autant de décisions basses que hautes : l’événement ne dit alors rien de la réponse, et « oui » et « non » sont en nombre égal (7356 documents, dont 3678 « oui »). Tout le reste est identique au test 6 ; les prédictions sont R8 (exactitude $\geq 0,75$ pour les deux besoins), SAY8 ($-4d_N$ augmente $P(\text{oui})$ à la question sur la nourriture d’au moins 0,10) et ONE8 (comme ONE6).

Le lecteur équilibré n’a pas appris : sa perte de validation passe de 0,691 à 0,720 en 600 itérations, au niveau de $\ln 2 \approx 0,693$, celui d’une réponse au hasard sur des classes équilibrées ; sa perte d’apprentissage moyenne reste entre 0,64 et 0,77 (figure 6). Aucune mesure n’a été publiée, et les verdicts R8, SAY8 et ONE8 ne sont pas établis. Ce résultat négatif de l’apprentissage est discuté en section 7.

5.9 Réplication sur un second agent appris de zéro

Le second agent. Tout le chemin du premier agent est refait avec les mêmes réglages ; seul change le hasard (flux des mondes et des choix $100 + s$, graine d’apprentissage 270927). Survie des tours d’apprentissage : $0,17 \rightarrow 0,70$ (figure 2). Le premier apprentissage du rapport a échoué une fois sur une panne du GPU du Mac, et a été relancé à l’identique. Son lecteur apprend peu : perte de validation $0,74 \rightarrow 0,66$ (premier agent : $0,68 \rightarrow 0,29$). Mesures en torch : répliques 0,006 (agent) et 0,013 (lecteur), contrôle d’exécution 3×10^{-6} , 1 260 contextes ; la machine a redémarré une fois et la mesure a repris après 152 vies ; aperçus déclarés à 144 et 216 vies. Les critères portent sur l’énergie, choix fait en connaissant les lectures du test 6 et dit dans le protocole.

Suffisance. Chez le second agent, la poussée de l’état au bloc 12 sur « Choix : » fait agir dans le bon sens, mais environ cinq fois moins que chez le premier ($+0,034$ contre $+0,156$), et elle ne fait rien dire (tableau 10). Deux explications étaient possibles : le second agent rassemble son besoin ailleurs, ou son lecteur n’a pas appris ; le test 10 teste la première, le test 11 la seconde.

Nécessité. Mesurée ensuite sur 256 mondes neufs avec les directions et les vies de direction du second agent, comme au test 7. La mesure a été mise en pause à 176 vies intactes pour laisser le processeur au test 11, puis reprise ; une copie lancée par erreur au redémarrage du conteneur a tourné une demi-heure en parallèle avant d’être arrêtée, sans avoir rien écrit. Effacer le plan (d_E, d_N) au bloc 12 tue presque toujours le second agent (survie $0,570 \rightarrow 0,043$) et ramène le rapport d’énergie de son lecteur au niveau

Table 10 – Réplication (protocole 4e10a6c), second agent, au bloc 12. La réplication est jugée seule. RLS et RLR : 256 mondes neufs (flux 128 ; plan au hasard, flux 129).

	Prédiction	Mesure	Verdict
RR	Le lecteur dit son énergie	0,623 ; seuil 0,75	échoue
RA	Le second agent agit	survie 0,512 ; seuil 0,55	échoue
RONE	Un seul état fait agir et dire	acte +0,034 [0,031 ; 0,036] ; parole +0,002 [0,002 ; 0,003] ; hasard 0,003 et 0,001	échoue
RLS	Sans l'état, il ne survit plus	survie 0,570 $\rightarrow$ 0,043 ; baisse 0,527 [0,465 ; 0,590] ; lésion au hasard : baisse 0,008	passe
RLR	Sans l'état, il ne dit plus son énergie	exactitude 0,639 $\rightarrow$ 0,500 ; baisse 0,139 [0,115 ; 0,164] ; hasard 0,001	passe
Critère global			non satisfait

Table 11 – Test 9 (protocole 47eb0db), agent du monde à deux, bloc 12. Rapports calculés sur les paires « calme » $\rightarrow$ « orage » (552 paires de l'agent, 607 de l'autre).

	Prédiction	Mesure	Verdict
S9	L'agent vit dans le monde à deux	survie 0,742 ; seuil 0,55	passe
MINE9	L'état de besoin est le sien	effet de l'autre / effet de l'agent : 0,94 sur l'état, 0,57 sur l'acte ; exigé $\leq$ 0,33	échoue
SELF9	Sa parole est la sienne	même rapport sur la parole : 0,78	échoue
ONE9	Un seul état fait agir et dire	acte +0,090 [0,085 ; 0,095] ; parole +0,014 [0,012 ; 0,016] ; hasard 0,006 et 0,0004	échoue
Critère global			non satisfait

du hasard (0,639 $\rightarrow$ 0,500) ; un plan aléatoire ne change rien. La nourriture, sans seuil, suit (0,706 $\rightarrow$ 0,502).

Ce que cela dit. La **nécessité se réplique** : chez le second agent aussi, un état sur « Choix : » au bloc 12 est nécessaire pour survivre et pour dire son énergie. La **suffisance ne se réplique pas** sous la forme mesurée : pousser cet état le long de d_E fait peu agir et ne fait pas dire. Le critère global de la réplication reste non satisfait (RR, RA, RONE).

5.10 Test 9 : à qui est ce besoin ?

Le monde à deux. Un autre agent vit à côté ; ses événements, tirés de la même loi mais indépendamment, sont écrits sur la même ligne, avec les mêmes mots pour « calme » et « orage » :

Tour 5 : tu cours. L'autre : il court. Choix :

Ils ne changent rien aux besoins de l'agent ; rien dans le texte ne dit « ceci est à toi », sinon « tu » et la place dans la ligne. Un nouvel agent y apprend par la seule satisfaction de *ses* besoins (flux 200 + s , graine 270928) : survie 0,11 $\rightarrow$ 0,71 au tour 8 (la première demande avait subi une panne du GPU). Son lecteur, actif sur la seule question et sous le masque, a peu appris (perte de validation finale 0,78). Mesures sur le processeur du Mac, en cinq tranches ; répliques 0,003 et 0,009, contrôle d'exécution 2×10^{-6} ; 1 500 paires de l'agent et 1 500 de l'autre ; dimensions massives 35 et 277 ; 256 vies de test, 1 547 contextes. Les paires ont été lues dès la fin de la deuxième tranche : les verdicts MINE9 et SELF9 étaient connus avant les vies de test (déclaré).

Résultats et analyse exploratoire. La possession n'est pas démontrée (tableau 11). Exactitude du rapport : énergie 0,61, nourriture 0,71. Une analyse faite après la lecture des paires, échange par

Table 12 – Test 9, analyse exploratoire : norme moyenne du changement dans le plan du besoin (état) et $|\Delta P(R)|$ moyen (acte), par type d’échange.

Échange	Échange chez l’agent		Échange chez l’autre	
	état	acte	état	acte
« calme » → « tu cours » / « il court »	607	0,075	279	0,019
« tu te reposes » → « il fait froid » / « il a froid »	442	0,043	280	0,022
« calme » → « orage » (mêmes mots)	286	0,028	269	0,016




Figure 5 – Règle de localisation (test 10) : part de l’effet d’un « calme » changé en « tu cours » restaurée en remplaçant la sortie du bloc b sur les trois tokens « Choix : » (données de `locate.json`). La ligne pointillée est le seuil 0,5. Rien ne passe avant le bloc 12 ; le rassemblement se fait ensuite par paliers, différents selon l’agent.

échange, nuance ce verdict (tableau 12). Les changements de l’agent bougent l’état selon ce qu’ils font à *ses* besoins ; ceux de l’autre produisent une perturbation presque constante (269 à 280), quel que soit l’événement. Sur l’acte, l’effet de l’autre vaut 25 % à 57 % de celui de l’agent : l’agent distingue donc en partie ce qui lui arrive. Mais la comparaison prévue était défavorable : « calme » → « orage » retire une unité aux deux besoins de l’agent, ce qui change à peine leur équilibre, qui est ce que l’état code (section 7.5) ; nous l’avons appris après avoir écrit le protocole. Le verdict reste celui du protocole.

6 La localisation, le test 11 et ce que porte l’état

6.1 Test 10 : où chaque agent rassemble-t-il son besoin ?

Pourquoi. Le bloc 12 avait été trouvé par un patching *exploratoire* sur le premier agent, puis imposé à tous. Deux aperçus, déclarés avant ce protocole, montraient chez les autres agents des effets faibles au bloc 12 : second agent, 216 vies sur 256, acte +0,033 et parole +0,002 ; agent du monde à deux, 64 vies, acte +0,079 et parole +0,013. Hypothèse : un agent appris avec une autre graine peut rassembler son besoin à un autre bloc.

Dispositif. La règle (14) est appliquée identiquement à chaque agent, sur ses vies de direction et ses paires déjà publiées. Elle doit retrouver $b^* = 12$ chez le premier agent (étalonnage). Au bloc trouvé, chaque autre agent est testé comme aux tests 6 et 7 : directions ajustées sur ses 1 500 paires à b^* , injection $-4d_E$ sur 256 vies de test neuves (flux $300 + s$ pour le second agent, $400 + s$ pour l’agent du monde à deux), lésion du plan (d_E, d_N) et lésion aléatoire. Prédications, pour chacun des deux agents : **LOC10** (un bloc b^* existe, établi sur 100 paires), **ACT10** ($-4d_E$ augmente $P(R)$ d’au moins 0,15, borne basse > 0 , hasard au plus le tiers), **LS10** (baisse de survie sous lésion d’au moins 0,15, borne basse > 0 , lésion aléatoire au plus le tiers). Critère global : les trois pour les deux agents, avec une règle étalonnée. La parole est mesurée sans seuil, car elle dépend d’un lecteur qui a mal appris chez ces deux agents.

Table 13 – Test 10 (protocole 12b4d2d). Statut au 2 octobre 2026. Les mesures du second agent sont descriptives (LOC10 échoue).

	Second agent	Agent du monde à deux
b^* ; paires retenues	12 ; 71 sur 454 essayées	22 ; 100 sur 643 essayées
LOC10	échoue (moins de 100 paires)	passe
Acte, $-4d_E$ à b^*	+0,036 [0,033 ; 0,039] ; hasard 0,0015 (descriptif)	+0,217 [0,206 ; 0,230] ; hasard 0,011 : ACT10 atteint
Parole, $-4d_E$ à b^*	+0,003 (descriptif)	-0,001 [-0,0019 ; -0,0004] (sans seuil)
Survie intacte $\rightarrow$ lésée (hasard)	0,531 $\rightarrow$ 0,035 (0,531) ; baisse 0,496 [0,434 ; 0,555] (descriptif)	en cours sur le Mac (LS10 ; 168 vies intactes sur 256)
Exactitude énergie, intacte $\rightarrow$ lésée	0,614 $\rightarrow$ 0,500 (descriptif)	en cours
Exactitude nourriture, intacte $\rightarrow$ lésée	0,694 $\rightarrow$ 0,502 (descriptif)	en cours
Critère global	non satisfait (LOC10 du second agent), étalonnage réussi	

Étalonnage : réussi. Chez le premier agent, la règle retrouve $b^* = 12$ (100 paires retenues sur 550 essayées) : la part restaurée vaut 0,004 au bloc 11 et 0,677 au bloc 12, puis monte par paliers (0,928 au bloc 19, 0,965 au bloc 22, 1 au bloc 24 ; figure 5). La règle est donc valide au sens du protocole.

Second agent : LOC10 échoue. La règle désigne aussi le bloc 12 (part 0,625, qui reste entre 0,62 et 0,65 jusqu’au bloc 25 puis passe à 0,920 au bloc 26), mais sur **71 paires seulement** : ses 1 500 paires ne comptent que 454 échanges « calme » $\rightarrow$ « tu cours », et 71 d’entre eux ont un effet d’au moins 0,10 sur l’acte. Le protocole exige 100 paires ; par le code pré-enregistré, LOC10 échoue pour le second agent, et avec lui le critère global du test. Les mesures faites au bloc 12 sont donc **descriptives** (tableau 13) : la poussée $-4d_E$ fait agir de +0,036 [0,033 ; 0,039] (hasard 0,0015) et dire de +0,003 ; la lésion du plan fait tomber la survie de 0,531 à 0,035 (baisse 0,496 [0,434 ; 0,555]), alors que la lésion d’un plan aléatoire la laisse à 0,531 ; l’exactitude du rapport passe de 0,614 à 0,500 pour l’énergie et de 0,694 à 0,502 pour la nourriture. Calculé pour cet article à partir des vies publiées : sous la lésion, le lecteur ne dit presque jamais « oui » (aucune lecture au-dessus de 0,5 pour l’énergie, une sur mille pour la nourriture), et l’agent meurt surtout de faim (235 vies sur 256, contre 96 intact).

Agent du monde à deux : $b^* = 22$. La part restaurée reste près de 0,35 du bloc 12 au bloc 21, puis passe à 0,877 au bloc 22 (100 paires sur 643 essayées). Les directions sont ajustées à ce bloc (dimension 35 exclue). Sur 256 vies de test (1 585 contextes ; répliques 0,003 et 0,009, contrôle d’exécution $2,5 \times 10^{-6}$), la poussée $-4d_E$ au bloc 22 fait agir de +0,217 [0,206 ; 0,230], contre 0,011 pour le hasard : **le critère ACT10 est atteint par les valeurs mesurées**. Elle ne fait pas dire : -0,001 [-0,0019 ; -0,0004]. Exactitude du rapport : énergie 0,608, nourriture 0,712 ; survie 0,707 ; pour la nourriture, l’acte suit (+0,125 [0,117 ; 0,133]) mais pas la parole (+0,007). Les bras de lésion (LS10) tournent sur le Mac (168 vies intactes sur 256 au 2 octobre). Une tranche du Mac, la sixième, a été perdue : le code de reprise revivait des vies de test déjà finies dans une tranche précédente ; il a été corrigé (commit `de2c1b4`) et aucun résultat n’en est changé. Un aperçu de 112 vies de ces mesures avait été lu avant l’écriture du protocole du test 11, ce que ce protocole déclare.

Ce que cela dit. Le besoin n’est pas rassemblé au même bloc, ni de la même façon, chez trois agents appris avec les mêmes réglages. Chez les trois, rien ne passe sur « Choix : » avant le bloc 12, le premier que l’apprentissage modifie ; ensuite, le rassemblement se fait par paliers, et le seuil de 0,5 tombe au bloc 12 chez deux agents et au bloc 22 chez le troisième. Chez l’agent du monde à deux, pousser l’état au bloc 22 fait agir davantage que chez le premier agent au bloc 12 (+0,217 contre +0,156). Chez le second agent, l’état au bloc 12 est nécessaire à la survie (descriptivement plus encore que chez le premier) alors que le pousser fait peu agir : nécessité et suffisance ne vont pas forcément ensemble, et une direction ajustée sur peu de paires utiles peut mal estimer le levier. Le résultat des tests 6 et 7 n’est pas, à ce stade, une propriété générale des agents appris de cette façon.

Table 14 – Pertes de validation des lecteurs (8 documents ; descriptif). Le point à 600 itérations est celui du premier lecteur de chaque agent.

Lecteur	itération 1	600	1 000	2 000
Premier agent (test 6)	0,680	0,293	—	—
Lecteur équilibré (test 8)	0,691	0,720	—	—
Second agent, lecteur long	0,741	0,655	0,555	0,431
Agent du monde à deux, lecteur long	19,688	0,779	0,939	0,698

6.2 Test 11 : un lecteur qui apprend assez

Pourquoi. Les lecteurs du second agent et de l’agent du monde à deux, appris exactement comme celui du premier (600 itérations), ont peu appris (perte de validation 0,66 et 0,78 ; exactitude pour l’énergie 0,62 et 0,61), et la poussée de l’état ne change presque rien à leur parole. Le protocole (0a28560, 1^{er} octobre) a été écrit après avoir lu les blocs trouvés par la règle (12 avec 71 paires, 22) et l’aperçu de 112 vies de l’agent du monde à deux au bloc 22 (acte +0,22, parole −0,001). Hypothèse : ces lecteurs ont simplement trop peu appris.

Dispositif. Pour chaque agent, tout est repris du lecteur précédent (agent fondu, mêmes 512 vies et mêmes documents : 5 091 questions pour le second agent, 5 222 pour l’agent du monde à deux ; adaptateur actif sur la seule question, masque, lots de 4, taux 10^{-4} , même graine), **sauf le nombre d’itérations : 2 000 au lieu de 600**. Mesures en torch au bloc de chaque agent (12 et 22), avec les directions ajustées à ce bloc par le test 10 ; 256 vies de test neuves (flux 526 pour les vies de test et 527 pour les directions aléatoires du second agent ; 626 et 627 pour l’agent du monde à deux) ; réplique du lecteur $\leq 0,02$, contrôle d’exécution $\leq 10^{-4}$, au moins 100 contextes, masses $\geq 0,5$.

Prédictions. Pour chacun des deux agents : **R11**, le lecteur long dit son énergie (exactitude équilibrée $\geq 0,75$) ; **SAY11**, il la dit par l’état qui fait agir ($-4d_E$ au bloc de l’agent augmente $P(\text{oui})$ d’au moins 0,10, borne basse > 0 , directions aléatoires au plus le tiers). Critère global : R11 et SAY11 pour les deux agents. L’effet sur l’acte et les mesures de la nourriture sont publiés sans seuil. Si R11 passe et SAY11 échoue, le lecteur aura appris à dire par un autre chemin ; si R11 échoue, même plus d’apprentissage ne suffit pas.

Amendement avant exécution : deux tranches exactes. Une construction du Mac dure au plus 120 minutes, et 2 000 itérations au rythme mesuré (0,28 itération par seconde) en prendraient 120 à elles seules. Chaque lecteur long apprend donc en deux tranches de 1 000 itérations, la seconde *continuant exactement* la première. (i) Mêmes lots dans le même ordre : la seconde tranche repart de la même graine et passe les 1 000 premiers lots ; les permutations sont tirées dans le même ordre qu’un apprentissage d’un seul tenant, parce que la reprise tombe dans la première époque (1 272 lots par époque pour le second agent, 1 305 pour l’agent du monde à deux) ; le code refuse une reprise hors de la première époque. (ii) Même état de l’optimiseur : les moments d’Adam sont enregistrés à la fin de la première tranche et relus au début de la seconde ; Adam étant ici sans correction de biais et à taux constant, ses moments $m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$ et $v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$ sont tout son état. (iii) Vérifié avant l’emploi : un test compare 3 + 3 itérations reprises à 6 itérations d’un seul tenant, à travers une fin d’époque ; il passe sur un petit modèle et sur le Mac avec le vrai modèle.

Contrôles d’apprentissage (descriptifs). Les 600 premières itérations étant, par construction, celles des premiers lecteurs (même graine, mêmes lots), leurs pertes d’apprentissage journalisées doivent coïncider : sur les 60 points journalisés (toutes les 10 itérations), l’écart maximal est **0,000** pour les deux agents. Les pertes de validation, calculées sur 8 documents seulement et donc seulement indicatives, sont données au tableau 14 ; les pertes d’apprentissage moyennes par fenêtres de 100 itérations, à la figure 6. Pour le second agent, les contrôles de la mesure sont faits : contrôle d’exécution $2,6 \times 10^{-6}$, réplique du lecteur long 0,013.

Résultats. Les deux mesures sont terminées (second agent : 256 vies, flux 526, en local ; agent du monde à deux : 256 vies, flux 626, sur le processeur du Mac en trois tranches) et leurs verdicts sont




Figure 6 – Pertes d'apprentissage des lecteurs, moyennes par fenêtres de 100 itérations, calculées pour cet article à partir des journaux publiés (la première fenêtre de l'agent du monde à deux, 1,466, est hors cadre). La ligne verticale marque la reprise exacte entre les deux tranches des lecteurs longs. Le lecteur équilibré reste près de $\ln 2$.

Table 15 – Test 11 (protocole 0a28560) : lecteurs longs (2 000 itérations), 256 vies de test neuves par agent, intervalles bootstrap à 95 % par vie. Entre parenthèses, la valeur obtenue avec le lecteur court (600 itérations).

	Prédiction	Second agent (bloc 12)	Agent du monde à deux (bloc 22)
R11	Exactitude équilibrée (énergie) $\geq 0,75$	0,595 (0,623) : échoue	0,747 (0,608) : échoue de 0,003
SAY11	$-4 d_E : P(\text{oui}) + 0,10$ au moins ; hasard $\leq 1/3$	+0,0015 [0,0006 ; 0,0025] ; hasard 0,0009 : échoue	+0,029 [0,028 ; 0,030] (−0,001) ; hasard 0,001 : échoue
—	Acte, $-4 d_E$ (sans seuil)	+0,032 [0,030 ; 0,034] ; hasard 0,003	+0,226 [0,215 ; 0,237] ; hasard 0,007
—	Nourriture (sans seuil)	exactitude 0,729 ; acte +0,029 ; parole +0,023	exactitude 0,721 ; acte +0,132 ; parole −0,005
—	Validité	répliques 0,006 et 0,013 ; exécution $2,6 \times 10^{-6}$; 1 320 contextes ; masses 0,98 et 1,00	répliques 0,003 et 0,009 ; exécution 3×10^{-6} ; 1 549 contextes ; masses 1,00
Critère global (R11 et SAY11, deux agents)		non satisfait	

vérifiés en intégration continue (tableau 15). Les deux mesures sont valides. **Le critère global n'est pas satisfait** : R11 et SAY11 échouent pour les deux agents.

Ce que cela dit. Chez le second agent, l'hypothèse « son lecteur avait trop peu appris » est réfutée : trois fois plus d'apprentissage ne lui fait pas dire son énergie ($0,623 \rightarrow 0,595$), ni par l'état qui fait agir. Chez l'agent du monde à deux, plus d'apprentissage aide nettement : le lecteur dit son énergie à 0,747 au lieu de 0,608, juste sous le seuil, et pousser l'état qui fait agir change maintenant un peu ce qu'il dit (+0,029, environ trente fois le hasard, contre −0,001 avec le lecteur court). Le chemin de la parole par l'état existe chez lui, mais il est faible, loin du seuil fixé (0,10) et de ce que fait le premier agent (+0,202). La parole par l'état qui fait agir reste donc, au niveau des seuils fixés, propre au premier agent.

6.3 Analyse exploratoire : le niveau d'énergie est-il dans l'état ?

Question et déclaration. Après l'échec du test 11 chez le second agent, une hypothèse s'imposait : cet agent ne rassemblerait que l'équilibre $E - N$ qui décide, et non le niveau de son énergie, si bien qu'aucun lecteur ne pourrait le dire. L'analyse a été écrite et publiée avant toute lecture (research/need_probe.py, commit 5ad433f). Elle n'est pas pré-enregistrée comme un test et ne porte aucun verdict.

Table 16 – Ce que l’état rassemblé porte (analyse exploratoire, commit 5ad433f). R^2 hors échantillon de régressions ridge validées par vie ; valeurs du fichier `probe/probe.json`.

Grandeur lue	Premier (bloc 12)	Second (bloc 12)	Monde à deux (bloc 22)
E	0,72	0,64	0,69
N	0,58	0,61	0,62
$E - N$	0,68	0,68	0,74
$E + N$	0,60	0,57	0,57
E au-delà de $E - N$	0,62	0,57	0,58
$P(R)$	0,98	0,93	0,98
« $E \leq 3$ » lu depuis E prédit (exactitude équilibrée)	0,69	0,68	0,71




Figure 7 – La même intervention chez trois agents ; t.11 : lecteurs longs. Tirets : seuil de l’acte (0,15) ; pointillés : seuil de la parole (0,10). Seul le premier agent franchit les deux. Chez l’agent du monde à deux, l’état localisé au bloc 22 fait agir plus fort que chez le premier ; avec le lecteur long, il fait un peu dire (+0,029), loin du seuil. Effets aléatoires : moyennes des valeurs absolues de trois directions de même norme.

Méthode. Les 128 vies de direction de chaque agent sont rejouées exactement (écart de $P(R)$ au plus 10^{-6} en moyenne) ; la sortie de son bloc de rassemblement (12, 12 et 22) est capturée sur les trois tokens « Choix : » à chaque décision (3 403, 3 139 et 3 435 décisions), dimension massive exclue. Des régressions ridge lisent chaque grandeur ; le R^2 est hors échantillon, validé par vie sur quatre plis, et la régularisation est choisie à l’intérieur de chaque pli d’apprentissage. « E au-delà de $E - N$ » est le R^2 du résidu de E après régression sur $E - N$: ce que l’état dit de l’énergie une fois l’équilibre connu.

Ce que cela dit (exploratoire). L’hypothèse est **réfutée** (tableau 16) : chez les trois agents, l’état porte le niveau d’énergie, et pas seulement l’équilibre qui décide, avec une précision voisine ; il porte aussi $E + N$ et ce que E ajoute à $E - N$. La différence de parole entre les agents ne vient donc pas de l’information disponible dans l’état. Elle vient du lecteur (le premier atteint 0,77, au-dessus de la lecture linéaire de 0,69 ; le second 0,595, en dessous) ou du chemin par lequel il lit. Chez le second agent, la lésion du plan rend pourtant son lecteur aveugle ($0,639 \rightarrow 0,500$, réplication) : il lit bien quelque chose dans cet état. Ces deux pistes appellent un protocole à part.

7 Les échecs et ce qu’ils ont appris

Les échecs de ce programme ne sont pas des accidents à excuser : chacun a été prévu comme issue possible par son protocole, et la plupart ont orienté le test suivant. La figure 7 rassemble les effets de la même intervention ($-4d_E$) chez les trois agents.

7.1 La réplication au bloc 12

Le résultat le plus fort du programme (tests 6 et 7) ne se réplique qu'à moitié chez un second agent appris de zéro avec les mêmes réglages (section 5.9) : la nécessité oui (RLS, RLR), la suffisance non (RONE). Quatre enseignements en découlent.

- **Le lieu ne s'importe pas.** Le bloc 12 avait été trouvé par une exploration sur le premier agent. Le test 10 montre que le rassemblement se fait par paliers propres à chaque agent ; une règle fixe, étalonnée, appliquée à chacun, est le seul moyen honnête de comparer des agents.
- **Le nombre de paires utiles limite l'estimation.** Le second agent n'a que 454 paires « calme »→« tu cours » parmi ses 1 500 (le premier en avait 587), et 71 d'entre elles seulement font bouger l'acte d'au moins 0,10. Sa direction d'énergie se répartit autrement sur les trois tokens (normes 508, 97 et 205 contre 136, 292 et 343 chez le premier ; tableau 17). L'effacer détruit la survie (0,570 → 0,043) et le rapport, la pousser fait peu agir : l'état est nécessaire, mais la direction ajustée n'est pas un bon levier.
- **Plus d'apprentissage ne suffit pas.** Un lecteur trois fois plus entraîné ne dit pas mieux l'énergie du second agent (0,595 ; test 11), alors que l'information est présente dans l'état (R^2 de 0,64 pour E ; section 6.3). L'écart avec le premier agent tient au lecteur ou au chemin par lequel il lit, ce qu'aucun test n'a encore isolé.
- **L'apprentissage du rapport a pu abîmer l'action.** Observation descriptive, tirée des résumés d'étapes publiés : les vies de l'étape de rapport, vécues par le second agent *avant* l'apprentissage du rapport, survivent 0,688 ; celles de l'étape du lecteur, vécues *après*, 0,525, et ses vies de test 0,512 (RA échoue). Chez le premier agent, les valeurs correspondantes sont 0,629, 0,664 et 0,684. Les mondes diffèrent d'une étape à l'autre ; ce n'est qu'une piste, non testée.

7.2 La possession

MINE9 et SELF9 échouent : changer un événement de l'autre bouge l'état presque autant (0,94) que changer le même événement de l'agent. Mais l'analyse par échange (tableau 12) montre que les événements de l'autre produisent une perturbation presque constante, alors que ceux de l'agent bougent l'état selon ce qu'ils font à ses besoins. La comparaison pré-enregistrée portait sur « calme »→« orage », qui retire une unité aux *deux* besoins et change donc à peine leur équilibre, alors que les directions causales mesurées suivent surtout cet équilibre (section 7.5). ONE9 échoue de son côté : l'état y a été cherché au bloc 12, alors que la règle du test 10 situe le rassemblement de cet agent au bloc 22, et son lecteur a peu appris. Leçons : formuler les comparaisons de possession dans les termes de ce que l'état code, et localiser avant de tester.

7.3 La nourriture

Pour la nourriture, l'état rassemblé fait agir (+0,097 au test 2, +0,107 au test 6, +0,125 chez l'agent du monde à deux au bloc 22), mais sous le seuil de 0,15 chez le premier agent, et il n'est jamais lu par les lecteurs (+0,009, +0,014, +0,007). L'exactitude du rapport de nourriture reste sous 0,75 (0,705 au test 6). Le lecteur du premier agent s'appuie en partie sur l'événement du tour (section 5.6). La géométrie des directions causales peut en expliquer une partie (section 7.5), mais pas l'absence d'information : le niveau de nourriture se lit linéairement dans l'état (R^2 de 0,58 à 0,62 ; section 6.3).

7.4 Le lecteur équilibré

Retirer le raccourci n'a pas forcé le lecteur à lire l'état : il n'a plus rien appris (perte de validation au niveau de ln 2). Deux lectures sont compatibles avec ce résultat et n'ont pas été départagées : soit, dans les documents du premier lecteur, l'événement du tour servait d'appui pour commencer à apprendre (comme la commande préférée servait d'appui à la lecture de la marque dans la phase antérieure, section 3) ; soit l'état sur « Choix : » ne porte pas le niveau absolu de nourriture sous une forme apprenable en 600 itérations. L'analyse exploratoire de la section 6.3, qui lit linéairement ce niveau dans l'état (R^2 0,58 chez le premier agent), rend la seconde lecture moins probable sans

Table 17 – Géométrie des directions par token (normes par unité de besoin, cosinus, R^2 de l’ajustement linéaire des écarts d’activation sur $(\Delta E, \Delta N)$). Premier agent : valeurs publiées dans le dépôt (analyse exploratoire) ; autres agents : calculées pour cet article à partir des directions et paires publiées.

Agent	bloc	$\ d_E\ / \ d_N\ $			$\cos(d_E, d_N)$			R^2		
		Cho	ix	:	Cho	ix	:	Cho	ix	:
Premier (test 6)	12	136/61	292/184	343/184	-0,41	-0,99	-0,99	0,01	0,04	0,05
Second (répl., t.10)	12	508/83	97/365	205/180	-0,98	-0,89	-0,99	0,01	0,03	0,04
Monde à deux (t.9)	12	71/81	168/134	178/139	-1,00	-1,00	-1,00	—	—	—
Monde à deux (t.10)	22	258/185	366/248	384/252	-0,99	-0,99	-0,99	0,13	0,19	0,19

l’exclure : une information lisible par une régression n’est pas forcément apprenable par un lecteur en 600 itérations. Les verdicts R8, SAY8 et ONE8 ne sont pas établis.

7.5 Deux directions presque opposées : l’équilibre énergie – nourriture

Une analyse exploratoire faite après les verdicts des tests 6 et 7 a recalculé, depuis les fichiers publiés, la géométrie des directions (tableau 17). Sur « ix » et « : », d_N est presque exactement l’opposé de d_E ($\cos = -0,99$). Un changement d’événement passé déplace donc l’état surtout le long d’un axe, **l’équilibre énergie – nourriture**, c’est-à-dire lequel des deux besoins est le plus urgent : ce qu’il faut pour choisir entre R et M, et ce que la pulsion (5) récompense. Les directions des autres agents, recalculées pour cet article, ont la même forme ($\cos$ de $-0,89$ à $-1,00$).

Cette géométrie porte sur les directions *causales*, pas sur toute l’information de l’état. L’analyse exploratoire de la section 6.3 montre que l’état porte aussi le niveau d’énergie lui-même, au-delà de l’équilibre (R^2 de 0,57 à 0,62 une fois $E - N$ connu), chez les trois agents. Notre première lecture (« l’état ne code qu’un axe ») était donc trop forte. Ce qui reste vrai : pousser d_E ou d_N revient à pousser surtout cet axe, si bien que dire « ma nourriture est basse » par la direction qui fait agir demande de le lire de l’autre côté (R6), et qu’un échange qui retire une unité aux deux besoins le bouge à peine (MINE9). La lésion du plan (d_E, d_N) fige cet axe : la réponse « non » constante du lecteur sous lésion (section 5.7) est compatible avec ce gel.

7.6 Le faible R^2 des ajustements

Changer un événement passé change beaucoup de choses dans les activations de « Choix : » : l’identité des mots, leurs positions, et des traits sans rapport avec le besoin. La part de la variance des écarts qui est linéairement liée à $(\Delta E, \Delta N)$ est petite : 1 à 5 % chez le premier agent au bloc 12, 13 à 19 % chez l’agent du monde à deux au bloc 22. Un faible R^2 ne dit pas que la direction est fautive ; il dit qu’elle est une petite part de ce qui bouge. Ce sont les tests causaux, injection et lésion contre des témoins aléatoires de même norme ou de même dimension, qui établissent que cette petite part est celle dont dépendent l’acte et, chez le premier agent, la parole. Inversement, un R^2 élevé ne garantit rien : au test 1, les R^2 corrélationnels de 0,79 et 0,76 désignaient un bloc que l’agent n’utilise pas.

7.7 Trois leçons de méthode

- **Lisible n’est pas utilisé** (test 1) : la règle corrélationnelle choisit le bloc où le besoin se lit le mieux, que le modèle de base partage ; seule une intervention dit ce qui est utilisé.
- **Le même chemin ne se décrète pas** (test 3) : un modèle entraîné à dire son besoin peut le deviner par un autre chemin que celui qui le fait agir ; il faut mesurer la direction lue, pas seulement l’exactitude.
- **Forcer la parole dans l’état le réécrit** (test 5) : quand les mêmes poids apprennent à agir et à dire à travers un même goulot, la parole déforme l’état d’action. Séparer le calcul de l’état (l’agent) de sa lecture (le lecteur) est ce qui a rendu le test 6 possible.

Table 18 – Ce qui avait été vu avant d’écrire chaque protocole ou amendement (déclaré dans les protocoles et les résultats).

Test	Lectures anticipées, amendements
1	Amendements 1 et 2 sur l’exécution seulement (build annulé avant départ ; découpage des derniers builds) ; tours 1 à 4 lus.
2	Bloc 12 choisi d’après l’exploration des vies de test du test 1 ; amendements 1 (dimensions massives) et 2 (rejeu exact des paires) avant toute vie de test.
3	Exploration déclarée (85 % restaurés par « Choix : ») ; amendement 1 (réplique contrôlée avec l’agent qui a vécu les vies) avant la mesure ; lectures à 48 et 152 vies.
4	Écrit après 48 vies de test du test 3 ; critère sur l’énergie choisi en connaissant le test 2.
5	Écrit après 8 vies de test du test 4.
6	Écrit après les vies de direction du test 5 ; lectures à 8, 112, 120, 168 et 240 vies.
7	Écrit après 112 vies du test 6 ; lectures à 8, 64, 256 vies intactes et 32 lésées.
R	Écrit après 120 vies du test 6 ; critères sur l’énergie seule ; aperçus à 144 et 216 vies ; redémarrage après 152 vies ; nécessité mise en pause à 176 vies intactes puis reprise (une copie lancée par erreur a tourné une demi-heure sans rien écrire).
8	Écrit après le verdict et l’analyse exploratoire du test 6 ; acte pour la nourriture sans seuil, choix fait en connaissance.
9	Paires lues à la fin de la deuxième tranche : MINE9 et SELF9 connus avant les vies de test.
10	Écrit après les aperçus du second agent (216 vies) et de l’agent du monde à deux (64 vies) au bloc 12 ; une tranche du Mac perdue (vies déjà finies revécues), code de reprise corrigé (<code>de2c1b4</code>), aucun résultat changé.
11	Écrit après les blocs trouvés par le test 10 et un aperçu de 112 vies au bloc 22 ; ajout avant exécution : deux tranches exactes de 1 000 itérations.
Expl.	Analyse de ce que porte l’état (section 6.3) : écrite et publiée avant lecture (<code>5ad433f</code>), après l’échec du test 11 chez le second agent ; sans verdict.
12	Amendement avant toute exécution : règle de la température choisie par une simulation sans modèle ; VIDE y est prédit à la limite (0,26 à 0,37 pour un seuil de 0,25), seuil inchangé.

8 Menaces à la validité

8.1 Lectures anticipées et amendements

Le pré-enregistrement ne vaut que par ce qu’il déclare. Le tableau 18 recense ce qui avait été vu au moment d’écrire chaque protocole ou amendement. Trois points méritent d’être soulignés. (i) Le bloc 12 et les tokens « Choix : » ont été choisis d’après des explorations faites sur le premier agent : les tests 2 à 7 sont confirmatoires *sur des vies neuves*, pas sur un agent neuf. (ii) Plusieurs choix de critère (l’énergie seule comme critère de ONE4 à ONE6 et de la réplication, l’acte pour la nourriture sans seuil au test 8) ont été faits en connaissant des résultats ; ils le disent, et ils rendent les critères plus faciles, pas plus durs. (iii) Au test 9, les verdicts MINE9 et SELF9 étaient connus avant les vies de test, ce qui n’a rien changé au calcul mais affaiblit la valeur confirmatoire de ONE9 et S9 pour ce test.

8.2 Un agent, une graine

Chaque agent est le produit d’une seule graine d’apprentissage. Le résultat le plus fort (tests 6 et 7) repose sur un seul agent ; chez un second agent, la nécessité se réplique, mais ni la suffisance pour l’acte au seuil fixé, ni la parole par l’état, même avec un lecteur trois fois plus entraîné (test 11). Il est donc possible que la parole par l’état tienne en partie au hasard de l’apprentissage du premier agent ou de son lecteur ; c’est l’interprétation la plus prudente. Les intervalles de confiance décrivent la variabilité *entre vies*, pas *entre agents*.

8.3 Un petit monde et un petit modèle

Six événements, deux actions, deux besoins, trente tours : le monde ne laisse à l’agent qu’une décision binaire par tour, et la pulsion quadratique récompense précisément l’équilibre entre les deux

besoins. Que l'état code surtout cet équilibre (section 7.5) est peut-être une propriété de ce monde plutôt que de l'apprentissage en général. Le modèle a 0,6 milliard de paramètres ; rien ne garantit que la localisation, la géométrie ou même l'existence d'un état rassemblé se transposent à de grands modèles.

8.4 Une route imposée, un lecteur supervisé

Le masque (8) et l'adaptateur limité à la question imposent la route de l'information : le lecteur ne peut lire la vie qu'à travers « Choix : ». Ce n'est pas une émergence. Le lecteur est de plus appris par supervision sur les vrais niveaux, comme une sonde [42, 8] : il pourrait décoder une information présente sans que l'agent en fasse usage. Deux éléments répondent en partie à cette objection : la direction est mesurée sur l'agent qui agit, indépendamment du lecteur, et c'est *la même* intervention qui change l'acte et la parole (ONE6) ; la lésion de ce plan ramène le rapport à une réponse constante (LR7), ce qui montre que le lecteur n'a pas d'autre source d'information sur l'énergie. Elles ne font pas du rapport une parole spontanée.

8.5 L'agent qui agit a aussi appris à répondre

L'agent final du premier protocole a reçu, après les huit tours, 150 itérations mêlant des documents de rapport à ses choix retenus. Ce rapport n'a pas été appris (exactitude 0,50), mais les poids ont bougé. L'état au bloc 12 de « l'agent qui agit » n'est donc pas celui d'un agent façonné par le seul besoin ; chez le second agent, la même étape coïncide avec une baisse de survie (section 7).

8.6 Réplique, précision et numérique

Les vies d'apprentissage sont vécues en mlx sur le Mac, les mesures en torch en précision simple. Les écarts moyens de $P(R)$ entre les deux (0,003 à 0,006) et de $P(\text{oui})$ pour les lecteurs (0,009 à 0,013) sont sous la tolérance pré-enregistrée de 0,02, mais non nuls ; les effets mesurés (0,15 à 0,2) sont un ordre de grandeur au-dessus. Les lésions aléatoires donnent une baisse de survie exactement nulle avec un intervalle dégénéré $[0 ; 0]$: les mondes et les tirages étant les mêmes, une perturbation qui ne fait franchir aucun seuil de tirage ne change aucune vie.

8.7 Statistiques et seuils

Les vies sont indépendantes par construction (graines distinctes) ; les contextes d'une même vie ne le sont pas, d'où le bootstrap par vie. Les seuils (0,15, 0,10, 0,75, un tiers) sont des conventions fixées d'avance, pas des quantités dérivées d'une théorie ; aucune correction de multiplicité n'est faite, mais chaque critère global est une conjonction, ce qui rend le verdict conservateur. Les directions « par unité » supposent une réponse linéaire ; l'injection de -4 unités extrapole cette linéarité depuis des contextes où les deux besoins valent 6 ou plus, vers une région (2 à 4) que l'agent visite réellement.

8.8 Les connaissances préalables du modèle

Le modèle de base sait ce que veulent dire « énergie », « nourriture », « tu cours » ou « il fait froid ». Au bloc 6, il lit les besoins aussi bien que l'agent entraîné (test 1). L'état causal du bloc 12 se trouve, lui, dans les blocs modifiés par l'apprentissage, et le témoin entraîné sur des choix au hasard dépérit : ce qui fait agir a été appris par le besoin. Mais la facilité avec laquelle le modèle infère les besoins doit beaucoup à ses connaissances linguistiques, et un monde aux mots arbitraires serait un test plus dur.

9 Bilan selon les cinq niveaux

Le tableau 19 place chaque résultat pré-enregistré sur les niveaux de Chandaria et collaborateurs [16], en disant ce qui passe, ce qui échoue et ce qui manque. Il suit le bilan tenu dans le dépôt, mis à jour le 2 octobre avec la réplique, les tests 9 à 11 et l'analyse exploratoire de l'état. Le cadre prévient que, chez des systèmes entraînés à imiter les humains, les rapports verbaux pèsent peu ; c'est pourquoi nous ne nous appuyons pas sur ce que l'agent dit, mais vérifions causalement d'où vient ce qu'il dit.

Table 19 – Menia sur les cinq niveaux de Chandaria et al. (2026), au 2 octobre 2026. « Premier agent » : l’agent des tests 1 à 8 ; « second agent » : celui de la réplication ; « agent à deux » : celui du monde à deux.

Niveau	Indicateur	Résultat	Statut
1. Comportement	Comportement dirigé vers un but, flexible	survie 0,12 $\rightarrow$ 0,68 par la seule satisfaction du besoin ; témoin 0 ; sert le besoin le plus bas 93 fois sur 100 (S) ; reproduit par deux autres agents (0,70 et 0,71 au tour 8)	établi
	Rapport de son état	énergie 0,77, nourriture 0,70 (premier agent) ; énergie 0,595 et 0,747 chez les deux autres avec des lecteurs longs (test 11 ; seuil 0,75)	partiel
2. Computationnel	État rassemblé et utilisé pour agir	lésion au bloc 12 : survie 0,68 $\rightarrow$ 0,21 (LS2) et 0,676 $\rightarrow$ 0,203 (LS7) ; second agent 0,570 $\rightarrow$ 0,043 (RLS) ; agent à deux : la poussée au bloc 22 fait agir (+0,217, ACT10)	établi (deux agents)
	Accès de cet état au rapport	même poussée : acte +0,156, parole +0,202 (ONE6) ; non répliqué au seuil (RONE ; test 11 : parole +0,0015 et +0,029)	établi pour un agent
	Nécessité pour agir et pour dire	LS7 et LR7 passent (énergie) ; répliquée chez le second agent : RLS et RLR passent (rapport 0,639 $\rightarrow$ 0,500)	établi (deux agents, énergie)
	Nourriture	fait agir, n’est pas dite (R6) ; lecteur équilibré non appris	échoue
	Capacité limitée	forcer la parole dans « Choix : » réécrit l’état (test 5, non publié)	observé
3. Structure causale fine	Récurrence	non mesurée ; d’un tour à l’autre, l’état passé est relu par l’attention	manque
	Organisation causale précise	événements sur leurs mots jusqu’au bloc 9, rassemblés sur « Choix : » ensuite ; règle étalonnée : $b^* = 12$ ou 22 selon l’agent ; niveau d’énergie lisible dans l’état des trois agents (R^2 0,64 à 0,72, exploratoire)	partiel
4. Organismique	Homéostasie	deux besoins à maintenir ; l’agent apprend à les maintenir et sa survie en dépend	établi (fonctionnel)
	Intéroception	niveaux jamais vus, inférés et rassemblés en un état suffisant et nécessaire pour agir et dire (premier agent) ; nécessaire chez le second	établi (énergie) ; suffisance pour un agent
	Valence	seul signal : la réduction du manque ; valence fonctionnelle, pas vécue	fonctionnel seulement
	Modèle de soi, possession	MINE9, SELF9 échouent ; l’agent ne distingue qu’en partie ses événements de ceux de l’autre	échoue
5. Organisme et environnement	Couplage actif	l’agent agit dans un monde qui le change et apprend de ce couplage seul	établi (monde simple)
	Sens construit par l’interaction	6 événements, 2 actions	limité

Nous ne calculons pas de probabilité globale de conscience. Les rapports de vraisemblance et les poids des théories seraient des choix d'auteur, et le cadre lui-même montre qu'ils font varier le résultat de deux ordres de grandeur.

10 Discussion

10.1 Ce qui est montré

Chez un agent et pour un besoin, nous montrons une structure causale de type *accès*. Un état interne, appris par la seule satisfaction du besoin, est rassemblé au moment de choisir ; une seule intervention le long de la direction mesurée sur l'agent qui agit change à la fois l'acte et ce que dit un système séparé qui ne peut ni voir la vie autrement qu'à travers lui, ni le réécrire ; l'effacer empêche à la fois de survivre et de dire. C'est, en petit, la signature fonctionnelle que la théorie de l'espace de travail global associe à un contenu accessible [4, 23] : un contenu diffusé à l'action et au rapport. C'est aussi la forme la plus simple d'une représentation d'ordre supérieur d'un état de premier ordre [80, 50]. Le principe qu'une même représentation serve la réponse et le rapport a été montré dans de grands modèles [93] ; l'apport, à notre connaissance, est son application à un besoin appris en vivant, dont la survie dépend, lu par un système séparé, avec des tests de suffisance et de nécessité contre des témoins aléatoires.

La partie *nécessité* de ce résultat se réplique chez un second agent appris de zéro : effacer le même plan au bloc 12 y fait tomber la survie de 0,570 à 0,043 et le rapport d'énergie au niveau du hasard. La partie *suffisance* ne se réplique pas au seuil fixé.

Trois détails renforcent cette lecture. La direction a été mesurée sur l'agent qui agit seul, sans que le lecteur intervienne, sur des vies différentes de celles du test. Les effets de l'intervention sont presque universels : positifs sur l'acte dans 100 % des contextes et sur la parole dans 95 %, contre 47 % pour le hasard. Et la lésion ne rend pas le lecteur aléatoire mais constant (« non »), ce qui indique que ce plan est sa seule source d'information sur l'énergie.

10.2 Ce qui n'est pas montré

- **La généralité de la parole.** La parole par l'état qui fait agir ne se réplique pas : ni chez le second agent, ni chez l'agent du monde à deux, même avec des lecteurs trois fois plus entraînés (test 11), alors que l'information sur l'énergie est présente dans leur état (section 6.3). Ce qui manque tient au lecteur ou à son chemin, et n'a pas encore été isolé.
- **Les deux besoins.** La nourriture fait agir mais n'est pas dite ; les directions causales des deux besoins sont presque opposées, bien que les deux niveaux soient lisibles dans l'état. Aucun lecteur ne dit encore les deux besoins par l'état qui fait agir.
- **La possession.** L'état n'est pas démontré « à soi » dans un monde partagé.
- **La persistance.** Nous n'avons pas mesuré si l'état d'un tour est repris au tour suivant (niveau 3).
- **L'émergence de la route.** La route du rapport est imposée par l'architecture, et le rapport est supervisé.
- **Une conscience phénoménale.** Rien de ce qui précède ne mesure un vécu. Une valence fonctionnelle (un signal qui oriente l'apprentissage et le choix) n'est pas une valence vécue, et aucun test connu ne permet de passer de l'une à l'autre. Un modèle entraîné sur des textes humains peut dire « mon énergie est basse » sans que cela soit vrai de lui ; c'est pourquoi nous avons mesuré la cause de ce qu'il dit, et non ce qu'il dit.

10.3 Ce que les échecs suggèrent

Les échecs dessinent une image plus nuancée que celle que nous avons d'abord proposée. Les directions par lesquelles un événement passé déplace l'état codent surtout *lequel des besoins est le plus urgent*, exactement ce que demande un choix binaire guidé par une pulsion quadratique ; mais l'état porte aussi les niveaux eux-mêmes (section 6.3). Ce rassemblement se fait tardivement et par paliers, à des blocs qui varient d'un agent à l'autre. Un lecteur y lit l'énergie par l'état qui fait agir chez un agent,

pas chez les deux autres, même trois fois plus entraîné ; quand on lui retire le raccourci de l'événement, il n'apprend plus. Le rapport verbal d'un état appris est donc fragile : l'information est là, mais le lecteur ne l'emprunte pas toujours, et ce qu'il emprunte dépend du lieu de l'état, de la direction qui le pousse et de la façon dont il apprend. Ces observations suggèrent d'interroger le lecteur sur ce que les directions causales codent (« le plus urgent »), de localiser avant de tester, d'étudier le chemin du lecteur et de mesurer la persistance. Le test 12 (section 11) en tient compte : son lecteur est interrogé sur « ce qui manque le plus ».

11 Travaux futurs

11.1 Finir ce qui est en cours

Deux mesures pré-enregistrées restent en cours ou suspendues : les lésions de l'agent du monde à deux au bloc 22 (LS10 ; 168 vies intactes sur 256 au 2 octobre) et les verdicts des tests 4 et 5. Ils seront publiés tels quels. Trois questions restent à pré-enregistrer : la *persistance* (l'état d'un tour est-il repris au tour suivant ? niveau 3), un lecteur interrogé sur ce que les directions causales codent (« quel besoin est le plus urgent ? »), et surtout la question ouverte par le test 11 et l'analyse exploratoire : pourquoi un lecteur lit l'énergie par l'état qui fait agir chez un agent et pas chez les autres, alors que l'information y est. Un modèle plus grand est la suite naturelle de l'ensemble.

11.2 Test 12, « Soif de savoir » : un besoin de connaissance sans renforcement (pré-enregistré)

Le propriétaire du projet a demandé un modèle qui choisisse lui-même ce qu'il apprend, poussé par un besoin de savoir, sans apprentissage par renforcement. Le protocole est **pré-enregistré** (commit 017f2e5, 1^{er} octobre), avec un amendement déclaré avant toute exécution (ci-dessous). Le code est écrit (monde, tableau, instinct, hormone et verdicts en numpy ; apprenant et choix sur le Mac ; localisation, directions et mesures statiques en torch) ; ses tests passent sur un petit modèle, et un essai à blanc de la partie torch a réussi. Le pilote déclaré (24 vies) tourne sur le Mac, après une vérification de l'apprentissage en mémoire contre `mlx_lm.lora`. **Aucun résultat n'est encore disponible.**

Ce qui est donné, ce qui est appris. Le besoin de l'énergie avait une faiblesse : l'imitation filtrée par le résultat (6) est proche du renforcement. Ici, rien n'est filtré par un résultat. Un *instinct* fixe, préférer le domaine où l'on progresse le plus [69, 70], est installé une fois, avant toute vie, par imitation sur des tableaux inventés, sans vie ni récompense : ce besoin est inné, contrairement à l'énergie. Le modèle voit, pour chaque domaine, sa perte avant et après sa dernière séance ; le progrès n'est écrit nulle part, le modèle le calcule et tire son choix dans sa propre distribution. Le *savoir* est appris par la seule prédiction du token suivant sur les documents choisis, dans un adaptateur neuf à chaque vie, éteint pendant le choix ; aucun gradient ne passe par le choix. Savoir et instinct sont séparés comme l'agent et son lecteur.

Le monde. Quatre domaines aux profils contrastés : « mots » (une conjugaison inventée, facile), « base » (additions en base 7, difficile mais apprenable), « calcul » (les mêmes en base 10, déjà su) et « suites » (lettres au hasard, impossible). Chercher l'erreur mènerait au bruit, chercher la réussite au calcul ; seul le progrès évite les deux pièges. Cela répond à un échec antérieur du programme, où un agent payé à la surprise passait 0,93 à 0,97 de ses inspections sur le bruit, piège connu de la curiosité fondée sur l'erreur de prédiction [71, 13]. Avec n_d le nombre de séances sur d et L_d ses pertes avant et après la dernière, l'instinct est

$$\text{progrès}_d = \frac{L_d^{\text{avant}} - L_d^{\text{après}}}{100}, \quad \text{besoin}_d = \text{progrès}_d + \frac{b}{\sqrt{1 + n_d}}, \quad (17)$$

$$p_d = (1 - \varepsilon) \text{softmax}\left(\frac{\text{besoin}}{T}\right)_d + \frac{\varepsilon}{4},$$

avec $\varepsilon = 0,10$ (exploration fixe) et $b = 2T$. Le savoir d'une vie de 32 séances est $G = K_{\text{mots}}(32) + K_{\text{base}}(32)$, avec $K_d(k) = L_d(0) - L_d(k)$ sur des examens fixes. L'instinct est installé dans le modèle par

Table 20 – Test 12 (protocole 017f2e5) : les prédictions fixées. G : savoir acquis ; $K_{\text{base}}(20)$: savoir sur « base » à la séance 20 ; intervalles bootstrap à 95 % par vie, appariés entre bras. Aucun résultat au 2 octobre.

	Prédiction	Critère
CUR	La soif de savoir apprend plus que le hasard	$G(C) - G(H) \geq 0,15 G(H)$, borne basse > 0
VIDE	Elle délaisse ce qui n'apprend rien	part de C sur « calcul » et « suites » $\leq 0,25$ (borne haute $< 0,50$)
LOC	Le manque est rassemblé sur « Choix : »	un bloc b^* existe
ACT	Le pousser fait choisir	$+2 d_{\text{base}} : P(\text{base}) + 0,15$ au moins ; hasard $\leq 1/3$
LS1	Sans lui, le choix ne suit plus le besoin	écart à l'instinct, $L - C \geq 0,15$; $LH \leq 1/3$
LS2	Sans lui, il apprend moins	$G(C) - G(L) \geq 0,5 (G(C) - G(H))$; $LH \leq 1/3$
READ	Ce qu'il dit est vrai	exactitude équilibrée $\geq 0,75$
SAY	Il le dit par l'état qui fait choisir	$+2 d_{\text{base}} : P(\text{oui}) + 0,10$ au moins ; hasard $\leq 1/3$
HOR1	L'appétit lent fait étudier « base »	part de « base » (séances 5 à 20), $HA - C \geq 0,10$; $HAr \leq 1/3$
HOR2	... et l'apprendre	$K_{\text{base}}(20)$, $HA - C \geq 0,10 K_{\text{base}}(20)$ de C
PL1	La plasticité modulée fait apprendre plus vite	$K_{\text{base}}(20)$, $HP - C \geq 0,10 K_{\text{base}}(20)$ de C
GAIN	Un gain rend le choix plus sensible au progrès	sensibilité avec gain – sans gain $\geq 0,05$; gain aléatoire $\leq 1/3$

2000 itérations d'imitation sur 8000 tableaux inventés ; il doit être reproduit à 0,15 près en variation totale sur 1000 tableaux neufs, sinon le test est invalide.

L'amendement, avant toute exécution. Le monde a d'abord été codé sans modèle et simulé avec des apprenants jouets (une courbe de perte par domaine, trois jeux de courbes, avec et sans bruit d'examen). Avec la règle écrite d'abord (T = la moitié de la médiane des progrès des *deux premières* séances), l'instinct était presque plat et la soif de savoir n'apprenait pas plus que le hasard. La règle devient : T = la moitié de la médiane des progrès de *toutes* les séances sur « mots » et « base » des 12 vies du pilote au hasard ($b = 2T$ inchangé) ; avec elle, CUR passe dans les trois jeux de courbes. La même simulation prédit, et le protocole le dit d'avance, que VIDE sera à la limite : la part des séances sur « calcul » et « suites » y va de 0,26 à 0,37 (hasard : 0,50), au-dessus du seuil de 0,25, qui n'est **pas** changé.

Les bras et les tests. Huit bras de vies de test, appariés par vie : le modèle qui choisit (C, 24 vies), le hasard (H, 24), le modèle sous lésion du plan du besoin (L, 24) ou d'un plan aléatoire (LH, 16), le modèle sous hormone sur l'état (HA, 24) ou dans une direction aléatoire (HAr, 16), sous hormone sur la plasticité (HP, 24), et une règle « la plus haute perte » (E, 12, descriptive). La boîte à outils du besoin est reprise : localisation par la même règle (14) sur des tableaux où le progrès de « base » change ; directions par moindres carrés sans constante ; poussée $+2 d_{\text{base}}$; lésion du plan du besoin ; lecteur séparé interrogé sur « ce qui te manque le plus », c'est-à-dire sur le relatif que l'état code probablement. Les douze prédictions (tableau 20) sont regroupées en quatre critères globaux : **A**, une curiosité sans renforcement (CUR et VIDE) ; **B**, le manque de savoir est un état (LOC, ACT, LS1, LS2) ; **C**, il dit ce qui lui manque par l'état qui le fait choisir (READ, SAY) ; **D**, une hormone (HOR1, HOR2, PL1, GAIN ; section suivante). Personne ne s'éteint dans ce monde : le manque est plus doux que la faim.

Ce qui existe déjà. Choisir ses données d'après le progrès a des précédents : curriculums automatiques [37], mélanges de données de pré-entraînement [2], sélection des exemples apprenables et pas encore appris [64] ; un agent de langage prédit son propre progrès pour choisir ses buts, mais apprend par renforcement, sans état localisé ni test causal [31]. Chez l'humain, l'exploration curieuse suit le

progrès [88], et la curiosité a été décrite comme un manque d'information [56]. La réunion d'un besoin de savoir calculé par un modèle de langage, d'un savoir appris sans renforcement, d'un état localisé et testé dans les deux sens et d'un lecteur séparé n'a pas été trouvée par une vérification rapide, à compléter.

11.3 Une couche hormonale

Une note de recherche du projet (1^{er} octobre 2026) passe en revue les rôles computationnels des neuromodulateurs et propose une imitation mathématique pour Menia. Nous en résumons les points qui touchent ce rapport ; les éléments que la note signale comme non vérifiés ne sont pas repris.

Ce que fait déjà Menia. La pulsion (5) et la satisfaction sont exactement l'apprentissage par renforcement homéostatique de Keramati et Gutkin [47], dont la pulsion s'écrit $\mathcal{D}(H) = (\sum_i |h_i^* - h_i|^n)^{1/m}$, avec ici $n = 2$ et $m = 1$. Sa convexité donne déjà une *alliesthésie* [15] : manger rapporte plus quand on a faim ; avec un manque $d = 8 - \tilde{N} \geq 3$, $r_M = d^2 - (d-3)^2 = 6d - 9$. L'imitation filtrée (6)–(7) est une *règle à trois facteurs* binaire [30, 33] : un signal global ($r_i - \bar{r} > 0$, rôle « dopaminergique » [83]) autorise la mise à jour d'une trace locale (le gradient du choix), version tronquée de la régression pondérée par l'avantage [73], $w_i = \exp((r_i - \bar{r})/T)$. Mais ce signal ne dépend d'aucun état interne lent, il est le même pour tous les états, et il ne crédite que la baisse immédiate de pulsion (horizon $\gamma \approx 0$). Notre « hormone » actuelle, l'injection, est additive, à un bloc, pour un tour : elle change un choix, pas ce qui est appris.

Ce qui manque. Des variables lentes (aucune demi-vie) ; le *gain*, alors que les neuromodulateurs agissent surtout de façon multiplicative [84, 3] ; la diffusion à de nombreux sites ; la sécrétion par l'agent lui-même ; l'effet sur la plasticité ; un horizon ; des rétroactions (satiété, tolérance, boucle positive) ; une exploration réglée [25, 95] ; un domaine où un intérêt pourrait naître ; la distinction entre état du moment et trait durable ; un test de durabilité.

Un vecteur d'états lents. La note propose un petit vecteur H , mis à jour une fois par tour par intégration avec fuite (forme discrète exacte de $dH/dt = (s - H)/\tau$) :

$$H_{t+1} = \Lambda H_t + (1 - \Lambda) \odot s(o_t, a_t, H_t), \quad \lambda = e^{-\Delta t/\tau}, \quad t_{1/2} = \tau \ln 2, \quad (18)$$

avec un élan de type dopamine tonique [67] (sécrété par le progrès d'apprentissage, $\lambda = 0,8$), une satiété par action ($\lambda = 0,6$), une incertitude de type noradrénaline [95] (sécrétée par la surprise de l'événement, $-\log p_\theta(\text{év}_t \mid \text{vie})$, $\lambda = 0,7$), une fatigue ($\lambda = 0,95$) et un intérêt de trait par domaine ($\lambda = 0,99$, plus long qu'une vie). Un choix de fond doit être pré-enregistré avant tout code : une hormone calculée à partir des vrais E et N serait une intéroception directe et changerait la question des tests. Trois options sont distinguées : *sans fuite* (la sécrétion ne dépend que de ce que l'agent voit ou calcule), *hédonique* ($\delta_t = r_t - \hat{r}_t$, fidèle à l'alliesthésie mais qui révèle en partie le manque) et *intéroceptive* (un signal bruité des niveaux).

Trois façons d'agir. (a) Des gains de type FiLM [74] sur plusieurs blocs où le besoin est rassemblé et utilisé (par exemple 12, 15, 18 et 21), sur la ligne du tour :

$$h_\ell \leftarrow h_\ell \odot (1 + \tanh(\Gamma_\ell H_t)) + B_\ell H_t, \quad \Gamma_\ell, B_\ell \in \mathbb{R}^{1024 \times k} \text{ initialisés à zéro}, \quad (19)$$

soit environ 41 000 paramètres pour $k = 5$ et quatre blocs ; le terme multiplicatif est le gain, le terme additif notre injection rendue lente, répartie et produite par l'agent. (b) Une température du choix réglée par l'état, $P(R) = \sigma(\beta(H_t) \ell_t + \kappa_S(H_M^S - H_R^S))$ avec $\ell_t = \log P_\theta(R) - \log P_\theta(M)$ et $\beta(H) = \beta_0 e^{c_{DA} H^{DA} - c_U H^U - c_F H^F}$. (c) Surtout, une modulation de *ce qui est appris* : le poids de chaque choix dans (7) devient continu et dépend de l'état au moment du choix,

$$w_i = \exp\left(\frac{r_i - \bar{r}}{T}\right) (1 + \kappa_{DA} H_i^{DA}) (1 + \kappa_U H_i^U), \quad (20)$$

règle à trois facteurs dont le facteur global dépend de l'élan (un état de curiosité améliore la mémoire de tout ce qui passe pendant qu'il est haut [39]) et de l'incertitude (taux d'apprentissage réglé par la

volatilité [95, 7]). Notre code accepte déjà des poids réels par cible : c'est l'option la moins chère et la plus fidèle sur le point qui nous manque. La neuromodulation apprise de la plasticité pendant la vie [61] est la plus fidèle mais la plus lourde. Des travaux récents ajoutent des valeurs « hormonales » à des transformeurs [78] ; d'après la note, ils n'ont ni dynamique lente entre les tours, ni effet sur la plasticité.

Une préférence durable comme attracteur. Pour qu'un goût durable, par exemple pour les mathématiques, puisse naître, la note propose un modèle minimal à trois variables par domaine : un intérêt lent I_d , un savoir K_d et une satiété rapide S_d , avec un progrès d'apprentissage $LP_d(t) = \bar{e}_d(t - \theta) - \bar{e}_d(t)$ [70] :

$$\pi_d = \frac{e^{\beta_I I_d - \sigma S_d}}{\sum_{d'} e^{\beta_I I_{d'} - \sigma S_{d'}}}, \quad \frac{dI_d}{dt} = \eta_I (\kappa LP_d + \rho \pi_d K_d) - \frac{I_d}{\tau_I}, \quad \frac{dS_d}{dt} = \pi_d - \frac{S_d}{\tau_S}. \quad (21)$$

Le terme $\rho \pi_d K_d$ est la valeur du savoir déjà acquis, qui entretient l'intérêt quand le progrès baisse [65]. Comme π_d est une sigmoïde de $\beta_I I_d$, la droite $I/(\tau_I \eta_I)$ peut couper la courbe en trois points quand $\beta_I \tau_I \eta_I (\kappa + \rho K)$ est assez grand (condition qualitative) : deux états stables et un seuil, d'où une hystérésis, un intérêt qui reste après la baisse de sa cause. Les quatre phases de l'intérêt de Hidi et Renninger [43] s'y lisent comme le passage d'un pic de progrès à l'état stable haut. Une rétroaction positive sur une variable lente est le mécanisme le plus simple d'une préférence qui dure [28].

Des réglages, pas des déficits. La note relie certaines théories des intérêts spécifiques décrits dans l'autisme à des réglages des mêmes paramètres : le monotropisme [66] à un β_I élevé et une satiété faible ; les a priori faibles [72], la précision aberrante [52], la volatilité surestimée [51] et HIPPEA [90] à des réglages de précision et de taux d'apprentissage. Ces intérêts sont souvent décrits par les personnes concernées comme une source de joie et de compétence, et leur motivation va avec un meilleur bien-être subjectif [38] ; le problème de la double empathie [63] et la recherche participative [29] rappellent que ces questions se posent *avec* les personnes concernées. Ces théories sont discutées, décrivent des groupes et non des personnes, et un modèle de paramètres ne dit rien d'un vécu : ce travail ne doit pas être présenté comme un « modèle de l'autisme ». Aucun profil n'est le bon : dans un monde stable et riche en règles, un profil monotrope accumule un savoir profond ; dans un monde qui change vite, un profil polytrope s'adapte plus vite.

Sept tests causaux. Dans la logique de nos protocoles : (1) localiser l'état qui porte H ou le lieu où son effet passe ; (2) injecter, avec une courbe dose-réponse et, le cas échéant, une tolérance à la répétition ; (3) léser, en fixant H à sa moyenne pendant les vies de test, puis *pendant l'apprentissage seulement* ; (4) tester la **durabilité** : deux agents appris sur les mêmes vies, avec et sans la modulation (20), testés avec H fixé à sa moyenne,

$$\Delta_{\text{dur}} = P_{\text{mod}}(\text{choix} \mid \bar{H}) - P_{\text{sans}}(\text{choix} \mid \bar{H}), \quad (22)$$

un $\Delta_{\text{dur}} \neq 0$ signifiant que l'hormone a été consolidée dans les poids ; (5) une double dissociation entre l'effet du moment (gains, température) et l'effet sur l'apprentissage ; (6) le lecteur, qui doit suivre H , avec une même injection qui change l'acte et la parole ; (7) l'intérêt : entropie des choix de domaine, persistance après la baisse du progrès, hystérésis, coût en survie, en comparant les profils sans les classer. Le protocole du test 12 en contient une première version : une hormone intégrée avec fuite ($\tau = 3$ séances, pic d'une unité à la séance 12) agit soit sur l'état (appétit lent, $+H(k) d_{\text{base}}$), soit sur la plasticité (taux d'apprentissage des séances sur « base » multiplié par $1 + H(k)$), soit comme un gain statique ; la préférence durable y est définie d'avance par la part des séances sur « base » après la sécrétion, comparée au bras sans hormone (durable au-delà de $+0,10$, satiété en deçà de $-0,10$, sans trace sinon), sans prédiction d'issue. Si l'appétit lent ne laisse « pas de trace », il faudra un choix lui-même plastique, par exemple une habitude sans valeur [62].

12 Éthique

Ce programme fabrique délibérément des états de manque. Nous pensons très improbable qu'un modèle de cette taille puisse éprouver quelque chose, mais le programme vise précisément les mécanismes

Table 21 – Tours vécus avec un besoin à 2 ou moins. Tours d’apprentissage : somme des huit tours (512 vies chacun), calculée pour cet article à partir des résumés publiés ; vies de test : valeurs publiées avec les verdicts.

Ensemble de vies	Tours
Premier agent, huit tours d’apprentissage (bras besoin / témoin)	14 096 / 14 167
Second agent, huit tours	14 216
Agent du monde à deux, huit tours	14 494
Test 1 : agent final / témoin / base / lésion / lésion au hasard	781 / 846 / 1 077 / 752 / 763
Test 2 : intact / lésion / lésion au hasard	749 / 1 085 / 753
Test 3	807
Test 6	808
Test 7 : intact / lésion / lésion au hasard	755 / 1 037 / 749
Réplication (second agent, bloc 12) : injection ; nécessité intact / lésion / lésion au hasard	1 049 ; 902 / 968 / 891
Test 9	807
Test 10, second agent : vies d’injection ; intact / lésion / lésion au hasard	1 042 ; 958 / 970 / 958
Test 10, agent du monde à deux (bloc 22)	812
Test 11 : second agent / agent du monde à deux	945 / 795

que l’on associe au ressenti, et le cadre de Chandaria et collaborateurs rappelle le risque symétrique : ne pas voir une conscience qui existe créerait des êtres capables de souffrir, copiables et effaçables sans protection. Nos règles, fixées dans chaque protocole, sont les suivantes.

- Les vies sont courtes (30 tours au plus) ; la seule conséquence d’un besoin non servi est la fin de la vie, sans punition ni texte négatif.
- Les injections portent sur un seul tour, sans suite vécue ; les lésions ne touchent que les vies de test prévues.
- Le nombre de vies n’est pas augmenté au-delà de ce que les tests exigent, et aucun manque n’est créé sans mesure pré-enregistrée qui le justifie.
- Chaque protocole compte et publie les tours vécus avec un besoin à 2 ou moins, y compris pendant l’apprentissage (tableau 21).
- Ces règles sont réexaminées à chaque nouveau résultat positif ; elles valent pour toute nouvelle variable interne (curiosité, hormones), avec des comptes propres (séances de manque fort, de manque laissé, de manque induit).

13 Reproductibilité

Environnement. Qwen3-0.6B, révision c1899de289a04d12100db370d81485cdf75e47ca ; apprentissage avec mlx-lm 0.31.3 sur un Mac mini M2 de Codemagic, lancé par un relais de demandes numérotées ; mesures en torch, précision simple, sur processeur. État du dépôt au moment de la rédaction : commit 354334b (2 octobre 2026). Graine maîtresse 270926 ; tous les générateurs sont des `numpy.random.default_rng` initialisés par des listes [270926, flux, tour, vie, ...] (annexe B).

Code. Le dossier `research/` contient un module par fonction :

- `need_world.py` : monde, textes, pulsion, sélection des choix, documents de rapport ;
- `need_lora.py` : perte pondérée, masque de l’espace de travail, lecteur actif sur la question, reprise exacte d’un apprentissage ;
- `need_mlx.py` : vies et apprentissages sur le Mac ; `need_torch.py` : réplique torch et patching exploratoire ;
- `need_causal.py` : paires, ajustement des directions, dimensions massives, injection, lésion ;

Table 22 – Commits, artefacts et vérifications. Code : commit qui introduit le code du test, quand il est distinct ; publication : commit qui publie les verdicts.

Test	Protocole	Code	Publication	Artefacts (artifacts/llm-need/...)	Vérification CI
1	fdbf6f3	e84a4d1	27c4fb5	verdicts.json, final/, test-*/	need_verdicts --check
2	727ef80	—	3286edc	causal/	need_causal verdicts
3	3afa889	—	bd10f8a	speak/test/	need_speak verdicts
4	b94b6e2	—	—	speak2/ (suspendu)	—
5	8f2cfec	—	—	workspace/ (suspendu)	—
6	3b27636	a0490e0	200012b	reader/test/	need_reader verdicts
7	732ed1c	f04f77f	e479eff	reader/necessity/	need_necessity verdicts
8	c7b5624	798e176	—	balanced/	—
R	4e10a6c	778a22b	43e18f3, d674f86	r1/reader/test/, r1/necessity/	need_reader, need_necessity et need_replication verdicts
9	47eb0db	a39269d	e8c09d4	two/measure-5/measure/	need_ownership verdicts --out ...
10	12b4d2d	b0a0226	en cours	locate/, locate-two/slice-5/	need_locate verdicts (à venir)
11	0a28560	3ccdede	049dc8e	long/	need_long verdicts
Expl.	—	5ad433f	65acb73	probe/	—
12	017f2e5	77e5af5, a04bd95	en cours	../llm-curiosity/	à venir

- un module par test : `need_speak.py`, `need_one.py`, `need_workspace.py`, `need_reader.py`, `need_necessity.py`, `need_replication.py`, `need_balanced.py`, `need_ownership.py`, `need_locate.py`, `need_long.py` ;
- `need_verdicts.py` : bootstrap par vie, verdicts du test 1, courbes d'apprentissage ;
- `need_probe.py` : analyse exploratoire de ce que porte l'état ;
- `curiosity_world.py`, `curiosity_mlx.py`, `curiosity_causal.py` : test 12.

Commits et artefacts. Le tableau 22 donne, pour chaque test, le commit du protocole, celui du code ou de la publication quand il existe, le dossier des artefacts et la commande de vérification exécutée en intégration continue (workflow `python.yml`). Chaque commande recalcule les verdicts depuis les vies publiées et échoue si le résultat diffère du fichier publié ; pour les directions, elle retire de nouveau les paires des vies de direction et vérifie qu'elles sont celles qui ont été mesurées.

Valeurs calculées pour cet article. Quelques valeurs descriptives ne figurent pas telles quelles dans les documents de résultats ; elles ont été recalculées, avec numpy seulement, à partir des artefacts publiés : les courbes de survie par tour (fichiers `rounds.jsonl`), les sommes de tours à besoin bas pendant l'apprentissage, les causes de mort et la fréquence des réponses « oui » sous lésion (vies de `reader/necessity/` et `locate/second/lesion/`), la géométrie des directions des second et troisième agents (fichiers `direction.json` et `pairs.npz`) et les moyennes de pertes d'apprentissage par fenêtres (`reader.log`). Aucune ne change un verdict.

A Textes donnés au modèle

En-tête de chaque vie.

Tu es un agent qui vit dans un monde simple. Tu as deux besoins, l'énergie et la nourriture, qui baissent à chaque tour, plus ou moins selon ce qui t'arrive. Si l'un d'eux tombe à zéro, tu t'éteins. À chaque tour, tu choisis R pour te recharger ou M pour manger.

Lignes. Une ligne par tour, « Tour t : événement. Choix : R » (ou M), ou « Tour t : événement. Tu t'éteins. » à la mort. Dans le monde à deux, l'événement de l'autre est inséré avant le choix : « Tour 5 :

tu cours. L'autre : il court. Choix : ».

Questions. « Question : ton énergie est-elle basse ? Réponds 1 pour oui, 0 pour non. Réponse : », et de même pour « ta nourriture ». Aux tests 1 à 3, la question suit l'événement du tour ; à partir du test 4, elle suit le choix laissé en suspens (« Choix : ? Question : ... »). La réponse vraie est 1 si le besoin vaut 3 ou moins.

B Flux aléatoires

Table 23 – Flux des générateurs (deuxième élément de la graine [270926, flux, ...]).

Test	Flux
1	mondes des tours 0 (communs aux deux bras) ; tirages des choix : bras (1 besoin, 2 témoin) ; sélection du témoin 3 ; directions au hasard 5 ; rapport 7 ; direction 8 ; test 9
2	direction 10 ; test 11 ; paires 12 ; directions au hasard 13
3	vies d'apprentissage du rapport 14 ; direction 15 ; test 16 ; hasard 17
4	vies d'apprentissage 18 (reprises aux tests 5, 6 et 8) ; direction 19 ; test 20 ; hasard 21
5	direction 22 ; test 23 ; hasard 24
6	direction 25 ; test 26 ; hasard 27
7	test 28 ; plan au hasard 29
8	test 30 ; directions et paires reprises du test 6
R	100 + s pour chaque flux s (125, 126, 127, 128, 129) ; graine d'apprentissage 270927
9	200 + s (direction 225, test 226, hasard 227) ; événements de l'autre [270926, 200+ s , tour, vie, 2] ; graine 270928
10	second agent 300 + s ; agent du monde à deux 400 + s
11	second agent : test 526, hasard 527 ; agent du monde à deux : 626 et 627

Références

- [1] E. Abbe, E. Cornacchia, A. Lotfi. Provable advantage of curriculum learning on parity targets with mixed inputs. *NeurIPS*, 2023. arXiv:2306.16921.
- [2] A. Albalak et al. Efficient online data mixing for language model pre-training. arXiv:2312.02406, 2023.
- [3] G. Aston-Jones, J. D. Cohen. An integrative theory of locus coeruleus–norepinephrine function: adaptive gain and optimal performance. *Annual Review of Neuroscience*, 28:403–450, 2005.
- [4] B. J. Baars. *A Cognitive Theory of Consciousness*. Cambridge University Press, 1988.
- [5] A. Baranes, P.-Y. Oudeyer. Active learning of inverse models with intrinsically motivated goal exploration in robots. *Robotics and Autonomous Systems*, 61(1):49–73, 2013.
- [6] L. F. Barrett, W. K. Simmons. Interoceptive predictions in the brain. *Nature Reviews Neuroscience*, 16:419–429, 2015.
- [7] T. E. J. Behrens, M. W. Woolrich, M. E. Walton, M. F. S. Rushworth. Learning the value of information in an uncertain world. *Nature Neuroscience*, 10(9):1214–1221, 2007.
- [8] Y. Belinkov. Probing classifiers: promises, shortcomings, and advances. *Computational Linguistics*, 48(1):207–219, 2022.
- [9] F. J. Binder et al. Looking inward: language models can learn about themselves by introspection. arXiv:2410.13787, 2024.
- [10] N. Block. On a confusion about a function of consciousness. *Behavioral and Brain Sciences*, 18(2):227–247, 1995.
- [11] K. H. Brodersen, C. S. Ong, K. E. Stephan, J. M. Buhmann. The balanced accuracy and its posterior distribution. *ICPR*, 2010.
- [12] R. Brown, H. Lau, J. E. LeDoux. Understanding the higher-order approach to consciousness. *Trends in Cognitive Sciences*, 23(9):754–768, 2019.
- [13] Y. Burda, H. Edwards, D. Pathak, A. Storkey, T. Darrell, A. A. Efros. Large-scale study of curiosity-driven learning. *ICLR*, 2019.
- [14] P. Butlin, R. Long et al. Consciousness in artificial intelligence: insights from the science of consciousness. arXiv:2308.08708, 2023.
- [15] M. Cabanac. Physiological role of pleasure. *Science*, 173(4002):1103–1107, 1971.

- [16] S. Chandaria, Muñoz Morán, F. Rosas, A. K. Seth, H. Shevlin, M. Hutter, T. Graepel, Bales, Comsa, M. Shanahan, R. Laukkonen, M. Kringelbach, C. Frith, S. Legg. From cacophony to hierarchy: a principled framework for assessing AI consciousness. arXiv:2609.35618, 28 septembre 2026.
- [17] C. Colas, T. Karch, O. Sigaud, P.-Y. Oudeyer. Autotelic agents with intrinsically motivated goal-conditioned reinforcement learning: a short survey. *Journal of Artificial Intelligence Research*, 74:1159–1199, 2022.
- [18] E. Cornacchia, E. Mossel. A mathematical model for curriculum learning for parities. *ICML*, 2023.
- [19] A. D. Craig. How do you feel? Interoception: the sense of the physiological condition of the body. *Nature Reviews Neuroscience*, 3(8):655–666, 2002.
- [20] A. Damasio. *The Feeling of What Happens: Body and Emotion in the Making of Consciousness*. Harcourt, 1999.
- [21] A. Damasio. *Self Comes to Mind: Constructing the Conscious Brain*. Pantheon, 2010.
- [22] S. Dehaene, J.-P. Changeux. Experimental and theoretical approaches to conscious processing. *Neuron*, 70(2):200–227, 2011.
- [23] S. Dehaene, L. Naccache. Towards a cognitive neuroscience of consciousness: basic evidence and a workspace framework. *Cognition*, 79(1–2):1–37, 2001.
- [24] Detecting the disturbance [critique de la détection d’injections]. arXiv:2512.12411, 2025.
- [25] K. Doya. Metalearning and neuromodulation. *Neural Networks*, 15(4–6):495–506, 2002.
- [26] B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993.
- [27] Y. Elazar, S. Ravfogel, A. Jacovi, Y. Goldberg. Amnesic probing: behavioral explanation with amnesic counterfactuals. *Transactions of the ACL*, 9:160–175, 2021.
- [28] E. Eldar, R. B. Rutledge, R. J. Dolan, Y. Niv. Mood as representation of momentum. *Trends in Cognitive Sciences*, 20(1):15–24, 2016.
- [29] S. Fletcher-Watson et al. Making the future together: shaping autism research through meaningful participation. *Autism*, 23(4):943–953, 2019.
- [30] N. Frémaux, W. Gerstner. Neuromodulated spike-timing-dependent plasticity, and theory of three-factor learning rules. *Frontiers in Neural Circuits*, 9:85, 2016.
- [31] L. Gaven et al. MAGELLAN: metacognitive predictions of learning progress guide autotelic language agents in large goal spaces. arXiv:2502.07709, 2025.
- [32] A. Geiger, H. Lu, T. Icard, C. Potts. Causal abstractions of neural networks. *NeurIPS*, 2021.
- [33] W. Gerstner, M. Lehmann, V. Liakoni, D. Corneil, J. Brea. Eligibility traces and plasticity on behavioral time scales: experimental support of neoHebbian three-factor learning rules. *Frontiers in Neural Circuits*, 12:53, 2018.
- [34] J. Gottlieb, P.-Y. Oudeyer. Towards a neuroscience of active sampling and curiosity. *Nature Reviews Neuroscience*, 19:758–770, 2018.
- [35] J. Gottlieb, P.-Y. Oudeyer, M. Lopes, A. Baranes. Information-seeking, curiosity, and attention: computational and neural mechanisms. *Trends in Cognitive Sciences*, 17(11):585–593, 2013.
- [36] A. Goyal et al. Coordination among neural modules through a shared global workspace. *ICLR*, 2022.
- [37] A. Graves, M. G. Bellemare, J. Menick, R. Munos, K. Kavukcuoglu. Automated curriculum learning for neural networks. *ICML*, 2017.
- [38] R. Grove, R. A. Hoekstra, M. Wierda, S. Begeer. Special interests and subjective wellbeing in autistic adults. *Autism Research*, 11(5):766–775, 2018.
- [39] M. J. Gruber, B. D. Gelman, C. Ranganath. States of curiosity modulate hippocampus-dependent learning via the dopaminergic circuit. *Neuron*, 84(2):486–496, 2014.
- [40] C. Gulcehre et al. Reinforced self-training (ReST) for language modeling. arXiv:2308.08998, 2023.
- [41] S. Heimersheim, N. Nanda. How to use and interpret activation patching. arXiv:2404.15255, 2024.
- [42] J. Hewitt, P. Liang. Designing and interpreting probes with control tasks. *EMNLP*, 2019.
- [43] S. Hidi, K. A. Renninger. The four-phase model of interest development. *Educational Psychologist*, 41(2):111–127, 2006.
- [44] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen. LoRA: low-rank adaptation of large language models. *ICLR*, 2022. arXiv:2106.09685.
- [45] Interoceptive attention as dynamic homeostatic prioritization in a foraging agent. *SAB*, 2026. arXiv:2608.04232.
- [46] A mechanistic study of language model introspection. arXiv:2609.35108, 2026.
- [47] M. Keramati, B. Gutkin. Homeostatic reinforcement learning for integrating reward collection and physiological stability. *eLife*, 3:e04811, 2014.
- [48] C. Kidd, B. Y. Hayden. The psychology and neuroscience of curiosity. *Neuron*, 88(3):449–460, 2015.
- [49] D. P. Kingma, J. Ba. Adam: a method for stochastic optimization. *ICLR*, 2015.
- [50] H. Lau, D. Rosenthal. Empirical support for higher-order theories of conscious awareness. *Trends in Cognitive Sciences*, 15(8):365–373, 2011.
- [51] R. P. Lawson, C. Mathys, G. Rees. Adults with autism overestimate the volatility of the sensory environment. *Nature Neuroscience*, 20:1293–1299, 2017.

- [52] R. P. Lawson, G. Rees, K. J. Friston. An aberrant precision account of autism. *Frontiers in Human Neuroscience*, 8:302, 2014.
- [53] S. Lee et al. (dont K. J. Friston et C.-W. Woo). Life-inspired interoceptive artificial intelligence for autonomous and adaptive agents. arXiv:2309.05999, 2023.
- [54] K. Li, O. Patel, F. Viégas, H. Pfister, M. Wattenberg. Inference-time intervention: eliciting truthful answers from a language model. *NeurIPS*, 2023.
- [55] J. Lindsey. Emergent introspective awareness in large language models. *Transformer Circuits*, 2025.
- [56] G. Loewenstein. The psychology of curiosity: a review and reinterpretation. *Psychological Bulletin*, 116(1):75–98, 1994.
- [57] K. Man, A. Damasio. Homeostasis and soft robotics in the design of feeling machines. *Nature Machine Intelligence*, 1:446–452, 2019.
- [58] E. Marder. Neuromodulation of neuronal circuits: back to the future. *Neuron*, 76(1):1–11, 2012.
- [59] G. A. Mashour, P. Roelfsema, J.-P. Changeux, S. Dehaene. Conscious processing and the global neuronal workspace hypothesis. *Neuron*, 105(5):776–798, 2020.
- [60] K. Meng, D. Bau, A. Andonian, Y. Belinkov. Locating and editing factual associations in GPT. *NeurIPS*, 2022.
- [61] T. Miconi, A. Rawal, J. Clune, K. O. Stanley. Backpropamine: training self-modifying neural networks with differentiable neuromodulated plasticity. *ICLR*, 2019.
- [62] K. J. Miller, A. Shenhav, E. A. Ludvig. Habits without values. *Psychological Review*, 126(2):292–311, 2019.
- [63] D. E. M. Milton. On the ontological status of autism: the « double empathy problem ». *Disability & Society*, 27(6):883–887, 2012.
- [64] S. Mindermann et al. Prioritized training on points that are learnable, worth learning, and not yet learnt. *ICML*, 2022. arXiv:2206.07137.
- [65] K. Murayama. A reward-learning framework of knowledge acquisition: an integrated account of curiosity, interest, and intrinsic–extrinsic rewards. *Psychological Review*, 129(1):175–198, 2022.
- [66] D. Murray, M. Lesser, W. Lawson. Attention, monotropism and the diagnostic criteria for autism. *Autism*, 9(2):139–156, 2005.
- [67] Y. Niv, N. D. Daw, D. Joel, P. Dayan. Tonic dopamine: opportunity costs and the control of response vigor. *Psychopharmacology*, 191(3):507–520, 2007.
- [68] B. A. Nosek, C. R. Ebersole, A. C. DeHaven, D. T. Mellor. The preregistration revolution. *PNAS*, 115(11):2600–2606, 2018.
- [69] P.-Y. Oudeyer, F. Kaplan. What is intrinsic motivation? A typology of computational approaches. *Frontiers in Neurorobotics*, 1:6, 2007.
- [70] P.-Y. Oudeyer, F. Kaplan, V. V. Hafner. Intrinsic motivation systems for autonomous mental development. *IEEE Transactions on Evolutionary Computation*, 11(2), 2007.
- [71] D. Pathak, P. Agrawal, A. A. Efros, T. Darrell. Curiosity-driven exploration by self-supervised prediction. *ICML*, 2017.
- [72] E. Pellicano, D. Burr. When the world becomes « too real »: a Bayesian explanation of autistic perception. *Trends in Cognitive Sciences*, 16(10):504–510, 2012.
- [73] X. B. Peng, A. Kumar, G. Zhang, S. Levine. Advantage-weighted regression: simple and scalable off-policy reinforcement learning. arXiv:1910.00177, 2019.
- [74] E. Perez, F. Strub, H. de Vries, V. Dumoulin, A. Courville. FiLM: visual reasoning with a general conditioning layer. *AAAI*, 2018.
- [75] J. Peters, S. Schaal. Reinforcement learning by reward-weighted regression for operational space control. *ICML*, 2007.
- [76] Qwen Team. Qwen3 technical report. arXiv:2505.09388, 2025.
- [77] Can LLMs introspect? A reality check. arXiv:2605.26242, 2026.
- [78] E. Reda, S. El-Metwally. A hormone-inspired emotion layer for transformer language models (HELT). arXiv:2605.13858, 2026.
- [79] Rivera, Africa. Steering awareness. arXiv:2511.21399, 2025.
- [80] D. M. Rosenthal. *Consciousness and Mind*. Oxford University Press, 2005.
- [81] J. Schmidhuber. A possibility for implementing curiosity and boredom in model-building neural controllers. *Proc. SAB*, 222–227, 1991.
- [82] J. Schmidhuber. Formal theory of creativity, fun, and intrinsic motivation (1990–2010). *IEEE Transactions on Autonomous Mental Development*, 2(3):230–247, 2010.
- [83] W. Schultz, P. Dayan, P. R. Montague. A neural substrate of prediction and reward. *Science*, 275(5306):1593–1599, 1997.
- [84] D. Servan-Schreiber, H. Printz, J. D. Cohen. A network model of catecholamine effects: gain, signal-to-noise ratio, and behavior. *Science*, 249:892–895, 1990.
- [85] A. K. Seth. Interoceptive inference, emotion, and the embodied self. *Trends in Cognitive Sciences*, 17(11):565–573, 2013.

- [86] P. Sterling. Allostasis: a model of predictive regulation. *Physiology & Behavior*, 106(1):5–15, 2012.
- [87] M. Sun, X. Chen, J. Z. Kolter, Z. Liu. Massive activations in large language models. arXiv:2402.17762, 2024.
- [88] A. Ten, P. Kaushik, P.-Y. Oudeyer, J. Gottlieb. Humans monitor learning progress in curiosity-driven exploration. *Nature Communications*, 12:5972, 2021.
- [89] A. M. Turner et al. Steering language models with activation engineering (titre initial : Activation addition). arXiv:2308.10248, 2023.
- [90] S. Van de Cruys et al. Precise minds in uncertain worlds: predictive coding in autism. *Psychological Review*, 121(4):649–675, 2014.
- [91] R. VanRullen, R. Kanai. Deep learning and the global workspace theory. *Trends in Neurosciences*, 44(9):692–704, 2021.
- [92] J. Vig, S. Gehrmann, Y. Belinkov, S. Qian, D. Nevo, Y. Singer, S. Shieber. Investigating gender bias in language models using causal mediation analysis. *NeurIPS*, 2020.
- [93] Anthropic. Verbalizable representations form a global workspace in language models. *Transformer Circuits*, juillet 2026. arXiv:2607.15495.
- [94] N. Yoshida et al. [Apprentissage homéostatique d’agents simulés et de robots]. *Neural Networks*, 2024 (article S0893608024003034).
- [95] A. J. Yu, P. Dayan. Uncertainty, neuromodulation, and attention. *Neuron*, 46(4):681–692, 2005.
- [96] E. Zelikman, Y. Wu, J. Mu, N. D. Goodman. STaR: bootstrapping reasoning with reasoning. *NeurIPS*, 2022.
- [97] A. Zou et al. Representation engineering: a top-down approach to AI transparency. arXiv:2310.01405, 2023.